



XỬ LÝ NGÔN NGỮ TỰ NHIÊN

BÁO CÁO BÀI TẬP LỚN CUỐI KỲ

Khi nào phối hợp đa tác tử LLM tạo ra giá trị?
Một khảo sát thực nghiệm dưới ba phép kiểm soát

Dương Trọng Nguyên
24022420

Trương Đình Đức
24021419

Trần Tùng Dương
24022309

Lê Hoàng Quân
24022433

Lớp học phần: INT3406

Hà Nội, 08/2026

Tóm tắt nội dung

Các hệ nhiều tác tử ngôn ngữ lớn — một model lập kế hoạch, một model giải, một model kiểm tra, một model tổng hợp — thường được báo cáo là vượt trội so với một model chạy một mình. Khảo sát này đo lại nhận định đó trên bốn benchmark suy luận (GSM8K, MATH-500, MBPP, HumanEval) với các model 1,5–32 tỷ tham số, dưới ba phép kiểm soát mà phần lớn báo cáo trong lĩnh vực bỏ qua: so ở cùng chi phí tính toán; so với model mạnh chạy một mình thay vì với model yếu; và chỉ tính trên những câu mà phối hợp còn có thể tạo khác biệt.

Sau ba phép kiểm soát, phần lớn hiệu ứng dương biến mất hoặc đổi dấu. Hiệu ứng dương lớn nhất (mười bốn điểm phần trăm) chỉ tồn tại khi so với model yếu; so cùng chi phí với model mạnh chạy một mình thì hoà hoặc thua. Thí nghiệm chính — thiết kế chốt trước, tái lập trên hai miền — định vị được nguồn thiệt hại: khi model mạnh nhìn thấy một bài làm *sai* của model yếu, độ chính xác của nó rơi từ 46% xuống 19% trên chính những bài nó vốn giải được, trong khi bài làm đúng giúp nó tốt lên nhẹ. Hệ quả là một nghịch lý biểu kiến được giải: chênh lệch năng lực giữa hai model làm giao thức “sửa bài của nhau” ngày càng thua, nhưng lại làm phép so-với-model-yếu ngày càng đẹp — cùng một biến, hai dấu, tuy mốc so sánh.

Về phía bộ kiểm: nơi có cách kiểm chắc chắn (code chạy được test), phối hợp đạt đúng trần lý tưởng và không phá bài nào khi model chưa bão hoà; nơi không có, một bộ phân loại lỗi rất tốt (AUC 0,893) cũng chỉ đổi được hơn hai điểm — khoảng cách giữa trần lý tưởng và bộ phiếu đa số là chặn trên mà không tín hiệu học được nào trong khảo sát vượt qua. Bảy nỗ lực huấn luyện các vai trò (ba biến thể GRPO, ORPO, credit-RL hai giai đoạn, đồng huấn luyện) đều không vượt chuẩn: model nhất quán tìm ra lỗi tắt của hàm thưởng — im lặng, nhại lại, bỏ kế hoạch — thay vì học kiểm thật. Toàn bộ quy trình dùng chốt trước và điều kiện hợp lệ; một nửa số lần chạy không vượt qua và bị loại trước khi đọc số.

1 Mở đầu


Việc ghép nhiều model ngôn ngữ lớn (LLM) thành một hệ thống đa tác tử gồm Planner, Solver, Verifier, Aggregator liệu có thực sự mang lại hiệu quả tốt hơn so với một model mạnh đơn lẻ tự làm không? Trực giác tự nhiên cho thấy việc phân tách nhiệm vụ và bổ sung cơ chế kiểm tra chéo sẽ giúp phát hiện lỗi sai tốt hơn, cải thiện độ chính xác. Nhận định này cũng được sự ủng hộ từ phần lớn các công trình công bố trong lĩnh vực gần đây.

Tuy nhiên, một quan sát thực nghiệm đã chỉ ra tính bất ổn của trực giác ban đầu này. Trên bộ dữ liệu MATH, khi sử dụng một model Qwen-7B đơn lẻ làm baseline, độ chính xác đạt 46,4%. Nhưng khi thêm vào ngữ cảnh một bài làm sai của model yếu hơn (Qwen-1,5B) cho chính bài toán đó, độ chính xác của Qwen-7B giảm mạnh xuống chỉ còn 19,2%. Model mạnh đã giải sai chính những bài toán mà nó vốn giải được, chỉ vì nhìn thấy thông tin nhiễu từ một lời giải sai của agent khác (Hình 1, chi tiết ở §5.9). Ngược lại, nếu lời giải được thêm vào là đúng chỉ mang lại mức cải thiện khiêm tốn. Điều này cho thấy việc cho các model xem bài của nhau là con dao hai lưỡi mà trong đó tác động tiêu cực nhiều hơn so với tác động tích cực.

Sự mâu thuẫn giữa thực nghiệm này và các bài báo cáo tích cực trước đây xuất phát từ 3 vấn đề nghiêm trọng trong phương pháp đo lường:

Thứ nhất, chi phí. Với cùng model 1,5B, một pipeline gồm bốn vai trò sinh ra lượng token gấp 2,9 lần (trên tập GSM8K) đến 6,6 lần (trên tập MATH) so với một lần sinh đơn lẻ. Khi các vai trò dùng model kích thước khác nhau, ngay cả số token cũng không cùng đơn giá — một token do model 7B sinh tốn khoảng 4,7–4,9 lần phép tính (FLOP) so với token của model 1,5B, vì chi phí suy luận tỷ lệ với số tham số [12] (§5.5). Việc so sánh 1 hệ thống tốn kém tài nguyên với 1 model đơn lẻ chạy mà không quy đổi về cùng một mức ngân sách tính toán (FLOP) sẽ dẫn đến những kết luận thiếu công bằng về mặt hiệu quả.

Thứ hai, mốc so sánh. Phần lớn các nghiên cứu thuộc nhóm generate-and-refine thường đo mức độ cải thiện so với model bị sửa (model yếu). Tuy nhiên trong thực tế, người ta thường phân vân giữa việc chạy cả hệ thống đa tác tử phức tạp hay chỉ dùng 1 model mạnh đơn lẻ. Khảo sát này chứng minh rằng việc chọn mốc baseline so sánh khác nhau có thể làm đảo ngược hoàn toàn dấu của hiệu ứng thu được (§5.5, §6).



Hình 1: *Thí nghiệm tác động artifact* — cho model mạnh xem bài làm của model yếu (thiết kế chốt trước, MATH-500): hai nhánh chỉ khác nhau ở việc ngữ cảnh có kèm bài làm sai của model yếu hay không. Chênh lệch $-27,2$ điểm ($p \approx 0$) là nguồn thiệt hại chính của các giao thức cho model sửa bài của nhau (§5.9).

Thứ ba, mẫu số. Trên tập dữ liệu MATH, với model 1,5B, có tới 57% số bài toán nằm ngoài khả năng can thiệp của các cơ chế chọn ứng viên. Trong đó, 32% bài toán quá khó khiến cho mọi đáp án candidate đều sai, 25% bài toán quá dễ khiến cho mọi đáp án candidate đều đúng. Cả 2 trường hợp này đều khiến cho bộ tổng hợp không giúp cải thiện gì hơn. Việc tính trung bình trên toàn bộ tập dữ liệu sẽ làm suy giảm tín hiệu cải thiện thực tế, dẫn đến nguy cơ bác bỏ sai các can thiệp có giá trị (§5.6). Thiếu kiểm soát này thì *đánh giá thấp* hiệu ứng thật; thiếu hai kiểm soát trên thì *đánh giá cao* — ba sai lệch không cùng chiều, nên chúng phải được áp đủ cùng lúc chứ không thay thế được cho nhau.

Đóng góp. Khảo sát này hợp nhất 3 hướng nghiên cứu vào 1 khung đo duy nhất: Phân rã đóng góp theo vai trò, phân tích chi phí, lợi ích của định tuyến, và phân tích luồng thông tin. Bốn đóng góp chính bao gồm:

1. **Ba phép kiểm soát** Đưa ra bằng chứng thực nghiệm cho thấy khi áp dụng đồng thời ba phép kiểm soát (Chi phí, mốc so sánh và mẫu số), phần lớn các hiệu ứng tích cực của sự phối hợp đa tác tử đều suy giảm hoặc đảo chiều (§5).
2. **Thí nghiệm tác động artifact** — cho model mạnh xem bài làm của model yếu — thiết kế chốt trước, tái lập hai miền (Hình 1): Tái lập thí nghiệm trên 2 miền để xác định nguyên nhân thiệt hại của cơ chế sinh-rời-sửa xuất phát trực tiếp từ việc tiếp xúc với thông tin sai lệch từ model yếu, chứ không phải đến từ việc nhìn thấy lời giải, qua đó khẳng định cơ chế sinh-rời-sửa hoạt động như một kênh truyền dẫn đáp án hơn là 1 cơ chế tự sửa lỗi (§5.9).
3. **Lời giải cho nghịch lý “cùng biến, hai dấu”**: Sự chênh lệch năng lực giữa các model khiến kết quả khi so với model yếu ngày càng tốt, tạo cảm giác cải thiện lớn, nhưng giá trị thực tế khi so với model mạnh đơn lẻ lại ngày càng âm. Sự mâu thuẫn này nằm ở việc chọn sai mốc baseline chứ không phải do ưu thế của cơ chế đa tác tử (§6).
4. **Một chặn trên cho giá trị của bộ kiểm**: Mức độ đóng góp của bộ kiểm bị chặn bởi khoảng cách giữa trần lý tưởng (Oracle) và phương pháp bỏ phiếu đa số (Majority Voting). Nghiên cứu chỉ ra rằng các tín hiệu kiểm tra chắc chắn (thực thi mã chạy test) có thể đạt tiệm cận mức trần này, trong khi các tín hiệu học được như cơ chế LLM-as-a-judge chỉ đóng góp một phần rất hạn chế (§5.10).

Toàn bộ số liệu đi kèm quy trình chống tự đánh lừa (chốt trước, điều kiện hợp lệ) mô tả ở §4; 50% số lần chạy không vượt qua điều kiện và bị loại trước khi đọc số. Báo cáo dùng một số ký hiệu riêng; Bảng 1 là chỗ tra nhanh — mọi ký hiệu đều được định nghĩa đầy đủ ở §3–4 trước khi dùng.

Tra nhanh ký hiệu (chi tiết: §3–4; ví dụ bằng số: Phụ lục A)

P, S, V, A	bốn <i>vai trò</i> pipeline: lập dàn ý – giải – kiểm-và-sửa – chọn đáp án cuối; viết liền là tổ hợp vai trò (PSVA = đủ bốn vai trò)
lần sinh	một lần model sinh trọn một lời giải; k lần sinh thì độc lập và bình đẳng — đơn vị đếm ngân sách suy luận (khác <i>lượt</i> : bước nối tiếp trong pipeline)
$H / \kappa / D$	ba câu hỏi của khung đo (§3.1): <i>tiềm năng cải thiện</i> (pool có giá trị tiềm tàng nào không) / <i>khả năng khai thác</i> (bộ chọn nhất được không) / <i>thiệt hại</i> (giao thức phá bao nhiêu)
$W / I / E$	ba <i>nhân vật</i> của thí nghiệm tác động artifact: model yếu / model mạnh giải một mình / cùng model mạnh nhưng thấy bài của W
artifact	bài làm của model yếu — thứ được đưa (hoặc không) vào ngữ cảnh model mạnh
G, L, R	cơ hội cải thiện / thiệt hại / phần cứu được — ba số hạng của $\Delta_{\text{ceil}} = G - L + R$
Δ_{ceil}	(<i>ceiling</i>) trần lý tưởng trừ model mạnh; cần đáp án chuẩn nên <i>chỉ để sàng lọc</i>
Δ_{real}	(<i>real</i>) $\text{acc}(E) - \text{acc}(I)$ — đại lượng <i>triển khai được</i> thật
chênh; g^*	hiệu accuracy model mạnh – model yếu (thang 0–1); mức chênh nơi Δ_{ceil} đổi dấu ($\approx 0,09$)
$\text{maj}@k; \text{oracle}@k$	bỏ phiếu đa số trong k lần sinh; trần lý tưởng (đúng nếu ≥ 1 lượt đúng)
$\text{exec3} / \text{llm3}$	trên code: chọn ứng viên bằng <i>chạy test</i> / để LLM <i>tự duyệt</i>
$V_{\text{gain}}, A_{\text{gain}}$	accuracy thay đổi khi thêm vai trò V (hoặc A) vào cùng pipeline
điểm; KTC	điểm phần trăm (+14,0 điểm = +0,140); khoảng tin cậy 95%
fold; mức dao động nền	1 trong 5 phần bài rời nhau; biên dao động của phép đo lặp (tối 7 điểm/100 bài) — hiệu ứng tin được khi 5/5 fold cùng dấu và qua t-test
mức A / mức B	5 fold kèm t-test (hoặc thí nghiệm khoá tiêu chí trước) / đo một lần, chỉ minh hoạ cơ chế

Bảng 1: Bảng tra nhanh toàn bộ ký hiệu và thuật ngữ riêng của báo cáo.

2 Công trình liên quan

Sinh rồi chọn. Kỹ thuật Chain-of-thought [22] đã tạo tiền đề cho phương pháp self-consistency [21]. Trong đó, hệ thống sinh nhiều lời giải độc lập rồi xác định kết quả thông qua cơ chế bỏ phiếu đa số — chính là mốc $\text{maj}@k$ của khảo sát này (định nghĩa ở §4). Các hướng tiếp cận chọn bằng bộ kiểm sau đó mở rộng theo 2 nhánh chính: đánh giá theo tiến trình suy luận [13] và phân bổ thêm tài nguyên tính toán ở thời điểm suy luận [20]. Đặc trưng cốt lõi của phương pháp này là giai đoạn tổng hợp chỉ chọn trong tập các lời giải đã sinh, chứ không tạo thêm lời giải mới. Do đó, theo đẳng thức phân rã ở §3.2, hướng tiếp cận này không làm phát sinh nguy cơ phá hỏng các lời giải đúng vốn có.

Sinh rồi sửa. Các framework tiêu biểu như Self-Refine [14], Reflexion [19] và CRITIC [7] cho model đọc sản phẩm của chính nó hoặc model khác rồi thực hiện sửa. Tuy nhiên, Huang và cộng sự [11] đã chỉ ra rằng LLM chưa thể tự sửa được lỗi suy luận khi thiếu tín hiệu kiểm chứng khách quan từ bên ngoài, kết luận này nhất quán với kết quả của chúng tôi ở §5.10. Điểm quan trọng nhất đối với báo cáo này là *mốc so sánh*: theo rà soát của chúng tôi, phần lớn công trình này báo cáo cải thiện so với model *bị sửa* hoặc lượt nháp đầu, tức là so với model yếu chứ không so với việc dùng thẳng model sửa chạy một mình. Khảo sát này sẽ chỉ ra hai mốc này cho hai dấu ngược nhau trên cùng một hệ (§5.5, §6)

Đa tác tử và tranh biện. Tranh biện đa tác tử [6] và LLM-as-a-judge [24] là các cơ chế phối hợp phổ biến. Một tổng hợp hệ thống [15] đánh giá năm khung tranh biện trên chín benchmark kết luận rằng các khung này *không nhất quán vượt được* self-consistency hay thậm chí CoT, dù tốn nhiều compute hơn; ở Llama-3.1-8B trên GSM8K, tranh biện còn giảm khoảng 16 điểm so với CoT (80,13 $\rightarrow$ 63,87) — nhất quán với mẫu hình suy giảm ở model nhỏ mà chúng tôi quan sát độc lập (§5.4). Hai hệ gần nhất về kiến trúc và phương pháp là MAS_RPSV (một cấu hình Reader–Planner–Solver–Verifier nối tiếp, trong khảo sát của MASPRM [16] trên GSM8K/MATH) và SHARP [17]

Vị trí của khảo sát. Khác với các công trình trước đây, khảo sát này không mục đích đề xuất một kiến trúc đa tác tử mới. Thay vào đó, chúng tôi đề xuất một khung đo lường thực nghiệm bao gồm 3 phép kiểm soát, một đẳng thức phân rã và khung phân tích 3 thừa số nhằm trả lời câu hỏi khi nào thì một cơ chế phối hợp đa tác tử tạo ra giá trị thật sự

3 Phương pháp đo lường

Phần này xây dựng khung đo lường cho các cơ chế phối hợp giữa các model. Chúng tôi tách bài toán thành ba câu hỏi cốt lõi — *tiềm năng cải thiện*, *khả năng khai thác*, *thiệt hại*: pool lời giải có chứa giá trị mới hay không; một bộ chọn khả thi có khai thác được giá trị đó hay không; và giao thức có làm giảm kết quả ở những bài vốn đã giải đúng hay không. Từ đó, các thí nghiệm sau dùng nhất quán những đại lượng định lượng tương ứng.

3.1 Ba câu hỏi cốt lõi

Để biết một cơ chế phối hợp có thực sự tạo ra giá trị hay không, chúng tôi xem xét ba thành phần độc lập:

- **Tiềm năng cải thiện** (H) — phần giá trị *tiềm tàng trong pool*: pool các lời giải được sinh ra có chứa lời giải mà model mạnh khi hoạt động đơn lẻ không tìm được hay không? Nếu không, dù bộ chọn hoạt động hoàn hảo, cơ chế phối hợp cũng không thể cải thiện kết quả.
- **Khả năng khai thác** (κ) — chất lượng *bộ chọn*: nếu pool thực sự chứa một lời giải mới, một tín hiệu khả thi, không cần biết đáp án, có thể chọn đúng lời giải đó hay không?
- **Thiệt hại** (D): giao thức có làm hỏng những bài mà model mạnh vốn đã giải đúng hay không, và mức độ thiệt hại là bao nhiêu?

Vì vậy, một cơ chế chỉ tạo ra giá trị ròng khi đồng thời thỏa ba điều kiện: pool có lời giải mới, bộ chọn khai thác được lời giải đó, và thiệt hại do giao thức gây ra nhỏ hơn phần cải thiện thu được. Ba nhánh nghiên cứu của báo cáo lần lượt tương ứng với ba thành phần này.

Khung trên chỉ đóng vai trò tổ chức các câu hỏi thực nghiệm; nó không phải là một mô hình dự báo. Các đại lượng dùng để kiểm chứng từng thành phần được định nghĩa trong các tiểu mục tiếp theo.

3.2 Tiếp xúc với artifact: do tác động và nguồn gốc các kết quả

Để cô lập tác động khi một model mạnh nhìn thấy lời giải của model yếu, xét một cặp model gồm model yếu và model mạnh, chẳng hạn Qwen-1.5B và Qwen-7B. Ba ký hiệu dưới đây khác với các vai trò $P/S/V/A$ ở §4 để tránh nhầm lẫn:

- W — model yếu, tự giải bài; lời giải sinh ra được gọi là *artifact*.
- I — model mạnh, tự giải bài **độc lập** và không quan sát artifact của W .
- E — chính model mạnh đó, với cùng lệnh giải bài, nhưng được cung cấp thêm artifact của W trong ngữ cảnh đầu vào.

I và E dùng cùng một model cho cùng một nhiệm vụ; điểm khác biệt duy nhất là E nhìn thấy artifact của W . Do đó, hiệu $\text{acc}(E) - \text{acc}(I)$ đo trực tiếp tác động của việc tiếp xúc với lời giải của model yếu. Đại lượng này, ký hiệu Δ_{real} , có thể đo trong triển khai thực tế mà không cần biết đáp án.

Để xác định *tiềm năng cải thiện* của cơ chế tiếp xúc, ta xét một bộ chọn lý tưởng biết đáp án. Bộ chọn này trả lời đúng nếu W đúng hoặc E đúng, nên đạt mức chính xác

$$\text{acc}(\text{CEIL}) = P(W \text{ đúng} \vee E \text{ đúng}).$$

Gọi mức cải thiện tối đa so với model mạnh chạy độc lập là Δ_{ceil} . Khi đó:

$$\Delta_{\text{ceil}} = \text{acc}(\text{CEIL}) - \text{acc}(I) = G - L + R, \quad (1)$$

trong đó ba thành phần có ý nghĩa:

$G = P(W \text{ đúng} \wedge I \text{ sai})$	cơ hội cải thiện — tính chất của <i>cặp model</i> ,
$L = P(W \text{ sai} \wedge I \text{ đúng} \wedge E \text{ sai})$	thiệt hại — do <i>giao thức</i> gây ra,
$R = P(W \text{ sai} \wedge I \text{ sai} \wedge E \text{ đúng})$	phần cứu được — bài cả hai model ban đầu đều trượt.

Đẳng thức (1) là một hệ quả đại số trực tiếp:

$$P(W \vee E) - P(I) = P(W \wedge \neg I) - P(\neg W \wedge I \wedge \neg E) + P(\neg W \wedge \neg I \wedge E).$$

Đẳng thức này tách mức cải thiện tối đa thành ba nguồn: cơ hội do model yếu cung cấp, thiệt hại do tiếp xúc gây ra, và các trường hợp được cứu khi cả hai model ban đầu đều thất bại.

Ví dụ, trên 100 bài, giả sử có 15 bài W đúng nhưng I sai ($G = 0,15$), 20 bài W sai, I đúng nhưng E sai ($L = 0,20$), và 5 bài cả W lẫn I đều sai nhưng E đúng ($R = 0,05$). Khi đó

$$\Delta_{\text{ceil}} = 0,15 - 0,20 + 0,05 = 0,$$

nghĩa là ngay cả bộ chọn lý tưởng cũng không thể vượt model mạnh hoạt động đơn lẻ.

Vì là một cận lý tưởng, Δ_{ceil} cần đáp án chuẩn nên không thể triển khai trực tiếp. Nó đóng vai trò **sàng lọc**: nếu $\Delta_{\text{ceil}} < 0$, ngay cả bộ chọn biết đáp án cũng không thể cải thiện model mạnh; khi đó không cần tiếp tục tìm bộ chọn khả thi κ . Ngược lại, $\Delta_{\text{ceil}} \geq 0$ chỉ cho biết về mặt thông tin vẫn còn tiềm năng cải thiện, chứ không bảo đảm một bộ chọn thực tế khai thác được tiềm năng đó.

Đẳng thức (1) cũng là một phép kiểm tính nhất quán của sổ sách. Nó khớp dữ liệu ở tất cả các cặp có lưu vết: 4/4 cặp trong khối thăm dò và 15/15 cặp trong thí nghiệm chính, tổng cộng 19/19 cặp. Tuy nhiên, đây chỉ là kiểm tra đại số trên dữ liệu, không phải bằng chứng cho bất kỳ giả thuyết thực nghiệm nào.

Δ_{ceil} chỉ áp dụng cho lớp cơ chế *chọn giữa W và E sau khi artifact của W đã được đưa vào ngữ cảnh*. Các cơ chế quyết định *có nên cho model mạnh tiếp xúc với artifact hay không* thuộc một lớp bài toán khác, với cận riêng được phân tích ở §5.10.

3.3 Giao thức tuyển chọn, sửa chữa và chênh lệch năng lực

Từ phân rã trên, điểm khác biệt quan trọng giữa các giao thức là chúng có thể tạo lời giải mới hay chỉ chọn trong số lời giải sẵn có. Vì vậy, chúng tôi chia giao thức thành hai lớp theo tiêu chí vận hành: *đầu ra cuối có bắt buộc phải là một phần tử của pool đã sinh hay không*.

- **Tuyển chọn**: đầu ra cuối phải là một phần tử của pool, chẳng hạn bỏ phiếu đa số hoặc lựa chọn bằng test. Với lớp này, $L = 0$ theo cấu trúc: giao thức không thể tạo ra một lời giải mới sai trên một bài mà pool đã chứa lời giải đúng.
- **Sửa chữa**: giao thức cho phép sinh thêm chuỗi mới sau khi quan sát pool, chẳng hạn verifier can thiệp hoặc giao thức tiếp xúc. Với lớp này, L không còn bằng 0 theo cấu trúc và phải được đo thực nghiệm. Trong dữ liệu của chúng tôi, verifier 7B có L rất nhỏ nhưng vẫn khác 0 (1/300 bài, §5.4), trong khi giao thức tiếp xúc có L lớn hơn đáng kể (§5.9).

Ngoài loại giao thức, **chênh lệch năng lực** giữa hai model cũng là một biến quan trọng. *Chênh* là hiệu giữa độ chính xác greedy của model mạnh và model yếu trên cùng benchmark; độ chính xác được chuẩn hoá trên thang 0–1. Ví dụ, với cặp 1.5B→7B trên MBPP, chênh lệch này là 0,244.

Các thí nghiệm tiếp theo dùng chênh lệch năng lực làm biến giải thích chính. Ký hiệu g^* chỉ mức chênh mà tại đó đường khớp của Δ_{ceil} đổi dấu (§5.7). Nhờ vậy, ta không chỉ khảo sát một cơ chế phối hợp có hiệu quả hay không, mà còn xác định *điều kiện về khoảng cách năng lực giữa các model để cơ chế đó còn tiềm năng tạo giá trị*.

4 Thiết lập thí nghiệm và quy trình

[TD: rà toàn bộ mục này]

Model. Qwen2.5-Instruct 1.5B/7B/14B/32B [23]; Llama-3.1-8B-Instruct [8]; DeepSeek-Coder-6.7B-Instruct [9]. Sáu model tạo thành 15 cặp có hướng trong thí nghiệm §5.7; các khối còn lại dùng Qwen 1.5B/7B/14B. Các lần chạy trải trên hai hệ phần cứng và hai mức độ chính xác số (4-bit và 16-bit); riêng chênh lệch do mức độ chính xác đã tới 3 điểm — cùng cỡ ngưỡng ý nghĩa hiệu dụng (xem Thống kê). Vì vậy so sánh chéo phần cứng chỉ đọc theo *dấu*; mọi so sánh định lượng đều nằm trong cùng một tổ hợp phần cứng, độ chính xác số và bộ bài.

Benchmark. GSM8K [5] (1319 bài); MATH-500 [10] (500 bài); MBPP [1] (499 bài ở dải chính; 464 bài ở dải giữ lại, dùng để kiểm chuyển miền); HumanEval [3] (164 bài). Với §5.10, điểm mấu chốt là MBPP/HumanEval có cách kiểm *chắc chắn*: lời giải qua test là bằng chứng trực tiếp. MATH và GSM8K không có tín hiệu này.

Vai trò và pipeline. Bốn vai trò gồm P (planner — lập dàn ý), S (solver — giải), V (verifier — kiểm và được phép sửa), A (aggregator — nhận nhiều ứng viên, chọn đáp án cuối). Các tổ hợp viết liền; chẳng hạn, $PSVA$ là pipeline đủ bốn vai trò. Những chữ này chỉ *vai trò trong pipeline*; $W/I/E$ và $G/L/R$ ở §3.2 là bộ ký hiệu riêng của thí nghiệm tác động artifact.

Bộ tổng hợp và các mốc. Một *lần sinh* là một lần model sinh trọn vẹn một lời giải cho bài toán; đây là đơn vị đếm ngân sách suy luận của báo cáo. k lần sinh cho cùng một bài là *độc lập và bình đẳng* — không lần nào đứng trước hay phụ thuộc lần nào — khác với các *lượt* nối tiếp trong pipeline (lượt kiểm, lượt thứ hai). Với k lần sinh: $maj@k$ lấy đáp án xuất hiện nhiều nhất (bỏ phiếu đa số); $oracle@k$ đúng nếu *ít nhất một* lượt đúng (trần lý tưởng của mọi cách chọn trong pool, cần đáp án chuẩn, chỉ dùng làm trần); $llm_agg@k$ là một lượt LLM đọc cả k ứng viên rồi chọn hoặc tổng hợp. Ví dụ: 5 lượt cho đáp án $\{7, 7, 7, 12, 15\}$, trong khi đáp án chuẩn là 12. $maj@5$ chọn 7 (sai), còn $oracle@5$ đúng vì có một lượt ra 12. Trên code, `execck` chạy test với từng ứng viên và lấy ứng viên qua test (tín hiệu chắc chắn); `llmk` để LLM tự duyệt thay vì chạy test (tín hiệu học được).

Đại lượng dẫn xuất. V_gain là độ chính xác của pipeline có V trừ pipeline cùng cấu hình bỏ V ; A_gain được định nghĩa tương tự cho A . AUC (diện tích dưới đường ROC) đo khả năng của bộ phân loại trong việc tách lời giải đúng khỏi lời giải sai; 0,5 là đoán ngẫu nhiên, 1,0 là hoàn hảo.

Quy ước đơn vị. Độ chính xác được viết trên thang 0–1; hiệu ứng viết bằng “điểm” (điểm phần trăm: +14,0 điểm = +0,140). “Chênh” cũng là hiệu accuracy trên thang 0–1 (chênh 0,09 $\approx$ 9 điểm). Chi phí có ba thang không thể thay thế cho nhau: *ký tự sinh* (đo thô), *token*, và *FLOP* (tham số $\times$ token). Chỉ thang FLOP so được giữa hai cỡ model; tỷ số chi phí luôn kèm dấu $\times$ (ví dụ 0,88 $\times$) để không lẫn với accuracy.

Giải mã. Khối luồng thông tin dùng greedy (`do_sample=False`), nên cùng cấu hình luôn cho cùng kết quả. Dao động giữa các fold vì vậy hoàn toàn do *khác bài*, không phải do nhiễu lấy mẫu.

Thống kê. Khối vai trò/chi phí chia 5 fold rời nhau (mỗi fold 60–100 bài). Để ước lượng *mức dao động nền* của phép đo, chúng tôi chạy cùng một cấu hình trên cả 5 fold: V_gain dao động từ +1,0 đến +8,0 điểm, với độ lệch chuẩn giữa fold là 2,65 điểm. Vì thế, một phép đo đơn lẻ trên 100 bài gần như không mang thông tin. Suy diễn bằng t-test trên fold ($SE = s/\sqrt{k}$; $t_{0,975}(4) = 2,776$, tức ngưỡng hiệu dụng $\sim 3,3$ điểm), khoảng tin cậy 95% (KTC), và phép thử dấu (5/5 fold cùng dấu $\Rightarrow p = 0,031$ một phía). Khối luồng thông tin dùng McNemar chính xác ghép cặp trên cùng bộ bài và bootstrap ghép cặp (10 000 lần). Với 131 phép thử toàn dự án, kỳ vọng $\sim 6,6$ dương tính giả [2]; các ca $p \in [0,02; 0,05]$ đọc đề đặt tương ứng.

Nhãn tin cậy. *Mức A* là kết quả đo trên 5 fold kèm t-test, hoặc thí nghiệm khoá trước tiêu chí diễn giải và đặt mọi điều kiện kỹ thuật đã đặt ra; *mức B* là đo một lần hoặc phân tầng hậu nghiệm, chỉ dùng để minh hoạ cơ chế. Các điều kiện kỹ thuật kiểm những thứ thống kê không thấy được — chẳng hạn adapter huấn

luyện rò sang nhánh đối chứng, hay bộ chấm đáp án lệch giữa hai nhánh; 16 trên 32 lần chạy trượt điều kiện và bị loại trước khi đọc kết quả.

Rà lại giữa kỳ. Rà 131 đại lượng theo chuẩn thống kê thống nhất: bốn kết quả chủ lực của khối fold (+14,0, +11,0, +5,6, +4,4 — xem §5) giữ ý nghĩa ($t = 3,3-6,9$), kết quả +7,7 của khối McNemar cũng giữ ($p = 0,0075$); 6 kết quả được phục hồi sau khi đối chiếu cờ hợp lệ; 1 mất ý nghĩa (chỉ có $k=3$ fold); 2 ca treo được phán dứt điểm bằng dữ liệu fold đã lưu, không phải chạy lại.

5 Kết quả

Phần này trình bày kết quả theo hai mạch phân tích. **Mạch thứ nhất** (từ §5.1 đến 5.6) phân tích tác động tuần tự của ba phép kiểm soát lên hiệu quả hợp tác giữa các tác nhân. **Mạch thứ hai** (từ §5.7 đến 5.11) xác định giá trị còn lại thông qua ba thừa số G , L và κ , và kết thúc bằng thảo luận về huấn luyện. Trừ khi ghi chú khác, các số liệu đều ở mức tin cậy A (§4); phạm vi đo của từng phép được ghi ngay tại bảng tương ứng. Bảng tra cứu ký hiệu ở Bảng 1.

5.1 Lợi ích của pipeline và mức dao động nền của phép đo

Task	Solver 1 lượt	Pipeline PSVA	Chênh lệch	Hệ số token sinh
GSM8K	0,632	0,744	+11,2	2,9×
MATH	0,405	0,345	−6,0	6,63×

Bảng 2: So sánh pipeline đầy đủ bốn vai trò với một lần sinh duy nhất (Qwen-1.5B; đo một lần trên toàn bộ tập). Hai cột giữa là độ chính xác, thang 0–1; cột *Chênh lệch* tính bằng điểm phần trăm.

Bảng 2 cho thấy kết quả trước khi áp dụng bất kỳ biện pháp kiểm soát nào. Trên GSM8K, pipeline hơn 11,2 điểm, trong khi trên MATH, nó tiêu tốn gấp 6,63 lần chi phí sinh token nhưng lại kém hơn 6 điểm. Cần lưu ý hai điểm quan trọng. *Thứ nhất*, kiểm định thống kê dựa trên một đại lượng gần tương tự nhưng không hoàn toàn trùng khớp: qua 5 fold, hiệu số $PSVA - PS = +5,6$ điểm (KTC [+3,3; +7,9]; $t = 6,89$) — lợi ích trên GSM8K là có ý nghĩa thống kê. *Thứ hai*, phép hiệu chuẩn mức dao động nền (§4) cho thấy hai phép đo trên 100 bài có thể chênh nhau tới 7 điểm; vì vậy, các hiệu ứng từ phép đo đơn lẻ chỉ được đọc như tín hiệu thăm dò.

Mục tiếp theo áp dụng phép kiểm soát thứ nhất: lợi ích này đến từ sự phối hợp giữa các vai trò hay chỉ đơn thuần là do số lượng lần sinh tăng lên?


5.2 Giá trị nằm ở nhiều lần sinh độc lập hơn là ở cơ chế phối hợp

Bộ tổng hợp (cùng 8 lần sinh)	MATH 1.5B	MATH 7B
greedy	0,50	0,72
maj@8	0,60	0,73
llm_agg@8	0,41	0,47
oracle@8	0,73	0,85

Bảng 3: So sánh các bộ tổng hợp với cùng ngân sách 8 lần sinh (hàng trên cùng là mốc 1 lượt để tham chiếu). Các ô là độ chính xác, thang 0–1.

Bảng 3 cố định ngân sách và chỉ thay đổi *phương thức tổng hợp*. Từ đó rút ra bốn kết luận.

Thứ nhất, bộ tổng hợp dùng LLM - llm_agg@8 kém hơn bộ phiếu đa số - maj@8 từ 19 đến 26 điểm ở cùng chi phí; ở model 7B, nó thậm chí còn kém cả greedy một lượt. Nó làm hỏng 21 câu trả lời đúng (với 1.5B) và 26 câu (với 7B), trong khi chỉ sửa được 2 và 0 câu sai. Phân tích 600 trace cho thấy 65% số



Hình 2: Sơ đồ pipeline bốn vai trò, 16 tổ hợp bật/tắt để tính giá trị Shapley, và quy trình ước lượng nhiễu qua 5 fold.

lần nó sao chép nguyên văn ứng viên *cuối cùng* — gần như một quy tắc dựa trên vị trí hơn là một bộ chọn dựa trên nội dung; 100% lượt không sinh ra đáp án mới.

Thứ hai, lợi ích của bộ phiếu đa số giảm khi năng lực model nền tăng. Ở model 1.5B, maj@8 cải thiện 10 điểm phần trăm, chiếm 43% mức cải thiện tối đa lý thuyết 23 điểm phần trăm. Ở model 7B, mức cải thiện chỉ còn 1 điểm phần trăm, tương ứng 8% trên mức tối đa 13 điểm phần trăm. Khoảng cách $\text{oracle@8} - \text{maj@8}$ (13 và 12 điểm phần trăm) sẽ được dùng lại ở §5.10 như chặn trên cho mọi bộ chọn.

Thứ ba, một đối chứng tách được ảnh hưởng của “phối hợp” khỏi ảnh hưởng của “thêm lần sinh”. Khi cho giải lại mà *không* xem phê bình của verifier, kết quả bằng đúng giải lại *có* xem phê bình ($\text{rerun} = \text{loop}$, cùng cho 0,453). Lợi ích vì vậy đến từ lần sinh thêm, không từ nội dung phản hồi. (Một phép đo đơn lẻ trước đó cho +20 điểm nhưng không tái lập: trên 5 fold chỉ còn +4,0 điểm.) Nhất quán với điều đó, biến thể vòng lặp giải-rời-chấm — rẻ hơn pipeline đủ vai trò — còn thắng nó trên MATH: +4,0 điểm (KTC [+0,5; +7,5]; $t = 3,21$) ở cùng chi phí.

Thứ tư, phần “gây hại” của aggregator phần lớn là hiện vật đo lường. Chỉ 73–81% lượt tổng hợp phát ra đáp án trong khung để chấm được; thêm một cơ chế dự phòng miễn phí (thiếu khung thì lấy đáp án của verifier, không gọi thêm model) đưa A_{gain} trên MATH 1.5B từ −6,4 điểm lên +0,8 điểm. Một lần chạy khác (bộ bài khác, không lượng tử hoá) cho +8,0 điểm; sau khi vá lỗi định dạng, hai ước lượng cùng phía không âm, phần chênh còn lại quy cho khác bộ bài và khác độ chính xác số. (mức B)

Sau phép kiểm soát chi phí, yếu tố chắc chắn có giá trị duy nhất là “các lần sinh độc lập bổ sung”. Mục tiếp theo đặt câu hỏi: những lần sinh đó nên do vai trò nào và model cỡ nào đảm nhiệm?

5.3 Phân rã đóng góp theo vai trò bằng giá trị Shapley

Trước khi phân tích hành vi chi tiết, chúng tôi đo lường đóng góp của từng vai trò bằng giá trị Shapley [18]: chạy đủ $2^4 = 16$ tổ hợp bật/tắt bốn vai trò (xem Hình 2); đóng góp φ_i của một vai trò là trung bình mức thay đổi độ chính xác khi thêm nó vào mọi tổ hợp con — đây là cách phân bổ duy nhất thỏa mãn các tiên đề về hiệu quả, đối xứng và cộng tính.

Bảng 4 cho thấy ba điểm chính. *Thứ nhất*, Solver và Verifier chiếm phần lớn giá trị; Planner ở 1.5B có đóng góp âm trên GSM8K — rõ nhất ở cặp tổ hợp: $SA = 0,682 \rightarrow PSA = 0,562$, việc thêm planner làm giảm 12 điểm. *Thứ hai*, đóng góp thay đổi theo năng lực: khi nâng riêng planner lên 7B, φ_P chuyển từ −0,023 lên +0,055 (chênh +0,078; KTC [+0,049; +0,109]) — planner âm là hệ quả của model yếu,

Vai trò	GSM8K 1.5B ($N = 1319$)	MATH-500 1.5B ($N = 500$)
Solver	+0,252 [+0,242; +0,263]	+0,145 [+0,128; +0,161]
Verifier	+0,252 (đối xứng cấu trúc với Solver)	+0,145 (đối xứng)
Aggregator	+0,190 [+0,182; +0,199]	+0,150 [+0,134; +0,167]
Planner	-0,014 [-0,030; +0,002]	+0,017 [-0,008; +0,043]

Bảng 4: Giá trị Shapley của bốn vai trò, mọi vai trò đều 1.5B. Các giá trị φ ở thang 0–1 (phần độ chính xác quy cho vai trò đó). KTC 95% bootstrap theo câu hỏi — *không có fold*, nên đọc kèm mức dao động nền ở §4; trên MATH mọi chênh lệch giữa các vai trò đều dưới mức dao động nền nên thứ hạng không có ý nghĩa.

không phải bản chất vai trò. Nâng riêng verifier lên 7B đẩy φ_V từ +0,269 lên +0,462 — verifier là vai trò nhạy cảm nhất với năng lực, báo trước cho §5.4. *Thứ ba*, chỉ số tương tác Shapley cho thấy S , V , A thay thế lẫn nhau mạnh ($I \approx -0,21$ đến $-0,27$ ở cả hai task): ba vai trò này đang thực hiện các phiên bản của cùng một nhiệm vụ, chứ không bổ sung cho nhau.

Một giới hạn quan trọng của phép đo này: Shapley phân bổ giá trị cho *nhân vai trò*, không cho *chức năng* — nếu planner lên giải bài, công của nó vẫn được ghi cho nhân “Planner” dù hành vi thực tế là của solver. Mục tiếp theo phân tích trace để trả lời liệu các vai trò có thực sự làm đúng chức năng của mình hay không.

5.4 Khoảng cách giữa vai trò được gán và vai trò thực thi

Bảng 5 tổng hợp hành vi từ trace, cho thấy sự chuyên biệt hoá vai trò phần lớn chỉ là hình thức ở model nhỏ: planner — mặc dù bị cấm tính đáp án — vẫn chứa đáp án đúng trong 34,7% câu MATH (45,3% trường hợp còn đưa ra cả khung đáp án); khi có plan, solver chỉ sao chép (độ dài trung vị lời giải là 19 ký tự, so với 664 khi không có plan). Ở model 7B, các hiện tượng này gần như biến mất — nhưng ở mức năng lực đó, pipeline lại thua solver đơn lẻ. Trên 2.000 lượt ở cả bốn ô, aggregator chỉ 3 lần đưa ra một đáp án mới và đúng: vai trò tổng hợp không thực hiện tính toán ở mọi mức năng lực.

Chỉ số hành vi (trace)	GSM8K 1.5B	MATH 1.5B	GSM8K 7B	MATH 7B
Planner rò rỉ đáp án đúng	14,0%	34,7%	1,0%	4,0%
Solver không sinh số mới	60,7%	62,0%	1,0%	11,0%
Độ dài lời giải solver	19	344	821	1247
Verifier can thiệp	32,7%	38,0%	4,0%	14,0%
Aggregator lặp lại đáp án của verifier	93,3%	73,3%	100%	97,0%

Bảng 5: Hành vi theo từng ô (task $\times$ năng lực, với $n = 100 - 150$ mỗi ô, đo trên trace).

Hai bằng chứng nhân quả hỗ trợ cho bảng này. *Thứ nhất*: chỉ cần bỏ dòng cấm “Do NOT compute the final answer” khỏi prompt của planner, solver hạ nguồn *tăng* +3,8 điểm trên MATH và +3,3 trên GSM8K — hướng dẫn chỉ che giấu đáp án chứ không ngăn planner tính toán, và việc che giấu này lại gây hại. *Thứ hai*, khi hoán vị prompt giữa các vị trí, độ chính xác không phân biệt được: trên GSM8K $0,660 = 0,660$ (cấu hình `solo` đạt 0,673); trên MATH `swap - normal` = +5,3 điểm nhưng $t = 1,84$, KTC $[-2,7; +13,4]$ — không đạt ý nghĩa thống kê. Mặc dù KTC rộng không cho phép loại trừ hoàn toàn hiệu ứng cỡ vừa, chúng tôi chỉ ghi nhận rằng không có bằng chứng cho thấy “danh tính vai trò” ảnh hưởng đến kết quả.

Vai trò kiểm cũng không thực sự kiểm soát. Ba phép đo độc lập: (i) Khi can thiệp, verifier 1.5B đúng chỉ 56–59% số lần — gần như ngẫu nhiên; verifier 7B đúng 98%. (ii) Thí nghiệm tiêm lỗi — sửa kết quả một bước tính trong chuỗi lời giải vàng rồi hỏi model “có lỗi tính toán không” — cho thấy 1.5B trả lời “không có lỗi” gần 100% số bài, tức mù với lỗi đã tiêm; 7B vượt qua cổng hiệu lực và phân biệt được bài sạch với bài đã bị sửa (+0,651 trên tầng bài nó tự giải được; tầng nó *không* tự giải được chỉ có $n = 9$ nên câu hỏi “kiểm có tách khỏi giải không” còn bỏ ngõ). (iii) Lưới V_{gain} (Bảng 6) cho thấy lượt kiểm chỉ sinh lợi trong một dải hẹp.

V_gain (điểm; min-max theo fold)	GSM8K	MATH
1.5B	+4,4 [+1; +8], 5/5 dương	+1,4 [-1; +4]
7B	+1,0 [-3; +5]	+4,4 [+2; +8], 5/5 dương

Bảng 6: V_gain theo task $\times$ năng lực (5 fold mỗi ô). Xếp bốn ô theo độ chính xác của solver — 0,402 (ngộp); 0,598 (có lợi); 0,668 (có lợi); 0,884 (bảo hoà) — lượt kiểm chỉ sinh lợi trong dải solver-accuracy $\approx$ 0,60–0,67: dưới dải thì ngộp, trên dải thì hết lỗi để sửa.

Yếu tố tác động rõ ràng nhất là năng lực của model ở lượt kiểm tra. Cùng trên 300 bài MATH (5 fold $\times$ 60), Bảng 7 cho thấy:

Lượt kiểm	Hiệu ứng (điểm)	KTC 95% (điểm)	Sửa : Phá
Verifier 7B (solver 1.5B)	+14,0	[+7,4; +20,6]	43 : 1
Verifier 1.5B (cùng cỡ)	+3,0	KTC chứa 0	15 : 6
Phần riêng do cỡ model lớn hơn	+11,0	[+3,9; +18,1]	—

Bảng 7: Tác động bất đối xứng năng lực ở lượt kiểm trên MATH. “Sửa : Phá” = số bài sai được sửa thành đúng so với số bài đúng bị phá thành sai; verifier cùng cỡ phá 6 bài, trong khi verifier 7B chỉ phá 1 bài trên cùng 300 bài.

Cơ chế từ trace: khi verifier can thiệp, nó tái sử dụng số liệu trung gian của solver với tỷ lệ thấp hơn khoảng 5 lần so với khi đồng ý (0,20–0,23 so với 0,96). Vì vậy, hành vi can thiệp gần với giải lại hơn là kiểm tra từng bước; về tác động, lượt kiểm tương đương với một lần sinh bổ sung. Điều này phù hợp với giả thuyết rằng +14,0 điểm chủ yếu đến từ việc thêm một lần sinh của model mạnh hơn. Sự nhất quán cũng thể hiện ở chỗ: V_gain có ý nghĩa trên MATH 7B (+4,4 điểm; KTC [+1,5; +7,3]) nhưng không có ý nghĩa trên MATH 1.5B (+1,4; $p = 0,235$). Lưu ý cho §3.3: verifier *sinh ra chuỗi mới*, nên thuộc lớp sửa chữa — L của nó đo được là $1/300 \approx 0,003$, rất nhỏ nhưng không phải bằng 0 về cấu trúc.

Con số +14,0 đang so với model yếu. Mục tiếp theo áp dụng phép kiểm soát thứ hai và thứ nhất đồng thời: so sánh với mốc model mạnh và xét đến chi phí token.

5.5 Model mạnh đơn lẻ vẫn là mốc chuẩn về hiệu quả và chi phí

Cấu hình	GSM8K	MATH	Token 7B (GSM8K)	Token 7B (MATH)
S1.5B + V7B	0,810	0,563	105k	119k
S7B đơn lẻ	0,910	0,593	120k	152k
S7B + V7B	0,900	0,670	205k	261k

Bảng 8: So sánh với mốc model mạnh: các cấu hình có lượt kiểm so với model mạnh chạy đơn lẻ (5 fold). Cột token chỉ tính token do model 7B sinh — không thể so sánh trực tiếp giữa các cấu hình có cỡ model khác nhau; hiệu chỉnh được trình bày ở Bảng 9. Hai cột giữa là độ chính xác (thang 0–1), hai cột cuối là số token (nghìn).

Bảng 8 thay đổi mốc so sánh từ “model yếu” sang “model mạnh đơn lẻ”, và bức tranh thay đổi. Cấu hình bất đối xứng S1.5B+V7B — chính là cấu hình cho +14,0 điểm ở Bảng 7 — *kém hơn* S7B đơn lẻ 10 điểm trên GSM8K và chỉ ngang bằng trên MATH. Cột chi phí cần hai hiệu chỉnh: (a) cột token gốc bỏ qua token của solver 1.5B; (b) token 7B đắt hơn token 1.5B khoảng 4,7–4,9 lần theo FLOP. Bảng 9 hiệu chỉnh về thang FLOP:

Kết luận: trên GSM8K, cấu hình bất đối xứng bị chi phối hoàn toàn (kém 10 điểm, chi phí FLOP tương đương); trên MATH, nó tiết kiệm biên 4–8% với độ chính xác tương đương. Model mạnh đơn lẻ nằm trên đường Pareto ở cả hai task.

Tỷ số chi phí (bất đối xứng / S7B)	Token thô 7B	Trọng số FLOP
GSM8K	$0,88 \times$ (“rẻ hơn 12%”)	1,00–1,05 ×
MATH	$0,78 \times$ (“rẻ hơn 22%”)	0,92–0,96 ×

Bảng 9: Hiệu chỉnh đơn giá token (độ nhảy ký tự/token quét 3,0–4,0). Chưa tính phần prefill — model 7B phải *đọc* bài làm của 1.5B — nên hiệu chỉnh vẫn thiên vị cho cấu hình bất đối xứng.

Điểm sáng duy nhất có ý nghĩa thống kê trong Bảng 8 lại nằm ở cấu hình cùng cỡ: thêm V7B vào S7B trên MATH cho +7,7 điểm ($p = 0,0075$; McNemar), với chi phí $1,7 \times$ token. Theo ký hiệu ở §3.2, đây là trường hợp $\text{acc}(E) > \text{acc}(I)$ — và đáng chú ý, nó xảy ra ở *chênh lệch bằng 0*. Cùng cấu hình trên GSM8K lại cho $1,7 \times$ chi phí để mất 1 điểm — lợi ích của lượt kiểm cùng cỡ phụ thuộc vào task. Chúng tôi sẽ quay lại điểm dữ liệu này ở §5.7, nơi nó là điểm duy nhất ủng hộ cho nửa dương của quy luật chênh lệch.

Vì cùng một cặp model trên cùng một họ bài xuất hiện với nhiều giá trị khác nhau trong báo cáo, Bảng 10 đối chiếu để tránh nhầm lẫn:

Con số	Đại lượng	Mốc so sánh	Thiết lập	Mục
+14,0 điểm	hiệu ứng lượt kiểm	model yếu (PS)	prompt kiểm, 300 bài	§5.4
−3,0 điểm	độ chính xác cấu hình	model mạnh (S7B)	như trên, 5 fold	§5.5
−12,4 điểm	$\Delta_{\text{real}} = \text{acc}(E) - \text{acc}(I)$	model mạnh	prompt <i>giải</i> , kèm artifact, $n = 500$	§5.9
−16,6 điểm	Δ_{ceil} (trần lý tưởng)	model mạnh	prompt sửa, bootstrap	§5.8

Bảng 10: Cùng cặp 1.5B→7B trên miền toán, bốn đại lượng khác nhau. Sự khác dấu giữa dòng đầu và ba dòng sau phản ánh chính hiện tượng trung tâm: thay đổi mốc so sánh sẽ thay đổi dấu của hiệu ứng.

Còn một phép kiểm soát chưa áp dụng: mẫu số. Mọi con số trên đều là trung bình toàn tập — bao gồm cả những câu mà không có cơ chế nào cứu được.

5.6 Phân tầng theo phạm vi tác động của bộ tổng hợp

Số lượt đúng /5	n	Solver	maj@5	Δ (điểm)
0/5 — quá khó	48 (32%)	0,000	0,000	0
1/5	20 (13%)	0,000	0,000	0
2/5	15	0,333	0,600	+26,7
3/5	12	0,583	1,000	+41,7
4/5	18	0,722	1,000	+27,8
5/5 — quá dễ	37 (25%)	1,000	1,000	0

Bảng 11: Phân tầng theo số lần đúng trong 5 lần sinh (MATH 1.5B, $n = 150$). Cột Δ là chênh lệch độ chính xác giữa maj@5 và Solver.

Bảng 11 phân 150 bài theo “pool chứa bao nhiêu lời giải đúng”. Hai con số bất động cần phân biệt: theo cấu trúc pool, 57% số câu (0/5 và 5/5) không thể có hiệu ứng với bất kỳ bộ tổng hợp nào — không có gì để chọn hoặc không có gì để cải thiện; đối với bộ phiếu đa số nói riêng, thêm tầng 1/5 (một phiếu không thắng nổi đa số) đưa tổng lên 70%. Trên tầng khả tác động, hiệu ứng của bộ phiếu là +21,5 điểm (các tầng 1–4/5) hay +31,1 điểm (tầng 2–4/5); trung bình toàn tập pha loãng còn +9,3 — tỷ lệ pha loãng 2,3–3,3 lần tùy cách nhóm (tầng được xác định hậu nghiệm bằng chính kết quả sinh, nên đây là công cụ diễn giải, không phải mốc triển khai được). Một can thiệp +10 điểm thật chỉ tác động được tầng 2–4/5 (30% số bài) sẽ hiện ra +3,0 điểm toàn tập — dưới mức dao động nền.

Ba phép kiểm soát vậy là ngược chiều nhau: thiếu mẫu số $\Rightarrow$ đánh giá thấp; thiếu chi phí hoặc mốc $\Rightarrow$ đánh giá cao. Hạn chế tự khai: các hiệu ứng chủ lực ở §5.4–5.5 chưa được phân tầng lại theo cách này (thiếu dữ liệu theo-bài cho từng tầng); con số toàn tập của chúng vì vậy là ước lượng thấp của hiệu ứng trên tầng khả tác động.

Hết mạch thứ nhất. Bức tranh sau ba phép kiểm soát: giá trị dương chắc chắn duy nhất là lần sinh thêm; cấu hình sửa-bài-của-nhau thua model mạnh đơn lẻ. Hồi II xác định giá trị mất đi đâu và có quy luật nào đoán trước được hay không.

5.7 Chênh lệch năng lực thu hẹp cơ hội cải thiện

Quan sát thô trên 7 cặp model gộp nhiều lần chạy cho thấy: các cặp khác họ có cơ hội G cao hơn khoảng 24% (0,0597 so với 0,0481), nhưng các cặp khác họ cũng có chênh lệch năng lực nhỏ hơn (0,130 so với 0,167); hai biến này bị trộn hoàn toàn. Thiết kế tách biệt (tiền đăng ký) sử dụng 6 model, 15 cặp có hướng, trên cùng 499 bài MBPP, hồi quy

$$\begin{aligned} G &= \beta_0 + \beta_1 \cdot \text{chênh} + \beta_2 \cdot \text{khác_họ} \\ \beta_1 &= -0,1922 \ (p \approx 0) \\ \beta_2 &= +0,0045 \ (\text{KTC } [-0,0051; +0,0140]; \ p = 0,31). \end{aligned}$$

R^2 chỉ với chênh lệch là 0,824. KTC của β_2 nằm trọn dưới ngưỡng tương đương +0,02 đã khoá trước, cho thấy một kết quả null có thông tin: khác họ là tương quan giả; biến giải thích chính là chênh lệch năng lực. Dấu của β_1 đáng chú ý: chênh lệch càng lớn, cơ hội G càng nhỏ — model yếu càng đuối thì càng hiếm bài nó cứu được model mạnh. (Kết quả đa dạng pool — 3 model cho 2,70/3 ứng viên phân biệt so với 1,91/3 khi cùng model — chỉ được ghi là khác model; đối chứng khác-model-cùng-họ chưa chạy.)

Thêm nhánh sửa cho cả 15 cặp (tiền đăng ký) cho quy luật của trần:

$$\Delta_{\text{ceil}} = +0,0218 - 0,2392 \times \text{chênh}; \quad R^2 = 0,60; \ p = 10^{-5}; \ g^* \approx 0,09, \quad (2)$$

trong đó $g^* = \beta_0/|\beta_1|$ là mức chênh nơi đường khớp cắt 0 (tức ≈ 9 điểm accuracy; chúng tôi chưa ước lượng KTC cho g^* nên nó là mô tả xu hướng, chưa phải quy tắc vận hành). Đăng thức (1) khớp 15/15 cặp. Đọc kèm bắt buộc: 0/15 cặp dương có ý nghĩa, 3/15 âm có ý nghĩa — trên MBPP quy luật chỉ phát biểu được chiều phủ định (chênh vượt $\sim 0,09$ thì giao thức sửa cho hiệu ứng âm); xác lập vùng dương cần cỡ 8 lần dữ liệu MBPP. Hai điểm dữ liệu ngoài MBPP soi vào nửa dương: cặp 7B→14B trên MATH (chênh 0,044 $< g^*$) đo được $-1,4$ điểm, KTC chứa cả hai phía, nên không ủng hộ; cấu hình cùng cỡ (chênh = 0) trên MATH đo được $+7,7$ điểm có ý nghĩa (§5.5), ủng hộ. Nửa dương vì vậy dừng ở mức ”một điểm thuận, một điểm không kết luận”. Chênh giải thích 82% phương sai của G nhưng chỉ 35% của L ; phần lớn biến thiên của thiệt hại đến từ yếu tố khác chưa định danh (đưa vào Hạn chế). (Ghi chú cơ chế^(mức B): ngưỡng bảo toàn mà lượt sửa phải vượt tăng theo chênh nhanh gấp đôi khả năng bảo toàn thực của nó — hệ số 2,18 so với 1,10; $p = 0,0066$ — gợi ý hiệu ứng âm phát sinh từ cấu trúc ngân sách $G-L$, không từ suy giảm năng lực nội tại của model mạnh.)

5.8 Kiểm tra khả năng chuyển miền của quy luật chênh lệch năng lực

Chúng tôi sử dụng đường khớp (2) ước lượng trên MBPP để dự báo Δ_{ceil} trên MATH (tiền đăng ký; 3 cặp Qwen; KTC bootstrap ghép cặp 10 000 lần). Kết quả được trình bày trong Bảng 12.

Cặp	Chênh	Δ_{ceil} đo được	KTC 95%	Dự báo từ MBPP	Kết luận
7B→14B	0,044	-0,0140	$[-0,046; +0,018]$	+0,0108	nằm trong khoảng
1.5B→7B	0,244	-0,1660	$[-0,208; -0,124]$	-0,0361	ngoài khoảng
1.5B→14B	0,288	-0,0680	$[-0,102; -0,034]$	-0,0471	nằm trong khoảng

Bảng 12: Kiểm tra khả năng chuyển miền của quy luật chênh lệch (thang 0–1). Cột Δ_{ceil} đo được và dự báo có đơn vị điểm chính xác.

Hai trong ba dự báo nằm trong khoảng tin cậy 95%, do đó quy luật không bị bác bỏ. Tuy nhiên, khoảng tin cậy khá rộng (0,064–0,084) nên phép kiểm có độ phân giải thấp. Hơn nữa, thứ tự ba điểm không đơn điệu (chênh 0,244 cho hiệu ứng âm sâu hơn chênh 0,288), vì vậy tính đơn điệu của quy luật chưa được xác

nhận trên miền toán. Cặp $1.5B \rightarrow 7B$ nằm ngoài một cách hệ thống, với $L = 0,208$, gấp khoảng 11 lần G . Hiện tượng này tái lập trong một phép đo độc lập trên cùng cặp $(-0,1380 \rightarrow -0,1660)$. Như vậy, quy luật chỉ mô tả xu hướng chung; ngoại lệ xuất hiện khi model yếu quá kém so với độ khó của bài toán.

5.9 Nội dung artifact quyết định tác động của việc tiếp xúc

Đây là thí nghiệm chính của khảo sát (tiền đăng ký; chọn MATH-500 để đổi miền so với quan sát thăm dò gốc trên MBPP). Thiết kế được mô tả trong Hình 1: hai nhánh I và E dùng cùng một lệnh giải, chỉ khác nhau ở việc ngữ cảnh có kèm artifact của W hay không. Kết quả được phân tầng theo nội dung artifact và trình bày trong Bảng 13.

Tầng	MBPP 11–510 (mức B)	MBPP 511–974 (mức B)	MATH-500 (mức A)
artifact sai	−19,0	−19,3	−27,2 ($p \approx 0$; $n = 261$)
artifact đúng	+6,4	+2,5	+3,8 ($p = 0,012$; $n = 239$)

Bảng 13: Hiệu ứng tiếp xúc $\text{acc}(E) - \text{acc}(I)$ (đơn vị: điểm phần trăm), phân tầng theo nội dung artifact. Hai cột MBPP là phân tầng hậu nghiệm (mức B); cột MATH là thí nghiệm tiền đăng ký (mức A).

Trên tầng artifact sai, độ chính xác của model mạnh giảm từ 46,4% xuống 19,2% — ngay trên những bài mà nó vốn giải được gần một nửa. Ngược lại, artifact đúng giúp cải thiện độ chính xác. Tổng hợp trọng số của hai tầng tái tạo đúng $\Delta_{\text{real}} = -12,4$ điểm. Kết luận về cơ chế: D không phải là hình phạt của việc nhìn thấy artifact nói chung, mà là của việc nhìn thấy nội dung sai. Vì thiết kế không có lệnh sửa, chỉ riêng sự hiện diện của nội dung sai trong ngữ cảnh đã đủ tạo hiệu ứng âm. (Đối chứng cùng thiết lập cho ảnh hưởng thuần của độ dài ngữ cảnh chưa được thực hiện; đối chứng gần nhất — chèn bối cảnh vô quan trong thiết lập kiểm (mức B) — cho −3,6 điểm, tức nhiều ngữ cảnh thuần có hại nhẹ, nhỏ hơn hình phạt nội dung sai từ 7 đến 8 lần.) Quan sát này khớp với mức tái sử dụng thấp khi can thiệp ở §5.4: model mạnh ít sao chép bề mặt nội dung sai, nhưng vẫn bị nó neo hướng giải — ảnh hưởng đi qua định hướng nhiều hơn qua trích dẫn.

Bảng 14 chấm lại toàn bộ 500 bài theo cặp trạng thái (W đúng/sai) $\times$ (I đúng/sai), đồng thời ghi tỷ lệ E đúng trong từng ô, nhằm trả lời câu hỏi khi model mạnh sai thì việc sửa có giúp ích hay không.

Tầng	n	Tỷ lệ E đúng (%)
W đúng, I đúng	228	99,6
W đúng, I sai	11	90,9
W sai, I đúng (vùng rủi ro)	121	36,4 (phá 63,6%)
Cả hai sai	140	4,3

Bảng 14: Phân tầng 2×2 theo trạng thái của W và I trên MATH ($n = 500$), kèm tỷ lệ E đúng trong mỗi tầng.

Từ Bảng 14 rút ra ba nhận xét chính. Thứ nhất, giao thức sửa đóng vai trò như một ống dẫn, không phải bộ sửa lỗi: gần như không tạo ra lời giải mới khi cả hai model đều trượt (4,3% = 6/140), phá hủy ở quy mô lớn trên vùng rủi ro (63,6% = 77/121), và truyền lại đáp án đúng của W khi có (10/11 bài — tầng quá nhỏ để ước lượng chặt chẽ). Thứ hai, ở cặp này tầng khai thác được nhỏ hơn vùng rủi ro 11 lần (11 so với 121 bài); tỷ lệ này co giãn theo chênh lệch, nhưng chưa được đo ở các mức chênh khác. Thứ ba, chiến lược “ W đúng thì giữ W ” tương đương với oracle CEIL. Ngay cả khi được cung cấp oracle này, mức tăng cũng chỉ là +0,4 điểm (đúng thêm 2/500 bài), vì E vốn đã giữ được 99,6% và 90,9% trong hai tầng tương ứng. Kể cả với CEIL = 0,578, giá trị này vẫn thấp hơn $I = 0,698$. Trong lớp giao thức sửa bất đối xứng đã đo, không có cấu hình nào đạt $\text{acc}(E) > \text{acc}(I)$ (0/15 cặp MBPP, tốt nhất −3,0 điểm; các cặp MATH trong Bảng 12); trường hợp $E > I$ duy nhất là cấu hình cùng cỡ ở §5.5. Vấn đề không nằm ở việc “quên giữ W ”, mà là E phá vùng rủi ro. Trong các phương án đã thử (hai cổng oracle ở §5.10), chỉ có việc không đưa artifact vào ngữ cảnh mới bảo vệ được vùng đó.

5.10 Từ tín hiệu kiểm chứng đến lựa chọn và định tuyến

Tín hiệu chắc chắn. Trên HumanEval, cùng model, cùng 4 lần sinh, chỉ khác nhau ở nguồn kiểm tra, kết quả được trình bày trong Bảng 15.

Điều kiện	greedy	exec3	llm3	exec3 phá	llm3 phá
HE 1.5B	0,5375	0,6000	0,4812	0,0	2,8
HE 1.5B	0,5625	0,6438	0,4375	0,0	4,6
HE 7B	0,8000	0,8812	0,7812	0,0	2,6
HE 7B	0,7938	0,9000	0,7438	0,0	3,2

Bảng 15: So sánh chọn bằng chạy test (exec3) và LLM tự duyệt (llm3). Bốn hàng tương ứng với bốn điều kiện (hai model $\times$ hai hệ phần cứng); độ trôi phần cứng khoảng 0,03, nhỏ hơn hiệu ứng quan tâm nên kết luận về dấu vẫn đứng. Cột “phá” là số bài bị phá trên mỗi fold.

exec3 không phá hủy bài nào trong cả 20/20 fold và đạt đúng oracle@4 ở hai ô có ghi số (0,6438 và 0,8812). Ngược lại, llm3 phá hủy thì ở tất cả 20 fold. Mốc trung thực là greedy; bỏ phiếu đa số có hại trên code ($-11,3$ và $-13,1$ điểm) vì lời giải dài hiêm khi trùng nhau nguyên văn. Chênh lệch exec3 – greedy dao động từ $+6,3$ đến $+10,6$ điểm qua bốn điều kiện. Một điều kiện áp dụng quan trọng: khi model nền bão hòa (GSM8K 7B, solver 0,916), một bộ kiểm thực thi có độ chính xác 0,837 vẫn cho hiệu ứng rỗng âm (26 phá / 6 sửa). Do đó, “có bộ kiểm chắc chắn” chỉ có giá trị khi còn tiềm năng cải thiện cải thiện.

Tín hiệu học được. Bộ phân loại được huấn luyện trên lỗi tiêm (lấy lời giải đúng rồi đổi một chữ số trong đáp án) và sau đó được dùng để phát hiện lỗi thật. Đây cũng chính là phép thử “thay một số trong đáp án, verifier có thấy không”. Kết quả được trình bày trong Bảng 16.

Model	Tách biệt trên lỗi tiêm	Tách biệt trên lỗi thật	AUC	Δ độ chính xác
1.5B	$-0,012$	$+0,195$	0,528	$-0,8$ điểm (1/5 fold dương)
7B	$+0,573$	$+0,693$	0,893	$+2,4$ điểm (2/5 fold dương)

Bảng 16: Hiệu quả của bộ phân loại lỗi học được. Hai cột đầu là mức tách biệt điểm phân loại giữa lời giải đúng và sai, đo trên lỗi tiêm và lỗi thật **[TD: xác nhận định nghĩa chính xác của đại lượng hai cột này]**. Ở 1.5B, AUC 0,528 $\approx$ đoán ngẫu nhiên: thay một chữ số trong đáp án, verifier 1.5B không phát hiện được.

Ở model 7B, tín hiệu đo được rất tốt (AUC = 0,893; trên lỗi thật còn tách tốt hơn lỗi tiêm, cần loại trừ khả năng bộ phân loại bắt đặc trưng bề mặt như độ dài; đối chứng chưa được thực hiện). Tuy nhiên, khi sử dụng tín hiệu này để chọn, mức cải thiện chỉ là $+2,4$ điểm, và chỉ 2/5 fold dương. Theo phép thử dấu của chính chúng tôi, mức tăng này chưa phân biệt được với 0. Như vậy, tín hiệu đo được không tự động trở thành tín hiệu dùng được; điều này cũng cố phát biểu chặn trên dưới đây.


Phát biểu hợp nhất. Đặt cạnh nhau: trên code, khoảng cách oracle@ k – maj@ k là $+21,3$ điểm và exec3 lấy gần tròn (đạt đúng oracle@4, phá 0 lần); trên toán, khoảng cách là 12–13 điểm (Bảng 3) nhưng tín hiệu học được tốt nhất chỉ lấy $+2,4$ điểm.

Khoảng cách oracle@ k – maj@ k là chặn trên cho giá trị của mọi bộ kiểm trên cùng pool. Tín hiệu chắc chắn (chạy test) lấy gần tròn chặn đó; tín hiệu học được trong khảo sát của chúng tôi chỉ lấy được một phần nhỏ, dù chất lượng đo lỗi rất cao. Nút thắt của miền toán vì vậy mang tính kép: vừa thiếu tín hiệu chắc chắn, vừa nghèo pool. Trong số bài mà maj@5 sai, 71% (48/68, tính từ Bảng 11) là bài pool không chứa nổi một ứng viên đúng, tức không bộ chọn nào có thể cứu được.

Định tuyến. Hai kết quả về “chọn lúc nào cần gọi thêm” đều ở mức B (đo một lần, $n = 300$). Bộ định tuyến đồng thuận (chạy S và V , chỉ gọi A khi hai vai trò bất đồng) trên GSM8K giữ gần trọn phần lợi của pipeline với 77% chi phí (0,720 so với 0,723 ở 2,32 so với 3 lượt); trên MATH đạt 0,413, bằng với solver đơn lẻ và không mang lại lợi ích. Cơ chế phía sau nhất quán với §5.9: tỷ lệ bài model yếu sai (tức tỷ lệ artifact sai trong ngữ cảnh) khoảng 33% trên GSM8K so với 59% trên MATH; khi hai vai trò bất đồng, A cứu được 45,4% trường hợp trên GSM8K nhưng chỉ 25,0% trên MATH. Do đó, quan sát “định tuyến tiết kiệm ở đúng nơi ít cần tiết kiệm nhất” chỉ dừng ở mức B.

Hai trần cho cổng tiếp xúc (tính trên dữ liệu §5.9): cổng theo artifact hoàn hảo (chỉ cho xem artifact đúng — oracle) đạt +1,8 điểm so với I ; bộ phân loại thật cần độ chính xác khoảng 88–89% để hòa vốn (hòa vốn $\approx 27,2/(27,2 + 3,8)$ theo hai hiệu ứng ở Bảng 13). Cổng biết khi I sai (oracle mạnh hơn) đạt +3,2 điểm, nhưng đòi hỏi phát hiện lỗi của chính model mạnh — đúng loại tín hiệu vừa cho thấy đo được nhưng không dùng được. Hàm ý: cải thiện bộ cổng có trần thấp; cấu hình mặc định không đưa artifact vào ngữ cảnh có kỳ vọng cao hơn.

5.11 Huấn luyện vai trò và các lỗi tắt của hàm mục tiêu



Hình 3: Ví dụ cụ thể trên GSM8K: solver giải đúng (20%), verifier gốc “sửa” thành sai (25%) — đúng kiểu phá vùng rủi ro của §5.9; verifier sau GRPO giữ nguyên đáp án đúng, nhưng đạt được điều đó chủ yếu bằng cách can thiệp ít đi, không phải kiểm tra tốt hơn. Hình tái sử dụng từ báo cáo khối Shapley của nhóm.

Nhóm đã thử bảy phương pháp huấn luyện/tối ưu vai trò (Bảng 17). Không phương pháp nào đạt chuẩn dự án (hiệu ứng vượt ngưỡng và 5/5 fold cùng dấu) trên tập lạ, và mỗi thất bại đều truy được về việc model tìm ra lỗi tắt của hàm mục tiêu thay vì học năng lực đích.

thứ nhất: GRPO verifier với thưởng +1 cho sửa đúng, −1 cho phá, 0 cho im lặng. Sau huấn luyện, precision tăng từ 0,70–0,90 lên 1,00 (5/5 fold), nhưng V_gain giảm từ +6,8 xuống +4,4 điểm, và số lần

Phương pháp	Kết quả chính	Lỗi tất tìm thấy
GRPO verifier; thưởng +1 sửa / -1 phá / 0 im lặng	precision 0,70–0,90 → 1,00 (5/5 fold) <i>nhưng</i> $V_{\text{gain}} +6,8 \rightarrow +4,4$ điểm; can thiệp 20,2 → 8,4/100 câu	“im lặng miễn phí”: precision hoàn hảo nhờ nói ít đi một nửa
GRPO; thưởng theo đáp án cuối (vá lỗ im lặng)	+1,8 điểm < ngưỡng +2,0 đã khoá trước	nhại solver: trung vị đầu ra 480 → 19 ký tự; đồng ý-khi-solver-sai 0,50 → 0,64
GRPO + bất đối xứng thông tin (solver 0,5B, verifier 1,5B; tiền đăng ký, đủ nhánh I)	so model yếu: +17,0 điểm (5/5 dương); so chính model kiểm tự giải: -10,4 điểm (5/5 âm)	RL chỉ gỡ 38% thiệt hại tiếp xúc; 54% bài hỏng ra đáp án <i>thứ ba</i> không theo ai
ORPO aggregator (học từ cặp ưa thích)	MATH +3,3 (3/5 fold, dưới mức dao động nền); GSM8K chéo task -2,7	khuếch đại tật chép-ứng-viên-cuối (0,71 → 0,81); học “tự giải lại” thay vì chọn
Credit-RL (thưởng = phần đóng góp Shapley biên)	0/4 vai trò cải thiện theo chuẩn 5/5 fold	planner sập về plan <i>rỗng</i> 200/200 câu; verifier 23 sửa / 24 phá
Credit-RL giai đoạn 2 (thiết kế chống lỗi tất)	V-COND +3,0 (4/5) trên GSM8K — biến thể dương duy nhất	không chuyển miền: trên MATH -7,0 (5/5 âm)
MAPoRL đồng huấn luyện S/V/A	0,690 → 0,690 (+0,000)	aggregator nghẽn suốt quá trình huấn luyện

Bảng 17: Bảy phương pháp huấn luyện vai trò (mỗi phương pháp có tiền đăng ký hoặc cổng hiệu lực; chi tiết và đỉnh chính từng lần chạy trong docs/). Phương pháp thứ tám — bộ phân loại supervised — đã ở Bảng 16.

can thiệp giảm từ 20,2 còn 8,4 trên 100 câu. Lỗi tất được xác định là “im lặng miễn phí”: precision hoàn hảo đạt được nhờ model nói ít đi một nửa.

thứ hai: GRPO theo đáp án cuối (vá lỗ im lặng) đạt +1,8 điểm, thấp hơn ngưỡng +2,0 đã đăng ký trước. Lỗi tất là nhại solver: trung vị độ dài đầu ra giảm từ 480 xuống 19 ký tự, tỷ lệ đồng ý khi solver sai tăng từ 0,50 lên 0,64.

thứ ba: GRPO + bất đối xứng thông tin (solver 0,5B, verifier 1,5B; tiền đăng ký, đủ nhánh I) đo đồng thời hai mốc: so với model yếu cho +17,0 điểm (5/5 fold dương); so với chính model kiểm khi tự giải cho -10,4 điểm (5/5 fold âm). RL chỉ gỡ được 38% thiệt hại tiếp xúc; 54% bài hỏng sinh ra đáp án thứ ba không theo ai.

thứ tư: ORPO aggregator (học từ cặp ưa thích) đạt +3,3 điểm trên MATH (3/5 fold, dưới mức dao động nền) và -2,7 điểm trên GSM8K chéo task. Lỗi tất là khuếch đại tật chép ứng viên cuối (từ 0,71 lên 0,81) và học “tự giải lại” thay vì chọn.

thứ năm: Credit-RL (thưởng bằng phần đóng góp Shapley biên) không giúp vai trò nào cải thiện theo chuẩn 5/5 fold. Planner sập về plan *rỗng* trong 200/200 câu; verifier có 23 lần sửa và 24 lần phá.

thứ sáu: Credit-RL giai đoạn 2 (thiết kế chống lỗi tất) cho V-COND +3,0 điểm (4/5 fold dương) trên GSM8K, là biến thể dương duy nhất, nhưng không chuyển miền: trên MATH cho -7,0 điểm (5/5 fold âm).

thứ bảy: MAPoRL đồng huấn luyện S/V/A cho kết quả không đổi (0,690 → 0,690), vì aggregator bị nghẽn suốt quá trình huấn luyện.

Hình 3 minh hoạ một ca cụ thể. Đáng chú ý nhất là thí nghiệm bất đối xứng thông tin (phương pháp thứ ba), khi đo được đồng thời hai mốc trên cùng một lần chạy. So với model yếu, hiệu ứng là +17,0 điểm (5/5 fold dương); so với chính model kiểm khi không xem bài, hiệu ứng là -10,4 điểm (5/5 fold âm). Đây là bản tái lập bằng huấn luyện của nghịch lý mốc so sánh (§6): RL thu hẹp thiệt hại tiếp xúc (gỡ 38%) nhưng không đảo được dấu của Δ_{real} . Kết luận chung của toàn bộ các phương pháp nổi thẳng vào §5.10: khi tín hiệu thưởng cũng chỉ là một tín hiệu học được, quá trình tối ưu hoá tìm đến lỗi tất của tín hiệu nhanh hơn tìm đến năng lực kiểm tra thực sự.


6 Tổng hợp và thảo luận: Cơ chế nghịch lý mốc tham chiếu

Hai quan sát thực nghiệm tưởng chừng mâu thuẫn: §5.4 ghi nhận chênh lệch năng lực lớn với mức tăng +14,0 điểm, §5.7 lại chỉ ra chênh lệch lớn khiến mức cải thiện tối đa Δ_{ceil} chuyển sang giá trị âm.

Sự tương phản này bắt nguồn từ việc sử dụng hai mốc tham chiếu khác nhau, trong đó chênh lệch năng lực tác động theo hai chiều trái ngược (Hình 4):

- *So sánh với model yếu W* (mốc quy chiếu thường gặp trong các nghiên cứu): vai trò kiểm tra thực chất tương đương một lượt giải độc lập bởi model mạnh hơn (§5.4). Từ đó phản ánh khoảng cách năng lực nội tại kết hợp với lợi thế từ lần sinh bổ sung, dẫn đến mức tăng tỷ lệ thuận với độ chênh lệch năng lực (từ +3,0 điểm khi chênh lệch bằng 0 lên +14,0 điểm khi chênh lệch đạt 0,244).
- *So sánh với model mạnh chạy độc lập I* (mốc quy chiếu thực tế trong triển khai): giá trị ròng tuân theo biểu thức $G - L + R$. Trong đó, cơ hội cải thiện G suy giảm theo độ chênh lệch ($\beta_1 = -0,19$, §5.7), trong khi tổn thất L lại tăng mạnh (MATH ở mức chênh lệch 0,244, L lớn gấp ~ 11 lần G). Hệ quả giá trị kết hợp giảm dần, cấu hình dương duy nhất xuất hiện khi hai model có năng lực tương đương (+7,7 điểm tại mức chênh lệch bằng 0, §5.5).

Như vậy, nghịch lý trên không xuất phát từ cơ chế phối hợp mà do sự thiên lệch trong cách chọn mốc so sánh: chênh lệch năng lực làm phóng đại hiệu quả biểu kiến so với model yếu, nhưng lại làm suy giảm giá trị gia tăng thực tế so với model mạnh. Cơ chế tổn thất do phơi nhiễm (§5.9) lý giải nguyên nhân dẫn đến sự suy giảm này: khi khoảng cách năng lực càng lớn, xác suất xuất hiện artifact sai càng cao, khiến model mạnh bị định hướng sai ngay trên tập bài toán mà bản thân nó có khả năng giải quyết độc lập.



Hình 4: Nghịch lý mốc tham chiếu. Trục hoành là khoảng cách năng lực: hiệu ứng đo so với *model yếu W* (đường xanh liền) tăng mạnh do cộng hưởng năng lực; trong khi trần giá trị ròng Δ_{ceil} so với *model mạnh I* (đường đỏ đứt: khớp trên 15 cặp MBPP; các chấm đỏ: 3 điểm đo MATH) suy giảm nhanh và đổi dấu sang âm khi vượt ngưỡng tới hạn $g^* \approx 0,09$ do tổn thất phơi nhiễm L áp đảo cơ hội cải thiện G .

Sáu kết quả thực nghiệm độc lập củng cố cho kết luận trên: (1) về mặt cấu trúc, giao thức tuyển chọn triệt tiêu hoàn toàn tổn thất ($L = 0$) theo thiết kế; (2) về độ lớn, tổn thất L vượt trội hoàn toàn cơ hội cải thiện G ($L \approx 11G$) khi chênh lệch năng lực lớn trên MATH; (3) về cơ chế, tổn thất bắt nguồn trực tiếp từ việc phơi nhiễm với artifact sai lệch, đã được xác thực qua thử nghiệm chốt trước trên hai miền task; (4) về

trần lý thuyết, cơ chế định tuyến lý tưởng cũng chỉ mang lại mức cải thiện khiêm tốn +1,8 điểm trên nền suy giảm -12,4 điểm; (5) về tính tổng quát, quy luật thiết lập trên MBPP duy trì tính nhất quán trên 2/3 cặp model của tập MATH; và (6) về tính tái lập qua huấn luyện, phương pháp học tăng cường dưới điều kiện bất đối xứng thông tin ghi nhận đồng thời mức tăng +17,0 điểm so với model yếu và mức giảm -10,4 điểm so với model mạnh qua 5/5 fold (§5.11). Ngoài ra, các công bố độc lập về việc tranh biện đa tác tử kém hiệu quả hơn phương pháp self-consistency trên các model quy mô nhỏ [4] tương tự cho thấy sự tương đồng về xu hướng.

Khuyến nghị thiết kế hệ thống (áp dụng cho dải model 1,5B–32B trên các task suy luận):

- **Đối với các miền có cơ chế kiểm chứng tất định khi model chưa đạt ngưỡng bão hoà:** phương pháp tối ưu là tạo tập ứng viên độc lập và chọn lọc dựa trên kết quả thực thi; cơ chế này tiệm cận trần oracle mà không làm suy giảm các lời giải chính xác. Ngược lại, khi model nền tảng đã bão hoà độ chính xác, việc bổ sung bộ kiểm tra có thể làm giảm hiệu năng tổng thể (ghi nhận 26 trường hợp làm sai so với 6 trường hợp sửa đúng trên GSM8K 7B).
- **Đối với các miền thiếu cơ chế kiểm chứng tất định:** kỹ thuật bỏ phiếu đa số khai thác hiệu quả phần lớn tiềm năng trên các model nhỏ (43% trên MATH 1.5B) nhưng hiệu quả giảm rõ rệt trên model lớn (8% trên 7B) và có thể phản tác dụng trong bài toán sinh mã. Vai trò tổng hợp bằng LLM nhìn chung không đem lại lợi ích vượt trội so với bỏ phiếu cơ học; các tín hiệu phân loại học được tuy đạt độ phân tách cao trên tập kiểm thử nhưng chưa tác động tích cực đến độ chính xác thực tế.
- **Nguyên tắc phối hợp liên model:** việc chuyển giao artifact của model nhỏ để model lớn hiệu chỉnh nhìn chung dẫn đến hiệu quả âm hoặc không có ý nghĩa thống kê, đặc biệt khi khoảng cách năng lực vượt ngưỡng $\sim 0,09$ (trên MBPP). Trong trường hợp này, phương án tối ưu về cả hiệu năng và chi phí là kích hoạt trực tiếp model mạnh đơn lẻ.

7 Kết luận và hạn chế

Hiệu quả thực tế của các hệ thống đa tác tử LLM không thể được khái quát hoá bằng một kết luận đơn tuyến, mà phụ thuộc có hệ thống vào ba yếu tố định lượng: (1) cơ hội cải thiện G , được quy định bởi khoảng cách năng lực và có xu hướng thu hẹp khi khoảng cách này gia tăng; (2) khả năng khai thác κ , phụ thuộc vào tính tất định của tín hiệu kiểm chứng thay vì chất lượng phân loại ước tính; và (3) tổn thất phối nhiệm L , phát sinh từ việc tiếp xúc với artifact sai lệch, trong đó các giao thức hiệu chỉnh chủ yếu đóng vai trò truyền dẫn đáp án thay vì sửa lỗi suy luận thực chất (§5.9). Khoảng cách năng lực giữa các model vừa làm tăng mức cải thiện biểu kiến so với model yếu W , vừa đồng thời làm suy giảm giá trị ròng so với model mạnh I . Trong những miền bài toán có cơ chế kiểm chứng tất định, phối hợp đa tác tử tiệm cận trần hiệu năng oracle mà không gây hại đến các lời giải đúng; ngược lại, ở các miền suy luận mở, kiến trúc hiệu quả nhất là tạo mẫu độc lập và tổng hợp cơ học, tránh đưa artifact trung gian vào ngữ cảnh của các model kế tiếp. Cuối cùng, việc nhiều kết quả khả quan ban đầu không còn duy trì ý nghĩa thống kê khi áp dụng đồng thời ba phép kiểm soát nghiêm ngặt và quy trình chốt trước (với 16/32 lần chạy bị vô hiệu hoá và tỷ lệ dự đoán đúng của giả thuyết là 21/43) cho thấy tầm quan trọng của kỷ luật thực nghiệm trong việc đánh giá các hệ thống tác tử ngôn ngữ.

Hạn chế.

1. **Độ bao phủ của đại lượng triển khai Δ_{real} :** Không gian thực nghiệm của Δ_{real} mới được khảo sát trên 15 cặp model của tập MBPP (trong đó 0/15 cặp đạt giá trị dương có ý nghĩa), một cặp bất đối xứng trên MATH (-12,4 điểm), và một cấu hình cùng quy mô năng lực (+7,7 điểm). Ba cặp kiểm chứng chéo mở rộng chưa hoàn tất vì giới hạn VRAM 14,6 GB của GPU miễn phí: 8/9 nhánh sinh đã xong, còn một nhánh — kết quả chưa được đọc.
2. **Độ biến thiên của chỉ số A_{gain} :** Sau khi chuẩn hoá định dạng đầu ra `\boxed`, hai lần chạy thực nghiệm độc lập ghi nhận mức cải thiện lần lượt là +0,8 và +8,0 điểm. Mặc dù đều mang giá trị

không âm, sự khác biệt về biên độ (do sai khác về phân vùng dữ liệu và mức lượng tử hoá model) cho thấy nhận định về tính trung tính của vai trò tổng hợp vẫn cần thêm các thực nghiệm kiểm chứng quy mô lớn hơn.

3. **Mức độ giải thích phương sai của tổn thất L :** Chênh lệch năng lực giải thích được 82% phương sai của cơ hội cải thiện G , nhưng chỉ giải thích được 35% phương sai của tổn thất phối ngẫu nhiên L . Điều này cho thấy phần lớn biến thiên của L còn chịu ảnh hưởng từ các yếu tố kiến trúc hoặc giao thức chưa được model hoá đầy đủ.
4. **Độ nhạy thống kê của một số nhóm đối chứng:** Thử nghiệm hoán vị vai trò trên MATH có khoảng tin cậy tương đối rộng (biên độ trên đạt +13,4 điểm). Một số điều kiện kiểm soát chuyên sâu bao gồm lần sinh bổ sung không kèm artifact, kiểm soát độ dài ngữ cảnh trong điều kiện phối ngẫu nhiên, và so sánh giữa các model khác nhau trong cùng một họ kiến trúc vẫn chưa được triển khai đầy đủ. Ngoài ra, phân tích giá trị Shapley (§5.3) hiện dựa trên bootstrap theo mẫu bài toán mà chưa phân tích theo fold dữ liệu độc lập.
5. **Khả năng tổng quát hoá liên miền:** Phân tích chuyển dịch quy luật sang miền toán học mới chỉ dựa trên 3 cặp model với khoảng tin cậy rộng; vùng giá trị dương của hàm hồi quy chênh lệch năng lực hiện chỉ có một điểm thực nghiệm (+7,7 điểm tại mức chênh lệch bằng 0) và chưa đủ độ nhạy thống kê để xác lập chắc chắn trên tập MBPP; ngưỡng đổi dấu g^* chưa được gắn khoảng tin cậy tham số.
6. **Chiến lược giải mã và phân tầng mẫu số:** Nhánh nghiên cứu về luồng thông tin hiện chủ yếu sử dụng chiến lược giải mã tất định (greedy decoding), dẫn đến việc mỗi cấu hình chỉ có một ước lượng điểm duy nhất; các hiệu ứng chính chưa được phân tầng triệt để theo tập bài toán có khả năng tác động.
7. **Phạm vi quy mô model:** Toàn bộ các kết luận thực nghiệm trong nghiên cứu này được xác lập trên dải model từ 1,5B đến 32B tham số cho các task suy luận có cấu trúc, do đó chưa thể suy rộng trực tiếp cho các model ngôn ngữ quy mô siêu lớn ($> 70B$); riêng các kết quả huấn luyện (§5.11) đều chạy trên model 0,5–1,5B. Hai chuẩn đánh giá thực nghiệm (thanh sai số 5-fold và quy trình khoá chốt trước) cũng cần được kiểm chứng chéo toàn diện hơn trong các nghiên cứu tiếp theo.

Tài liệu

- [1] J. Austin et al. *Program Synthesis with Large Language Models*. arXiv:2108.07732, 2021.
- [2] Y. Benjamini, Y. Hochberg. *Controlling the False Discovery Rate*. JRSS–B 57(1), 1995.
- [3] M. Chen et al. *Evaluating Large Language Models Trained on Code*. arXiv:2107.03374, 2021.
- [4] Y. Chen et al. *When and Why Does Multi-Agent Debate Fail and Does It Really Underperform?* arXiv:2510.20963, 2025.
- [5] K. Cobbe et al. *Training Verifiers to Solve Math Word Problems*. arXiv:2110.14168, 2021.
- [6] Y. Du et al. *Improving Factuality and Reasoning in Language Models through Multiagent Debate*. ICML, 2024.
- [7] Z. Gou et al. *CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing*. ICLR, 2024.
- [8] A. Grattafiori et al. *The Llama 3 Herd of Models*. arXiv:2407.21783, 2024.
- [9] D. Guo et al. *DeepSeek-Coder: When the Large Language Model Meets Programming*. arXiv:2401.14196, 2024.
- [10] D. Hendrycks et al. *Measuring Mathematical Problem Solving with the MATH Dataset*. NeurIPS, 2021.
- [11] J. Huang et al. *Large Language Models Cannot Self-Correct Reasoning Yet*. ICLR, 2024.
- [12] J. Kaplan et al. *Scaling Laws for Neural Language Models*. arXiv:2001.08361, 2020.

- [13] H. Lightman et al. *Let's Verify Step by Step*. ICLR, 2024.
- [14] A. Madaan et al. *Self-Refine: Iterative Refinement with Self-Feedback*. NeurIPS, 2023.
- [15] *Multi-LLM-Agents Debate — Performance, Efficiency, and Scaling Challenges*. ICLR Blogposts, 2025.
- [16] *MASPRM: Multi-Agent System Process Reward Model*. arXiv:2510.24803, 2025.
- [17] *SHARP: Shapley Credit-based Optimization for Multi-Agent System*. arXiv:2602.08335, 2025.
- [18] L. S. Shapley. *A Value for n -Person Games*. Contributions to the Theory of Games II, 1953.
- [19] N. Shinn et al. *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS, 2023.
- [20] C. Snell et al. *Scaling LLM Test-Time Compute Optimally Can Be More Effective than Scaling Model Parameters*. arXiv:2408.03314, 2024.
- [21] X. Wang et al. *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. ICLR, 2023.
- [22] J. Wei et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.
- [23] A. Yang et al. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024.
- [24] L. Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS, 2023.

A Thuật ngữ và ký hiệu

greedy: giải mã tất định, luôn chọn token xác suất cao nhất; cùng cấu hình cho kết quả giống hệt.

maj@k / oracle@k / llm_agg@k: xem §4 (kèm ví dụ {7, 7, 7, 12, 15}).

artifact: bài làm của model yếu W , thứ được đưa (hoặc không) vào ngữ cảnh model mạnh.

$W / I / E$: model yếu; model mạnh độc lập; cùng model mạnh nhưng tiếp xúc artifact (§3.2).

$H / \kappa / D$: tiềm năng cải thiện (giá trị tiềm tàng trong pool) / khả năng khai thác (chất lượng bộ chọn) / thiệt hại do giao thức — ba câu hỏi của khung đo.

$G / L / R$: cơ hội / thiệt hại / cứu — ba số hạng của $\Delta_{\text{ceil}} = G - L + R$.

Δ_{ceil} : trần lý tưởng trừ model mạnh (cần đáp án chuẩn — chỉ để sàng lọc); Δ_{real} : $\text{acc}(E) - \text{acc}(I)$, triển khai được.

chênh (lệch năng lực): hiệu accuracy một lượt giữa model mạnh và model yếu, thang 0–1; g^* : mức chênh nơi đường khớp Δ_{ceil} đổi dấu.

V_gain / A_gain: hiệu accuracy khi thêm/bỏ vai trò V/A khỏi pipeline cùng cấu hình.

mức A / mức B: tiền đăng ký hoặc 5 fold kèm t-test / đo một lần hoặc hậu nghiệm (chỉ minh hoạ cơ chế).

mức dao động nền: biên độ chênh lệch của cùng một cấu hình giữa các fold (đo được: +1,0 đến +8,0 điểm).

B Con trở tư liệu gốc

B. Trích các bản tiền đăng ký (#104, #106, #107, #112) — docs/PREREGISTRATION.md.

C. Nhật ký các lần chạy bị loại (16 trên 32) và lý do — docs/RESULT_SEALS.md.

D. Quy tắc quy trình đo — docs/QUY_TRINH_VONG_LAP.md.

E. Bảng kết quả đầy đủ khối nhóm — docs/RESULTS.md; phân tích Shapley theo vai trò — docs/.

F. Rà thống kê giữa kỳ và các phán quyết — report/CAU_HOI_THAO_LUAN.md (nhóm E, A6–A7, F).