

Khi nào phi hợp a tốc t LLM to ra giò tr?

Mt kho sòt thc nghi m đi ba phỏp kim sòt

Nguyễn

c

Tú tng Dng*

Thòng 8, 2026

Tóm ttt ni dung

Còc h a tốc t LLM — planner-solver-verifier-aggregator, tranh bin, sinh-ri-sa — thng c bèo cò lị ci thìn òng k so vi mt model n l. Kho sòt nịy o li nhn nh ú trỏn GSM8K, MATH-500, MBPP vi HumanEval vi Qwen2.5 (1.5B-32B), Llama-3.1-8B vi DeepSeek-Coder-6.7B, đi *ba phỏp kim sòt* mị phn ln bèo cò trong lnh vc b qua: (1) **cứng ngón sòch suy lun** — pipeline bn vai tn 2,9-6,6 ln chỉ phờ mt lt gii, vi token ca còc model khòc c khũng cng n giò; (2) **ững mc so sòn** — ngi trin khai ò cú model mnh trong tay, nỏn i lng ững lị chỏnh lch vi *model mnh chy mt mớnh* ($V - I$), khũng phi vi model yu ($V - S$); (3) **ững mu s** — 57% s cóu khũng th chu tốc ng ca bt k c ch phi hp nịo, khin hiu ng tht b pha loũng 3,3 ln.

Sau ba kim sòt, bc tranh o chiu cú h thng. Hiu ng dng ln nht (+14,0 im, 5/5 fold) ch tn ti khi so vi model yu; so cng chỉ phờ FLOP vi model mnh n l thờ hoi hoc kỏm. Nguyễn nhón c nh v bng mt ng thc i s $\Delta_{\text{ceil}} = A - B + C$ (khp tuyt i 19/19 cp o) vi mt thờ nghi m tin ng kỳ tời lp trỏn hai mìn: thit hi n t vic model mnh **típ xũc vi ni dung sai** — trỏn MATH, chỏnh xỏc ca nú ri t 46,4% xung 19,2% trỏn tng artifact sai (-27,2 im; $p \approx 0$), trong khi artifact ững lịm nú *khỏ lớn* (+3,8 im; $p = 0,012$). Cứng mt bin chỏnh lch nng lc nuũ c c hi (A) ln thit hi (B): giao thc **tuyt chn** cú $B \approx 0$ theo cu trũc nỏn chỏnh lch cng ln cng thng; giao thc **sa cha** phi tr B nỏn chỏnh lch cng ln cng thua — nghch lý biu kin c gii trn.

mìn cú b kim **ững n** (code chy test c), phi hp t ững trn oracle vi khũng phờ mt bii nịo trong 20/20 fold; mìn khũng cú, mt b phón loi t AUC 0,893 vn ch i c +2,4 im — vớ giò tr ca mị b kim b chn bi khong còch **oracle@k - maj@k**, khũng bi cht lng tòn hiu. Khuyt ngh thc tin: *đứng model nh gii, model ln sòt; sinh c lp ri chn; ng cho model mnh xem bii lịm ca model yu vi mc òch sa.*

1 M u

Ghỏp nhieu vai LLM thnh mt h cú to thỏm giò tr so vi mt model n l khũng? Vị nu cú, giò tr n t óu — t *cu trũc phi hp*, hay t th khòc i kỏm cu trũc ú?

Cóu hi khú tr li hn v ngoi, vớ ba vn o lng.

Th nht, ngón sòch. Pipeline bn vai $P \rightarrow S \rightarrow V \rightarrow A$ tn 2,9 ln kỳ t sinh trỏn GSM8K vi 6,63 ln trỏn MATH so vi mt lt gii (§5.1). So mt h chỉ phờ $3\times$ vi mt h $1\times$ ri kt lun “phi hp cú giò tr” lị so sòn khp khing. Tinh vi hn: khi còc vai đứng model *khòc c*, ngay c s token cng khũng cng n v — mt token do model 7B sinh tn $\sim 4,7-4,9$ ln FLOP so vi token ca model 1.5B, vớ chỉ phờ suy lun t l vi s tham s [11] (§5.5).

Th hai, mc so sòn. Gn nh toịn b dùng sinh-ri-sa o ci thìn so vi model *b sa* — tc model yu ($V - S$). Nhng la chn thc ca ngi trin khai, vn ò cú model mnh trong pipeline, lị: chy pipeline, hay **gi thng model mnh** ($V - I$)? Kho sòt nịy cho thý hai mc ú cho **hai du ngc nhau** trỏn cng mt h (§5.5, §5.8).

*Th t tởn vị vic ghi nhn Quón: quy t Bc 0. Bn v1.0: §2 do Nguyễn chp bũt tm, c rị vị xỏc nhn trỏch dn; §4 Tú tng Dng rị.

Th ba, mu s. Phón tng theo khú cho thy 57% s cóu nm ngoi tm vì ca mi c ch phi hp: 32% quò sc (khũng mu nio ững — khũng cú gơ chn), 25% quò d (mi mu u ững — khũng cú gơ ci thin). Hiu ng +31,1 im trồn tng kh tọc ng b pha loõng thịnh +9,3 khi trung bnh toin tp (§5.3). Thiu kim soòt nịy, hiu ng tht b ònh giò *thp* — ngc chiu vì hai kim soòt trồn.

Kho soòt hp nht ba nhònh nghiõn cu c lp ca nhúm — phón rõ úng gúp theo vai bng giò tr Shapley [14], phón tồch chi phờ-lì òch ca c ch nh tuyền, vị phón tồch lung thũng tin ca giao thc sa cha — di mt khung duy nht, vị trnh bịy kt qu theo **mch đn đt**: mi thờ nghim sinh ra t cóu hi mị thờ nghim trc li.

úng gúp.

1. Khung phón rõ giò tr value = $H(\text{pool}) \times \kappa(z) - D(\text{protocol})$ thng nht ba nhònh (§3).
2. Bng chng trồn hai thit k c lp rng **chõnh lch nng lc** — khũng phi s lng vai, danh tòngh vai, hay h model — lị bin quy t nh (§5.4, §5.7).
3. Mt **ng thc i s** $\Delta_{\text{ceil}} = A - B + C$ tồch c hi khi thit hi, khp tuyt i trồn 19/19 cp o (§3, §5.7).
4. Bng chng tin ng kỳ, tòi lp hai min: thit hi ca giao thc sa n t **típ xữc vì ni dung sai**, khũng phi t tip xữc; vị giao thc sa lị **ng đn, khũng phi b sa li** — truyên òp òn ững gn trn vn (90,9%) nhng gn nh khũng sòng to li gii mi (4,3%) vị phò quy mĩ ln (63,6% trồn tng ri ro) (§5.8).
5. Gii nghch lý “cứng bin, hai du” ca chõnh lch nng lc (§6).
6. Mt phòt biau nh lng v κ : giò tr ca b kim bng khong còch **oracle@k – maj@k**, khũng bng cht lng b kim — kóm hai trn nh tuyền tòngh c (§5.10).
7. Mt b quy trnh chng t ònh la (tin ng kỳ, iu kin hp l, niỏm phong hash, sịn nhieu, t-test theo fold) mị **50% s ln chy khũng vt qua** — bn thón t l ú lị mt kt qu (§7).

2 Cũng trnh liỏn quan

Sinh-ri-chn. Chui suy lun [18] m ng cho self-consistency [17]: sinh *k* li gii c lp ri b phiu a s — chònh lị **maj@k** ca kho soòt nịy. Dừng chn-bng-b-kim gm chm theo quò trnh [12] vị m rng compute lữc suy lun [16]. c im chung: giao thc *khũng cho phỏp to li gii mĩ bc tng hp*, tc $B \approx 0$ theo thut ng ca chũng tũ.

Sinh-ri-sa. Self-Refine [13], Reflexion [15] vị CRITIC [6] cho model c sn phm (ca chònh nú hoc model khòc) ri sa. Huang vị cng s [10] ch ra LLM cha t sa c suy lun khi thiu tòngh hiu ngoi — nht quòn vì kt qu llm3 vị phón tng tip xữc ca chũng tũ. **im chũng tũ nhn mngh: còc cũng trnh dừng nịy ch yu bòa cò ci thin so vì model b sa hoc lt nhòp u ($V - S$), khũng so vì vic đứng thng model sa ($V - I$)** [: rị tng bị, xòc nhn mc so sòngh ca tng bị — óy lị ch lun im §1 ng hoc].

a tọc t vị tranh bin. Tranh bin a tọc t [5] vị LLM-lịm-giỏm-kho [20] lị còc c ch phi hp ph bin. Tng hp s liu cũng b gn óy ca nhúm [: **ngun c th**] cho thy tranh bin thua self-consistency a s ù so sòngh vị **sp 16 im** vì Llama-3.1-8B trồn GSM8K (80,13 → 63,87) — khp vì mu hnh sp model nh mị chũng tũ quan soòt c lp (§5.4). H gn nht v kin trũc lị MAS_RPSV (bn vai ni tip, cứng c model, cứng benchmark) vị SHARP — cứng đứng giò tr Shapley cho credit assignment, vị bòa cò ch 12,96% lt gi subagent lị hu òch [: **xòc nhn c hai ngun**] — song song vì kt qu “2/4 vai thc s tòngh toòn” ca chũng tũ.

V trở ca kho soòt. Chũng tũ khũng xut kin trũc mị; chũng tũ xut **còch o**: ba phỏp kim soòt, mt ng thc phón rõ, vị mt khung ba tha s — ri đứng chũng tr li *khi nịo* còc kin trũc trồn to giò tr tht.

3 Khung lý thuyết

3.1 Phón rõ giò tr

$$\text{value} = H(\text{pool}) \times \kappa(z) - D(\text{protocol}) \quad (1)$$

- H — **d a**: pool ng viồn cú cha li gii mị model mnh n l khũng to ra c khũng? o bng **oracle@k**.
- κ — **cht lng b chn**: mt tồn hiu *kh thi* (khũng phi oracle) cú lý c li gii ú ra khi pool khũng?
- D — **thit hi**: bn thón giao thc phò lng bao nhiêu?

Ba nhònh ca nhúm o ba tha s: Shapley theo vai o H ; router o κ ; lung thũng tin o D .

3.2 ng thc phón rõ

Kỳ hiu (chữ ý: *khũng* trũng vi tổn vai §4): S = model yu gii bị; I = model mnh gii bị, *khũng thy gơ ca* S ; V = **cũng model mnh ú** nhng ng cnh cú kổ bị lịm ca S . I vị V lị cũng mt model — khòc nhau **input**, nỏn $V - I$ cũ lp ỹng mt bin: vic nhơn thy bị lịm ca model yu. Trn lý tng CEIL = ỹng nu S ỹng **hoc** V ỹng — chònh lị **oracle@2** trở cp $\{S, V\}$, tc chín lc “ S ỹng thờ gi S ” dng hoịn ho.

$$\Delta_{\text{ceil}} = \text{acc}(\text{CEIL}) - \text{acc}(I) = A - B + C \quad (2)$$

$A = P(S \text{ ỹng} \wedge I \text{ sai})$	c hi cú sn — tònht cht ca <i>cp model</i>
$B = P(S \text{ sai} \wedge I \text{ ỹng} \wedge V \text{ sai})$	giao thc phò bị I vn ỹng — tònht cht ca <i>giao thc</i>
$C = P(S \text{ sai} \wedge I \text{ sai} \wedge V \text{ ỹng})$	giao thc cu bị c hai u sai

óy lý ng thc i s, khũng phi mĩ hnh: khp tuyt i trở 4/4 cp cú lu vt vị 15/15 cp ca thờ ngihm quy mĩ ln. Giao thc **ch chn** cú $B \approx 0$ vớ khũng th to li gii sai mị; giao thc **sa** luĩn phi tr B . Δ_{ceil} lị *chn trở sịng lc* (cn ỏp òn chun, khũng trin khai c): $\Delta_{\text{ceil}} < 0 \Rightarrow$ ỹng lng ngay — khũng cng nộ cu nị; $\Delta_{\text{ceil}} > 0 \Rightarrow$ mị c hi tip v κ . Con s trin khai lị $\Delta_{\text{honest}} = \text{acc}(V) - \text{acc}(I)$.

3.3 Ba mnh

M1. D lị hịm ca tip xữc vi **nị dung sai**, khũng phi ca tip xữc (§5.8).

M2. κ ph thuc tồn hiu lị **ỹng n** hay **hc c** — khũng ph thuc mnh hay c lp. (ổ qua hai ln thu hp t bn gc “c lp thng tng quan”; §5.10.)

M3. nh tuyen tit kim ỹng nị ỏt cn tit kim nht (§5.6).

4 Thit lp thờ ngihm

[**TD**: rị toịn b mc nịy]

Model. Qwen2.5-Instruct 1.5B/7B/14B/32B [19]; Llama-3.1-8B-Instruct [7]; DeepSeek-Coder-6.7B-Instruct [8]. Lng t hoà **o tng model, khũng suy theo h**: DeepSeek-6.7B np nf4 ht 3,61 GB; Qwen-7B 5,21 GB; Llama-8B vị Qwen-14B *khũng* lng t hoà c trở bn chy (fp16 ~16/28 GB). Phn cng: Kaggle 2×T4 (nf4/fp16) vị RTX 6000 Pro 95 GB (bf16); so sònht chổ ln chy ch hp l khi trũng c (phn cng + chònh xòc s) ln b bị — o c nf4 so vị bf16 dch kt qu ti 0,03.

Benchmark. GSM8K [4]; MATH-500 [9]; MBPP [1] — di chònh **task_id** 11–510 (~499 bị sau lc chun), di gi li 511–974 (464 bị); HumanEval [3]. **MBPP/HumanEval** cú **b kim ỹng n** (chy test); MATH/GSM8K khũng — khòc bit nịy quy nh kt lun §5.10.

Vai vị chi phờ. P planner, S solver, V verifier, A aggregator; t hp PS, PSV, PSVA, SVV, ... Chi phờ bõ theo lt gi vị theo token/kỳ t; khi cõc vai khõc c model, quy thõm v **chi phờ trng s FLOP** (tham $s \times \text{token}$).

Gii mõ vị tõnh tt nh. Khi lung thũng tin dũng greedy (`do_sample=False`): cũng cu hõnh cho kt qu **ging ht tng bii** (kim 499/499 gia hai tị khõn, hai ngịy). H qu: chy li cũng cu hõnh khũng phi bng chng c lp; dao ng gia cõc fold n t *khõc bii*, khũng phi nhiu ly mu.

Thng kõ. Khi vai trũ/chi phờ: 5 fold ri nhau; sịn nhiu hiu chun bng cõch chy cũng cu hõnh trõn 5 fold (V_{gain} dao ng $+1,0 \dots +8,0$; std gia fold 2,65); suy din bng t-test trõn fold ($SE = s/\sqrt{k}$; $t_{0,975}(4) = 2,776$), KTC 95%, vị phõp th du (5/5 cũng du $\Rightarrow p = 0,031$ mt phõa). Khi lung thũng tin: McNemar chõnh xõc gõp cp trõn cũng b bii; bootstrap gõp cp theo ch s bii (10 000 ln). Ngng din gii c **khõc trc khi chy** trong bng tin ng kỳ, gm dũng bõc b gi thuyt.

5 Hình trõnh thc nghiõm

Trõnh bii theo mch: mĩ mc m bng cõu hĩ k tha, ỳng bng cõu hĩ li. S liũ mc A tr khi ghi khõc.

5.1 Pipeline cú giũp khũng — vị sịn nhiu nh hõnh mĩ th

Task	Solver	Pipeline	Chõnh	Chi phờ kỳ t
GSM8K	0,632	0,744	+0,112	2,9×
MATH	0,405	0,345	−0,060	6,63 ×

Bng 1: Pipeline y so vi solver n l (Qwen-1.5B).

Trõn GSM8K cú li (5 fold: PSVA $-$ PS = +5,6; KTC [+3,3; +7,9]; $t = 6,89$); trõn MATH **tn 6,63 ln kõm hn 6 im**. Phõp hiu chun sịn nhiu — cũng cu hõnh, 5 fold — cho V_{gain} t +1,0 n +8,0: mt phõp o n l 100 bii gn nh khũng mang thũng tin, vị mĩ hiu ng t ỳ i kõm KTC.

Cõu hĩ li: phn li cú phi do phi hp, hay ch do c sịnh nhiu lt?

5.2 Kim soõt ngõn sõch: giò tr nm lt sinh, khũng vai tng hp

B tng hp (8 lt sinh)	MATH 1.5B	MATH 7B
greedy (1 lt)	0,50	0,72
maj@8 — b phiu	0,60	0,73
llm_agg@8 — LLM tng hp	0,41	0,47
oracle@8 — trn	0,73	0,85

Bng 2: Cũng ngõn sõch 8 lt sinh, ch i b tng hp.

Cũng chi phờ, thịnh phn LLM tng hp kõm b phiu 19–26 im; 7B kõm c greedy mt lt. Nũ phõ a s ỳng 21/26 ln, sa c a s sai 2/0 ln. Kt qu **ph thuc task** (`vote5 - llm_agg`: +0,075 MATH, −0,056 GSM8K) — phõt biu ỳng: *b tng hp LLM khũng mang giò tr n nh; mĩn khũ nú góy hĩ òng k*.

Hai i chng tõch nt:

- **rerun = loop** (0,453 = 0,453): gii li *khũng xem* phõ bõnh ca verifier cho kt qu bng chõnh xõc gii li *cú phõ bõnh*. Li òch n t **lt sinh thõm**, khũng t ni dung phn hĩ. (Con s +20 o mt ln khũng tõi lp: 5 fold cùn +4,0.) Bin th vùng lp gii-ri-chm r hn pipeline vị li **thng nú** trõn MATH: `loop - PSVA` = +4,0; KTC [+0,5; +7,5]; $t = 3,21$ — cũng chi phờ (4,2 so vi 4,0 lt).

- **Aggregator không chn — nú chộp.** 65% s cóu nú chộp nguyên ng viồn *cui cứng*; c 600 trace: 100% lt không sinh s mi. **Nhng phn “gốý hi” phi ònh chònh:** 85% s ca phò trồn MATH lị *khũng phòt ra \boxed{}* — li nh dng; ch 5% chn nhm tht. Thỏm fallback min phò: **A_gain** t $-6,4$ thình **+1,0** [0; +2]. B tng hp LLM *trung tòngh mt khi x lý xong nh dng* — không cng giò tr, nhng “phò hoi” phn ln lị hìn vt o lng. (Mt móu thun cha gii gia hai ln chy 5 fold ca chònh i lng nịy — $-6,4$ vị $+8,0$, mi bốn nht quòn nị b — xem §8.)

Cóu hi li: mi can thip u cho 0–5 im — cú phi ang o sai mu s?

5.3 Kim soát mu s: 57% s cóu bt ng

Mu ững /5	<i>n</i>	Solver	vote5	Δ
0/5 — quò sc	48 (32%)	0,000	0,000	0,000
1/5	20	0,000	0,000	0,000
2/5	15	0,333	0,600	+0,267
3/5	12	0,583	1,000	+0,417
4/5	18	0,722	1,000	+0,278
5/5 — quò d	37 (25%)	1,000	1,000	0,000

Bng 3: Phón tng theo s mu ững trong 5 lt (MATH 1.5B, $n = 150$).

57% s cóu khũng th cú hui ng vớ lý do toòn hc. Trồn tng kh tòn ng: $+21,5$ im (nhúm 1–4/5, còch nhúm ca tị liu ngun) hay $+31,1$ (nhúm 2–4/5, loi tng hui ng bng 0); trung bõnh toịn tp pha loõng cùn $+9,3$. Mt can thip $+10$ im tht s hìn ra $+3$ — di sịn nhiu, vị b kt ti oan lị vũ dng. Ba kim soát tòn ng **ngc chiu**: thiu mu s $\Rightarrow$ ònh giò thp; thiu ngón sòch/mc $\Rightarrow$ ònh giò cao.

Cóu hi li: trong phn kh tòn ng, vai nịo ứng gúp?

5.4 Vai trò: chuyển bit hoà sp ; bin tht lị nng lc ca lt kim

Ch s **hình vi** t trace: 1.5B, planner — b cm tòngh òp òn — cha sn òp òn 34,7% cóu MATH (45,3% cú *\boxed{}*); solver không sinh s mi 60,7–62% lt, li gii dị **19 kỳ t** khi cú plan (664 khi khũng). *Nú khũng gii — nú chộp.* 7B, hai vai hi phc (rù òp òn 1,0–4,0%) — nhng mc ú pipeline lị thua solver n l. i chng nhón qu: **hoàn v prompt gia còc v trở** (normal/swap/solo) cho accuracy không phón bit c — GSM8K 0,660 = 0,660, solo 0,673; MATH swap – normal = $+5,3$ nhng $t = 1,84$, KTC $[-2,7; +13,4]$ — khũng t. **Danh tòngh vai không phi bin.**

Bin tht lị **nng lc ca model** lt th hai. Cứng 300 bị MATH (5 fold $\times$ 60):

Lt kim	Hui ng	KTC 95%	Sa : Phò
Verifier 7B (solver 1.5B)	+14,0	[+7,4; +20,6]	43 : 1
Verifier 1.5B (cứng c)	+3,0	chm 0	15 : 6
Riõng phn do ln hn	+11,0	[+3,9; +18,1]	—

Bng 4: Bt i xng nng lc lt kim, MATH.

C ch t trace: khi can thip, verifier **tòi s dng 0%** s liu ca solver — nú khũng dù tng bc, nú **gii li t u**. *Verifier lị mt solver th hai i lt b kim; mua verifier 7B lị mua mt solver tt hn cho lt th hai.* Phứ hp: **V_gain** cú ý ngha c MATH 7B ($+4,4$; KTC $[+1,5; +7,3]$) — giò tr verifier xut hìn *cứng* nng lc; MATH 1.5B thớ khũng ($+1,4$; $p = 0,235$).

Cóu hi li: +14,0 lị so vì model yu. So ững mc thớ sao?

5.5 Kim soát mc so sòngh vị n giò token: cu hõnh bt i xng b chi phi

So vì S7B n l: bt i xng kỏm 10 im trồn GSM8K; hoị trồn MATH (chỏnh theo fold cha 0). Ct token cú **hai li chng nhau**: (a) trng o gc ch m token *do 7B sinh*, b sút token ca solver 1.5B; (b) token

Cu hnh	GSM8K	MATH	Token GSM8K	Token MATH
S1.5B + V7B	0,810	0,563	105k	119k
S7B mt mnh	0,910	0,593	120k	152k
S7B + V7B	0,900	0,670	205k	261k

Bng 5: Token o tht, 5 fold. *Ct token khng so c trc tip gia hai c model — xem hiu chnh bốn di.*

7B t $\sim 4,7-4,9$ ln token 1.5B. Quy v trng s FLOP (tham s $\times$ token; nh y chars/token 3,0–4,0):

	Token thũ 7B	Trng s FLOP
GSM8K: asym / S7B	0,88 — “r hn 12%”	1,00–1,05 — tit kim bin mt
MATH: asym / S7B	0,78 — “r hn 22%”	0,92–0,96 — cùn 3–8%

Bng 6: Hiu chnh n giò token. Cha tnh prefill (7B cùn phi c bị ca 1.5B) nnn hiu chnh vn thion v cho cu hnh bt i xng.

Kt lun: **trón GSM8K cu hnh bt i xng b chỉ phi hoịn toịn** (kõm 10 im, khng r hn); trón MATH lị tit kim *biõn* vì chõnh xõc hoị. Solver n l nm trón ng Pareto c hai task; pipeline y khng nm trón ng Pareto MATH. Cì thìn tht duy nht trong bng: thõm V7B vjo *chõnh* S7B trón MATH: +7,7 ($p = 0,0075$) — vì giò 1,7 $\times$ token.

óy lị dng tng quõt ca vn mc: $V - S$ dng, $V - I$ óm — **cúng h, hai mc, hai kt lun ngc nhau**, lp lị mi nhõnh ca kho sõt.

Cóu hi lị: giò tr mt i óu? (T óy dng ng thc §3.2.)

5.6 nh tuyen: tit kim ni õt cn nht (mc B — o mt ln, $n = 300$)

Consensus router (chy S, V ; bt ng mi gi A): GSM8K t 0,7200 vì chỉ phõ 2,32 lt — gi 94% phn lị ca pipeline (0,7233; 3 lt) vì 77% chỉ phõ; MATH t 0,4133 — **ũng bng solver n l**, vũ dng. C ch: khi $S-V$ bt ng, A cu 45,4% trng hp trón GSM8K nhng 25,0% trón MATH. Mnh M3: nh tuyen ch tr tin ni õ sn ng thun. (Võ sao MATH t hn — tr lị §5.8: model yu sai nhieu hn $\Rightarrow$ tip xữc ni dung sai nhieu hn.)

5.7 S hng A : chõnh lch nng lc, khng phi h model — vị quy lut ca Δ_{ceil}

Quan sõt thũ trón 7 cp gp nhieu ln chy: cp *khõc h* cú d a A cao gn gp ùi (0,0597 so vì 0,0481) — nhng cõc cp khõc h eng cú chõnh lch nng lc nh hn (0,130 so vì 0,167); hai bin trn hoịn toịn. Thit k tõch (tin ng kỳ): **6 model, 15 cp cú hng, cng 499 bị MBPP, mt ln chy**, b sung ũng cõc ù cùn thiu:

$$A = \beta_0 + \beta_1 \cdot \text{chõnh} + \beta_2 \cdot \text{khõc_h}$$

$$\beta_1 = -0,1922 \ (p \approx 0) \quad \beta_2 = +0,0045, \text{ KTC } 95\% [-0,0051; +0,0140], \ p = 0,31$$

R^2 ch vì chõnh lch = 0,824. KTC ca β_2 nm **trn di** ngng +0,02 õ khoẽ trc — **null cú thng tin**: “khõc h” lị tng quan gi; bin tht lị chõnh lch nng lc. (Kt qu a dng pool — 3 model cho 2,70/3 ng viõn phõn bit so vì 1,91/3 khi lý mu cng model; 36,2% $\rightarrow$ 6,5% s bị ch mt ng viõn — c ghi lị “khõc **model**”: i chng khõc-model-cng-h cha chy.)

Thõm nhõnh sa cho c 15 cp (tin ng kỳ) cho quy lut:

$$\Delta_{\text{ceil}} = +0,0218 - 0,2392 \times \text{chõnh}; \quad R^2 = 0,60; \ p = 10^{-5}; \ g^* \approx 0,09 \quad (3)$$

ng thc $A - B + C$ khp 15/15. c kõm bt buc: **0/15 cp dng cú ý ngha; 3/15 óm cú ý ngha** $\Rightarrow$ ch phõt biu **chiu ph nh**: *chõnh lch vt $\sim 0,09$ thõ ng dng giao thc sa*. Xõc lp vng dng cn $\sim 8 \times$ toịn b MBPP — bt kh thi trón benchmark nịy. Chõnh gii thờch 82% phng sai ca A nhng ch 35%

ca B. (Ghi chữ c ch, mc B: ngng bo toịn mị V phi vt tng theo chỏnh vi h s 2,18 — nhanh gp ửi kh nng bo toịn the ca nú, h s 1,10; chỏnh lch h s p = 0,0066. Giao the sa cht vớ s hc ngón sỏch, khũng phi vớ model mnh “yu búng vớa”.)

Cóu hi li: B do óu mị cú?

5.8 S hng B: hớnh pht ca ni dung sai — vị giao the sa lị ng dn

Thit k sch nht (tin ng kỳ; MATH-500 i min so vì quan sỏt thm dù gc trỏn MBPP): hai nhònh đứng **cứng mt lnh gii**, khỏc duy nht vic ng cnh cú kỏm bị lịm ca model yu; phón tng theo **ni dung** bị lịm ú:

	MBPP 11–510 ^(mc B)	MBPP 511–974 ^(mc B)	MATH-500 (mc A)
Artifact sai	−0,1900	−0,1927	− 0,2720 ($p \approx 0$; $n = 261$)
Artifact ững	+0,0636	+0,0245	+ 0,0377 ($p = 0,012$; $n = 239$)

Bng 7: Hiu ng ca vic nhón thy artifact, phón tng theo ni dung. Kt qu trung tóm.

Trỏn tng artifact sai, model mnh ri **46,4% → 19,2%** — trỏn chỏnh nhng bị nú vn gii c gn mt na; artifact ững lịm nú khỏ lớn. Tng hp trng s tòi to *chỏnh xỏc* $V - I = -0,1240$. **D khũng phi hớnh pht ca vic nhón thy — mị ca vic nhón thy ni dung sai**; vị vớ thit k khũng cú lnh sa, *riỏng nhón thy ỏ góy hi*.

Bng $2 \times 2 \times 2$ y (chm li t trace) tr li cóu hi t nhiỏn “*khi I sai the sa cú giữp khũng?*”:

Tng	n	V ững
S ững, I ững	228	99,6%
S ững, I sai	11	90,9%
S sai, I ững (<i>vững ri ro</i>)	121	36,4% — tc phỏ 63,6%
C hai sai	140	4,3%

Bng 8: Bng $2 \times 2 \times 2$ trỏn MATH ($n = 500$).

Ba c s: (1) **giao the sa lị ng dn, khũng phi b sa li** — truyển ỏp ỏn ững ca S gn trn vn (90,9%), gn nh khũng sỏng to li gii mị (4,3%), phỏ quy mũ ln (63,6%); (2) tng khai the c nh hn tng ri ro **11 ln** (11 so vì 121 bị); (3) “gi nguyỏn S khi S ững” chỏnh lị oracle CEIL — vị tng khũng oracle ú cng ch thỏm +0,004 trỏn MATH (ững 2 bị/500), vớ V vn ỏ gi c 99,6%/90,9%; k c vy CEIL = 0,578 vn thua $I = 0,698$. **Khũng cu hớnh nịo cú $V > I$** trong toịn b kho sỏt (0/15 cp MBPP; tt nht −0,030). Vn khũng phi “quỏn gi S ” — mị lị V phỏ tng (S sai, I ững), vị cỏch duy nht bo v tng ú lị *ng cho xem*.

óy cng lị li gii cho §5.6: aggregator vũ dng trỏn MATH vớ ú model yu sai nhiu hn — t l tip xữ ni dung sai cao hn (45,4% so vì 25,0% khp hng; mc B).

5.9 Tờnh chuyủn min ca quy lut chỏnh lch

Đứng ng khp **trỏn MBPP** d bởo Δ_{ceil} **trỏn MATH** (tin ng kỳ; 3 cp Qwen; mị iu kin hp l t; KTC bootstrap gỏp cp 10 000 ln):

Cp	Chỏnh	o c	KTC 95%	MBPP d bởo
7B→14B	0,044	−0,0140	[−0,046; +0,018]	+0,0108
1.5B→7B	0,244	− 0,1660	[−0,208; −0,124]	−0,0361
1.5B→14B	0,288	−0,0680	[−0,102; −0,034]	−0,0471

Bng 9: Th im tờnh chuyủn min ca quy lut chỏnh lch.

2/3 d bòa trong không $\Rightarrow$ quy luật **khủng b bcc b** trở nên toàn (khủng với “ô xóc nhn”: KTC rng 0,064–0,084 nổi phấp kim cú phón gii thp). Cp lch lch **h thng** — $B = 0,208$, gp mi ln A — vị tời lp mt phấp o c lp trở cứng cp ($-0,1380 \rightarrow -0,1660$): quy luật mũ t xu hng; ngoi l ni model yu quò yu so vi bị.

5.10 κ : ững n t trn oracle; hc c thơ “o c $\neq$ đúng c”

Tồn hiu ững n — HumanEval, cứng model, cứng 4 lt sinh, khòc duy nht ngun kim; tời lp trở 4 cu hnh $\times 2$ h phn cng:

Ũ	greedy	exec3	llm3	exec3 phò	llm3 phò
HE 1.5B (Kaggle)	0,5375	0,6000	0,4812	0,0	2,8
HE 1.5B (5090)	0,5625	0,6438	0,4375	0,0	4,6
HE 7B (5090)	0,8000	0,8812	0,7812	0,0	2,6
HE 7B (Kaggle)	0,7938	0,9000	0,7438	0,0	3,2

Bng 10: Kim bng chy test (exec3) so vi LLM t kim (llm3).

exec3 phò 0 bị trong 20/20 fold vị t ững oracle@4 hai ũ cú ghi s; llm3 phò c 20 fold. Mc trung thc li greedy — b phiu **cú hi trở code** ($-0,113/-0,131$; li gii dị him trúng): **exec3** – greedy = $+0,063 \rightarrow +0,106$. Gii hn: khi model nn báo hoị (GSM8K 7B, solver 0,916), b kim thc thi chònh xóc 0,837 vn **l rùng** (26 phò / 6 sa).

Tồn hiu hc c — b phón loi hun luyr trở li tiỏm (i mt ch s trong li gii ững), c hai ũ hp l:

Model	Li tiỏm	Li tht	AUC	i thịnh chònh xóc
1.5B	$-0,012$	$+0,195$	0,528	$-0,008$ (1/5 fold)
7B	$+0,573$	$+0,693$	0,893	$+0,024$ (2/5 fold)

Bng 11: B phón loi hc c: o c rt tt, gn nh khủng đúng c.

7B nú hc rt tt, chuyr giao cùn tt hn trong phón phi — nhng AUC 0,893 ch mua c $+2,4$ im. **o c $\neq$ đúng c**. Phòt biu hp nht, ni bn thờ ngim:

Giò tr ca mt b kim bng không còch oracle@k – maj@k, khủng bng cht lng b kim. Code: không còch $+21,3$ im — b test ly toịn b. Toàn: không còch nh — AUC 0,893 ly $+2,4$. **Nữt tht nm khóu SINH, khủng phi khóu CHN** (50–58% bị khủng ng thun, pool gn nh khủng cha ng viỏn ững).

Hai trn nh tuyền tòn c trở d liu §5.8: cng **theo artifact** (ch cho xem khi artifact ững — oracle): 0,7160 so vi I 0,6980 = **$+0,018$** ; b phón loi tht cn $\sim 89\%$ mi hoị vn. Router **bit-khi-I-sai** (oracle mnh hn): $+3,2$ im MATH — nhng ùi tồn hiu phòt hin *li ca chònh model mnh*, ững loi tồn hiu va chng minh li o c mị khủng đúng c. Kt lun thc tin: **khủng phi “lịm cng tt hn” — mị “mc nh ng cho xem”**.

6 Tng hp: nghch lý vị li gii

Nghch lý. §5.4: chỏnh lch nng lc ln $\Rightarrow +14,0$ im. §5.7: chỏnh lch nng lc ln $\Rightarrow \Delta_{\text{ceil}}$ óm. Cứng mt bin, hai du.

Li gii — hai giao thc, mt ng thc:

$$\begin{array}{ll} \text{Tuyền chn (verifier, 43:1):} & \text{value} \approx A \times \kappa - 0 \quad \rightarrow \text{chỏnh tng} \Rightarrow \text{giò tr } \mathbf{tng} \\ \text{Sa cha (V phi tr B):} & \text{value} = A - B + C \quad \rightarrow B \text{ tng nhanh hn } A \Rightarrow \text{giò tr } \mathbf{gim} \end{array}$$

Chỗnh lch nng lc nuũi $c \sim A \ln B$; giao thc quy t nh gt bốn nĩ. Sõu minh bng chng c lp hi t: (1) i s — ch-chn t $B \approx 0$ theo cu trũc; (2) $\ln$ — trũn MATH chỗnh $\ln$, B gp $\sim 11 \ln A$; (3) c ch — B lĩ thĩt hi do tip xũc ni dung sai, tin ng kỳ, hai min; (4) trũn — cng lc hoĩn ho ch thu $+0,018$ trũn nũ $-0,124$; (5) ngoi chng — tranh bin thua self-consistency vĩ sp model nh trong s liũ cũng b [ngũn]; (6) liũn min — quy lut MBPP d bõo c MATH $2/3$ cp.

Bc tranh cui lĩ mt **cũy quy t nh**:

- **Min cũ b kim ũng n** (code chy test): phi hp t ũng trũn oracle, 0 phũ — dũng, vĩ dũng dũg ch-chn.
- **Min khũng cũ**: b phiũ c hc ly phũn ln giũ tr ca vic sinh nhiũ lt; thĩnh phũn LLM tũg hp trung tũnh-n-hĩ; tũn hiũ hc c o c nhũg khũng dũng c.
- **Mĩ min**: ng cho model minh xem bị ca model yũ vĩ mc òch sa — nht lĩ khi chỗnh lch vt $\sim 0,09$; õ cũ model minh thũ gi thũg nũ.

Mt cũu: dũng model nh giũ, model $\ln$ sũt; sinh c lp ri chũn — ng a cho nhau sa.

7 Phũg phũp lun kho cu

Nhũm dũng hai chũn kim chũg b sung nhau: **thanh sai s theo fold** (khi vai trũ/chĩ phũ) vĩ **tin ng kỳ + iũ kin hp l + niũm phong hash** (khi lung thũng tin: bng dĩn giũ khoũ *trc* khi chy, cũ dĩng bũc b gi thũyt; hash artifact ghi trũ khi c s; VOID thũ khũng c). Cũc con s t nũĩ:

- **16/32 $\ln$ chy cũ tp kt qu mang trũg thũi VOID (50%)** — h iũ kin hp l ang lĩm ũng vic; 18 $\ln$ cũ niũm phong hash.
- **S dĩ oũn trũ cũũg khai: 21 ũng / 43** — ngĩ t gi thũyt oũn sai mt na; ú lĩ lý do phi khoũ dĩn giũ trũ khi thũ s.
- **Tũnh tt nh**: hai tĩ khũn, hai ngĩy, cũũg phũn cũg $\Rightarrow$ gĩng nhau 499/499 bị. Chũ li cũũg cu hũnh khũng phi bũg chũg c lp.
- **Rĩ li thũg kũĩ gia k**: ngũg “5 im” gc suy cho phũp o n l; vĩ 5 fold, chũn ũng lĩ t-test (ngũg hiũ dĩng $\sim 3,3$ im) kũĩm KTC vĩ xũc sut mt phũa $P(\text{hiũ ng} > 0)$. Rĩ 131 i lng: **bn kt qu ch lc u ng vũg** ($t = 3,3-6,9$; $P(> 0) = 98,5-99,9\%$); 6 kt qu c phũc hi *sau khi i chiũ c hp l* (thũg kũĩ khũng cu c $\ln$ chy vũ hiũ); 1 kt qu mt ý ngũa ($k = 3$ fold, $t_{\text{crit}} = 4,303$); 2 ca treo c phũn dĩt khoũt bũg dĩ liũ fold cũn trũn Kaggle — khũng cũn chy li. 131 phũp th $\Rightarrow$ k vũg $\sim 6,6$ dĩng tũnh gi [2]; cũc ca $p \in [0,02; 0,05]$ c vĩ dĩĩ dĩt tũg ng.

Phũn $\ln$ “cĩ thĩn” ghi nhũn ban u khũng sũg sũt qua kim chũg — ú lĩ mt kt qu, khũng phi mt thĩt bi.

8 Hũn ch

1. Δ_{honest} **cha cũ kt lun**. i lng trũn khai c thĩt õ qua nm $\ln$ chy u hũg vũ giũ hũn 14,6 GB ca GPU min phũ; phũn $\ln$ kt lun nh lng dĩa trũn cũn trũn Δ_{ceil} — vĩ mĩ cũn trũn ca dĩũg sa u óm hoc khũng dĩng cũ ý ngũa.
2. **Mũũ thun cha giũ**: hai $\ln$ chy 5 fold ca **A_gain** trũn MATH 1.5B cho dĩũ ngũc nhau ($-0,064$ vĩ $+0,080$; khũc c fold 100/40, cũ th khũc x lý `\boxed`). Con s $-6,4$ ch trũch kũĩm cũũ thũch nĩy cho tĩ khi giũ xũg.
3. Hai khi dũng hai chũn kim chũg, cha kim cũũ; xũt hp nht chũn cha c nhũm phũ dĩũt.

4. Tồnh chuyn min đa trồn 3 cp, KTC rng, 1/3 lch h thng; vúng dng ca quy lut chốnh **khũng th** xóc lp trồn MBPP (thiu lc ~ 8 ln).
5. κ cha gii c min khũng cú b kim ững n: ba tồn hui nh tuyen ỗ th u tht bi hoc trn quò thp (+0,018 / +3,2 u lị oracle).
6. Khi lung thũng tin ch đứg greedy — mi cu hnh mt im; khi vai trù cú fold bứ li.
7. Tp model b gii hn bi VRAM tng min phờ; phm vi khng nh: **model nh-n-trung (1,5B–32B) trồn bii toòn suy lun**; cha nú c v model rt ln.
8. §5.6 vị còc phón rỏ MBPP §5.8 lị mc B (o mt ln / hu nghim); token 1.5B trong hui chnh FLOP lị c lng t kỳ t (nhy ỗ quố t).

9 Kt lun

“a tồc t cú giúp khũng” khũng cú cớu tr li n — nhng cú cớu tr li **cú cu trức**. Di ba phỗp kim soồt, giò tr ca phi hp phón rỏ thnh ba tha s o c: d a H do chốnh lch nng lc quy nh; b chn κ do tồn ững n ca tồn hui quy nh; thit hi D do tip xức vi ni dung sai quy nh. Cứng mt chốnh lch nng lc nuũ c c hi ln thit hi — giao thc tuyen chn gt c hi, giao thc sa cha gồnh thit hi; vị giao thc sa, khi nhon k, lị mt ng đn ồp ồn ch khũng phi mt b sa li. Ni cú b kim ững n, phi hp chm trn oracle mị khũng phò mt bii nọ; ni khũng cú, cồch khũn ngoan lị sinh c lp, b phiu, vị ng còc model c bii ca nhau.

Tị liu

- [1] J. Austin et al. *Program Synthesis with Large Language Models*. arXiv:2108.07732, 2021.
- [2] Y. Benjamini, Y. Hochberg. *Controlling the False Discovery Rate*. JRSS-B 57(1), 1995.
- [3] M. Chen et al. *Evaluating Large Language Models Trained on Code*. arXiv:2107.03374, 2021.
- [4] K. Cobbe et al. *Training Verifiers to Solve Math Word Problems*. arXiv:2110.14168, 2021.
- [5] Y. Du et al. *Improving Factuality and Reasoning in Language Models through Multiagent Debate*. ICML, 2024.
- [6] Z. Gou et al. *CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing*. ICLR, 2024.
- [7] A. Grattafiori et al. *The Llama 3 Herd of Models*. arXiv:2407.21783, 2024.
- [8] D. Guo et al. *DeepSeek-Coder: When the Large Language Model Meets Programming*. arXiv:2401.14196, 2024.
- [9] D. Hendrycks et al. *Measuring Mathematical Problem Solving with the MATH Dataset*. NeurIPS, 2021.
- [10] J. Huang et al. *Large Language Models Cannot Self-Correct Reasoning Yet*. ICLR, 2024.
- [11] J. Kaplan et al. *Scaling Laws for Neural Language Models*. arXiv:2001.08361, 2020.
- [12] H. Lightman et al. *Let’s Verify Step by Step*. ICLR, 2024.
- [13] A. Madaan et al. *Self-Refine: Iterative Refinement with Self-Feedback*. NeurIPS, 2023.
- [14] L. S. Shapley. *A Value for n -Person Games*. Contributions to the Theory of Games II, 1953.
- [15] N. Shinn et al. *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS, 2023.
- [16] C. Snell et al. *Scaling LLM Test-Time Compute Optimally Can Be More Effective than Scaling Model Parameters*. arXiv:2408.03314, 2024.

- [17] X. Wang et al. *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. ICLR, 2023.
- [18] J. Wei et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.
- [19] A. Yang et al. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024.
- [20] L. Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS, 2023.

Ph lục (con tr ngun)

- A. Thut ng vị kỳ hiu — `report/THUAT_NGU.md` (chỗp mc 1–4 khi dng bn in).
- B. Trờch còc bn tin ng kỳ (#104, #106, #107, #112) — `docs/PREREGISTRATION.md`.
- C. Bng niỏm phong hash — `docs/RESULT_SEALS.md`.
- D. 16 ln chy VOID (trỏn 32) vị lý do.
- E. S d oỏn trc (21/43).
- F. 37 quy tc quy trỏnh — `docs/QUY_TRINH_VONG_LAP.md`.
- G. Bng kt qu y khi nhúm — `docs/RESULTS.md`.
- H. Phỏn tỏch Shapley theo vai — 29 tị li u trong `docs/`.
- I. Rị li thng kỏ gia k vị còc phỏn quy t — `CAU_HOI_THAO_LUAN.md` nhúm E, mc A6–A7.

Hỏnh d kin. (1) S khung $H \times \kappa - D$ + ònh x ba nhỏnh — *Nguyỏn*; (2) **ngch lý hai ng ngc chiu** (quan trng nht) — *Nguyỏn*; (3) Δ_{ceil} theo chỏnh lch, 15 im + g^* — *Tứng Dng*; (4) phỏn tng tip xữc 2×2 — *Tứng Dng*; (5) accuracy–chi phờ (trng s FLOP), cú im router — *Tứng Dng*; (6) bt i xng verifier, cú KTC — c ; (7) trn nh tuyền theo chỏnh xỏc b phỏn loi — *Tứng Dng*.