

Khi nào phối hợp đa tác tử LLM tạo ra giá trị?

Một khảo sát thực nghiệm dưới ba phép kiểm soát

Nguyễn

Đức

Tùng Dương*

Tháng 8, 2026

Tóm tắt nội dung

Các hệ đa tác tử LLM — planner–solver–verifier–aggregator, tranh biện, sinh-rồi-sửa — thường được báo cáo là cải thiện đáng kể so với một model đơn lẻ. Khảo sát này đo lại nhận định đó trên GSM8K, MATH-500, MBPP và HumanEval với Qwen2.5 (1.5B–32B), Llama-3.1-8B và DeepSeek-Coder-6.7B, dưới *ba phép kiểm soát* mà phần lớn báo cáo trong lĩnh vực bỏ qua: (1) **cùng ngân sách suy luận** — pipeline bốn vai tốn 2,9–6,6 lần chi phí một lượt giải, và token của các model khác cỡ không cùng đơn giá; (2) **đúng mốc so sánh** — người triển khai đã có model mạnh trong tay, nên đại lượng đúng là chênh lệch với *model mạnh chạy một mình* ($V - I$), không phải với model yếu ($V - S$); (3) **đúng mẫu số** — 57% số câu không thể chịu tác động của bất kỳ cơ chế phối hợp nào, khiến hiệu ứng thật bị pha loãng 3,3 lần.

Sau ba kiểm soát, bức tranh đảo chiều có hệ thống. Hiệu ứng dương lớn nhất (+14,0 điểm, 5/5 fold) chỉ tồn tại khi so với model yếu; so cùng chi phí FLOP với model mạnh đơn lẻ thì hoà hoặc kém. Nguyên nhân được định vị bằng một đẳng thức đại số $\Delta_{\text{ceil}} = A - B + C$ (khớp tuyệt đối 19/19 cặp đo) và một thí nghiệm tiền đăng ký tái lập trên hai miền: thiệt hại đến từ việc model mạnh **tiếp xúc với nội dung sai** — trên MATH, độ chính xác của nó rơi từ 46,4% xuống 19,2% trên tầng artifact sai (−27,2 điểm; $p \approx 0$), trong khi artifact đúng làm nó *khá lên* (+3,8 điểm; $p = 0,012$). Cùng một biến chênh lệch năng lực nuôi cả cơ hội (A) lẫn thiệt hại (B): giao thức **tuyển chọn** có $B \approx 0$ theo cấu trúc nên chênh lệch càng lớn càng thắng; giao thức **sửa chữa** phải trả B nên chênh lệch càng lớn càng thua — nghịch lý biểu kiến được giải trọn.

Ở miền có bộ kiểm **đúng dẫn** (code chạy test được), phối hợp đạt đúng trần oracle và không phá một bài nào trong 20/20 fold; ở miền không có, một bộ phân loại đạt AUC 0,893 vẫn chỉ đổi được +2,4 điểm — vì giá trị của mọi bộ kiểm bị chặn bởi khoảng cách $\text{oracle@k} - \text{maj@k}$, không bởi chất lượng tín hiệu. Khuyến nghị thực tiễn: *dùng model nhỏ để giải, model lớn để soát; sinh độc lập rồi chọn; đừng cho model mạnh xem bài làm của model yếu với mục đích sửa.*

1 Mở đầu

Ghép nhiều vai LLM thành một hệ có tạo thêm giá trị so với một model đơn lẻ không? Và nếu có, giá trị đến từ đâu — từ *cấu trúc phối hợp*, hay từ thứ khác đi kèm cấu trúc đó?

Câu hỏi khó trả lời hơn về ngoài, vì ba vấn đề đo lường.

Thứ nhất, ngân sách. Pipeline bốn vai $P \rightarrow S \rightarrow V \rightarrow A$ tốn 2,9 lần ký tự sinh trên GSM8K và 6,63 lần trên MATH so với một lượt giải (§5.1). So một hệ chi phí $3 \times$ với một hệ $1 \times$ rồi kết luận “phối hợp có giá trị” là so sánh khập khiễng. Tinh vi hơn: khi các vai dùng model *khác cỡ*, ngay cả số token cũng không cùng đơn vị — một token do model 7B sinh tốn $\sim 4,7\text{--}4,9$ lần FLOP so với token của model 1.5B, vì chi phí suy luận tỷ lệ với số tham số [11] (§5.5).

*Thứ tự tên và việc ghi nhận Quân: quyết ở Bước 0. Bản v1.0: §2 do Nguyễn chấp bút tạm, Đức rà và xác nhận trích dẫn; §4 Tùng Dương rà.

Thứ hai, mốc so sánh. Gần như toàn bộ dòng sinh-rồi-sửa đo cải thiện so với model *bị sửa* — tức model yếu ($V - S$). Nhưng lựa chọn thực của người triển khai, vốn đã có model mạnh trong pipeline, là: chạy pipeline, hay **gọi thẳng model mạnh** ($V - I$)? Khảo sát này cho thấy hai mốc đó cho **hai dấu ngược nhau** trên cùng một hệ (§5.5, §5.8).

Thứ ba, mẫu số. Phân tầng theo độ khó cho thấy 57% số câu nằm ngoài tầm với của mọi cơ chế phối hợp: 32% quá sức (không mẫu nào đúng — không có gì để chọn), 25% quá dễ (mọi mẫu đều đúng — không có gì để cải thiện). Hiệu ứng +31,1 điểm trên tầng khả tác động bị pha loãng thành +9,3 khi trung bình toàn tập (§5.3). Thiếu kiểm soát này, hiệu ứng thật bị đánh giá *thấp* — ngược chiều với hai kiểm soát trên.

Khảo sát hợp nhất ba nhánh nghiên cứu độc lập của nhóm — phân rã đóng góp theo vai bằng giá trị Shapley [14], phân tích chi phí-lợi ích của cơ chế định tuyến, và phân tích luồng thông tin của giao thức sửa chữa — dưới một khung duy nhất, và trình bày kết quả theo **mạch dẫn dắt**: mỗi thí nghiệm sinh ra từ câu hỏi mà thí nghiệm trước để lại.

Đóng góp.

1. Khung phân rã giá trị $\text{value} = H(\text{pool}) \times \kappa(z) - D(\text{protocol})$ thống nhất ba nhánh (§3).
2. Bằng chứng trên hai thiết kế độc lập rằng **chênh lệch năng lực** — không phải số lượng vai, danh tính vai, hay họ model — là biến quyết định (§5.4, §5.7).
3. Một **đẳng thức đại số** $\Delta_{\text{ceil}} = A - B + C$ tách cơ hội khỏi thiệt hại, khớp tuyệt đối trên 19/19 cặp đo (§3, §5.7).
4. Bằng chứng tiền đăng ký, tái lập hai miền: thiệt hại của giao thức sửa đến từ **tiếp xúc với nội dung sai**, không phải từ tiếp xúc; và giao thức sửa là **ống dẫn, không phải bộ sửa lỗi** — truyền đáp án đúng gần trọn vẹn (90,9%) nhưng gần như không sáng tạo lời giải mới (4,3%) và phá ở quy mô lớn (63,6% trên tầng rủi ro) (§5.8).
5. Giải nghịch lý “cùng biến, hai dấu” của chênh lệch năng lực (§6).
6. Một phát biểu định lượng về κ : giá trị của bộ kiểm bằng khoảng cách $\text{oracle}@k - \text{maj}@k$, không bằng chất lượng bộ kiểm — kèm hai trần định tuyến tính được (§5.10).
7. Một bộ quy trình chống tự đánh lừa (tiền đăng ký, điều kiện hợp lệ, niêm phong hash, sần nhiễu, t-test theo fold) mà **50% số lần chạy không vượt qua** — bản thân tỷ lệ đó là một kết quả (§7).

2 Công trình liên quan

Sinh-rồi-chọn. Chuỗi suy luận [18] mở đường cho self-consistency [17]: sinh k lời giải độc lập rồi bỏ phiếu đa số — chính là $\text{maj}@k$ của khảo sát này. Dòng chọn-bằng-bộ-kiểm gồm chấm theo quá trình [12] và mở rộng compute lúc suy luận [16]. Đặc điểm chung: giao thức *không cho phép tạo lời giải mới ở bước tổng hợp*, tức $B \approx 0$ theo thuật ngữ của chúng tôi.

Sinh-rồi-sửa. Self-Refine [13], Reflexion [15] và CRITIC [6] cho model đọc sản phẩm (của chính nó hoặc model khác) rồi sửa. Huang và cộng sự [10] chỉ ra LLM chưa tự sửa được suy luận khi thiếu tín hiệu ngoài — nhất quán với kết quả llm3 và phân tầng tiếp xúc của chúng tôi. **Điểm chúng tôi nhấn mạnh: các công trình dòng này chủ yếu báo cáo cải thiện so với model bị sửa hoặc lượt nháp đầu ($V - S$), không so với việc dùng thẳng model sửa ($V - I$) [Đ: rà từng bài, xác nhận mốc so sánh của từng bài — đây là chỗ luận điểm §1 đứng hoặc đổ].**

Đa tác tử và tranh biện. Tranh biện đa tác tử [5] và LLM-làm-giám-khảo [20] là các cơ chế phối hợp phổ biến. Tổng hợp số liệu công bố gần đây của nhóm [Đ: nguồn cụ thể] cho thấy tranh biện thua self-consistency ở đa số ô so sánh và **sụp 16 điểm** với Llama-3.1-8B trên GSM8K ($80,13 \rightarrow 63,87$) — khớp

với mẫu hình sụp đổ ở model nhỏ mà chúng tôi quan sát độc lập (§5.4). Hệ gần nhất về kiến trúc là MAS_RPSV (bốn vai nổi tiếp, cùng cỡ model, cùng benchmark) và SHARP — cùng dùng giá trị Shapley cho credit assignment, và báo cáo chỉ 12,96% lượt gọi subagent là hữu ích [Đ: xác nhận cả hai nguồn] — song song với kết quả “2/4 vai thực sự tính toán” của chúng tôi.

Vị trí của khảo sát. Chúng tôi không đề xuất kiến trúc mới; chúng tôi đề xuất **cách đo**: ba phép kiểm soát, một đẳng thức phân rã, và một khung ba thừa số — rồi dùng chúng để trả lời *khi nào* các kiến trúc trên tạo giá trị thật.

3 Khung lý thuyết

3.1 Phân rã giá trị

$$\text{value} = H(\text{pool}) \times \kappa(z) - D(\text{protocol}) \quad (1)$$

- H — **đur địa**: pool ứng viên có chứa lời giải mà model mạnh đơn lẻ không tạo ra được không? Đo bằng `oracle@k`.
- κ — **chất lượng bộ chọn**: một tín hiệu *khả thi* (không phải oracle) có lấy được lời giải đó ra khỏi pool không?
- D — **thiệt hại**: bản thân giao thức phá hỏng bao nhiêu?

Ba nhánh của nhóm đo ba thừa số: Shapley theo vai đo H ; router đo κ ; luồng thông tin đo D .

3.2 Đẳng thức phân rã

Ký hiệu (chú ý: *không* trùng với tên vai ở §4): S = model yếu giải bài; I = model mạnh giải bài, *không thấy gì của S*; V = **cùng model mạnh đó** nhưng ngữ cảnh có kèm bài làm của S . I và V là cùng một model — khác nhau ở **input**, nên $V - I$ cô lập đúng một biến: việc nhìn thấy bài làm của model yếu. Trần lý tưởng CEIL = đúng nếu S đúng **hoặc** V đúng — chính là `oracle@2` trên cặp $\{S, V\}$, tức chiến lược “ S đúng thì giữ S ” ở dạng hoàn hảo.

$$\Delta_{\text{ceil}} = \text{acc}(\text{CEIL}) - \text{acc}(I) = A - B + C \quad (2)$$

$A = P(S \text{ đúng} \wedge I \text{ sai})$	cơ hội có sẵn — tính chất của <i>cặp model</i>
$B = P(S \text{ sai} \wedge I \text{ đúng} \wedge V \text{ sai})$	giao thức phá bài I vốn đúng — tính chất của <i>giao thức</i>
$C = P(S \text{ sai} \wedge I \text{ sai} \wedge V \text{ đúng})$	giao thức cứu bài cả hai đều sai

Đây là đẳng thức đại số, không phải mô hình: khớp tuyệt đối trên 4/4 cặp có lưu vết và 15/15 cặp của thí nghiệm quy mô lớn. Giao thức **chỉ chọn** có $B \approx 0$ vì không thể tạo lời giải sai mới; giao thức **sửa** luôn phải trả B . Δ_{ceil} là *chặn trên sàng lọc* (cần đáp án chuẩn, không triển khai được): $\Delta_{\text{ceil}} < 0 \Rightarrow$ đóng hướng ngay — không cổng nào cứu nổi; $\Delta_{\text{ceil}} > 0 \Rightarrow$ mới được hỏi tiếp về κ . Con số triển khai là $\Delta_{\text{honest}} = \text{acc}(V) - \text{acc}(I)$.

3.3 Ba mệnh đề

- M1.** D là hàm của tiếp xúc với **nội dung sai**, không phải của tiếp xúc (§5.8).
- M2.** κ phụ thuộc tín hiệu là **đúng dẫn** hay **học được** — không phụ thuộc mạnh hay độc lập. (Đã qua hai lần thu hẹp từ bản gốc “độc lập thẳng tương quan”; §5.10.)
- M3.** Định tuyến tiết kiệm ở đúng nơi ít cần tiết kiệm nhất (§5.6).

4 Thiết lập thí nghiệm

[TD: rà toàn bộ mục này]

Model. Qwen2.5-Instruct 1.5B/7B/14B/32B [19]; Llama-3.1-8B-Instruct [7]; DeepSeek-Coder-6.7B-Instruct [8]. Lượng tử hoá **đo từng model, không suy theo họ**: DeepSeek-6.7B nạp nf4 hết 3,61 GB; Qwen-7B 5,21 GB; Llama-8B và Qwen-14B *không* lượng tử hoá được trên bản chạy (fp16 ~16/28 GB). Phần cứng: Kaggle 2×T4 (nf4/fp16) và RTX 6000 Pro 95 GB (bf16); so sánh chéo lần chạy chỉ hợp lệ khi trùng cả (phần cứng + độ chính xác số) lần bộ bài — đo được nf4 so với bf16 dịch kết quả tới 0,03.

Benchmark. GSM8K [4]; MATH-500 [9]; MBPP [1] — dải chính `task_id` 11–510 (~499 bài sau lọc chuẩn), dải giữ lại 511–974 (464 bài); HumanEval [3]. **MBPP/HumanEval có bộ kiểm đúng dẫn** (chạy test); MATH/GSM8K không — khác biệt này quyết định kết luận §5.10.

Vai và chi phí. P planner, S solver, V verifier, A aggregator; tổ hợp $PS, PSV, PSVA, SVV, \dots$. Chi phí báo theo **lượt gọi** và theo **token/ký tự**; khi các vai khác cỡ model, quy thêm về **chi phí trọng số FLOP** (tham số $\times$ token).

Giải mã và tính tắt định. Khối luồng thông tin dùng greedy (`do_sample=False`): cùng cấu hình cho kết quả **giống hệt từng bài** (kiểm 499/499 giữa hai tài khoản, hai ngày). Hệ quả: chạy lại cùng cấu hình không phải bằng chứng độc lập; dao động giữa các fold đến từ *khác bài*, không phải nhiễu lấy mẫu.

Thống kê. Khối vai trò/chi phí: 5 fold rời nhau; sần nhiễu hiệu chuẩn bằng cách chạy cùng cấu hình trên 5 fold (V_{gain} dao động $+1,0 \dots +8,0$; std giữa fold 2,65); suy diễn bằng t-test trên fold ($SE = s/\sqrt{k}$; $t_{0,975}(4) = 2,776$), KTC 95%, và phép thử dấu (5/5 cùng dấu $\Rightarrow p = 0,031$ một phía). Khối luồng thông tin: McNemar chính xác ghép cặp trên cùng bộ bài; bootstrap ghép cặp theo chỉ số bài (10 000 lần). Ngưỡng diễn giải được **khoá trước khi chạy** trong bảng tiền đăng ký, gồm dòng bác bỏ giả thuyết.

5 Hành trình thực nghiệm

Trình bày theo mạch: mỗi mục mở bằng câu hỏi kế thừa, đóng bằng câu hỏi để lại. Số liệu mức A trừ khi ghi khác.

5.1 Pipeline có giúp không — và sần nhiễu định hình mọi thứ

Task	Solver	Pipeline	Chênh	Chi phí ký tự
GSM8K	0,632	0,744	+0,112	$2,9\times$
MATH	0,405	0,345	−0,060	6,63 $\times$

Bảng 1: Pipeline đầy đủ so với solver đơn lẻ (Qwen-1.5B).

Trên GSM8K có lợi (5 fold: $PSVA - PS = +5,6$; KTC $[+3,3; +7,9]$; $t = 6,89$); trên MATH **tốn 6,63 lần để kém hơn 6 điểm**. Phép hiệu chuẩn sần nhiễu — cùng cấu hình, 5 fold — cho V_{gain} từ $+1,0$ đến $+8,0$: một phép đo đơn lẻ 100 bài gần như không mang thông tin, và mọi hiệu ứng từ đây đi kèm KTC.

Câu hỏi để lại: phần lợi có phải do phối hợp, hay chỉ do được sinh nhiễu lượt?

Bộ tổng hợp (8 lượt sinh)	MATH 1.5B	MATH 7B
greedy (1 lượt)	0,50	0,72
maj@8 — bỏ phiếu	0,60	0,73
llm_agg@8 — LLM tổng hợp	0,41	0,47
oracle@8 — trần	0,73	0,85

Bảng 2: Cùng ngân sách 8 lượt sinh, chỉ đổi bộ tổng hợp.

5.2 Kiểm soát ngân sách: giá trị nằm ở lượt sinh, không ở vai tổng hợp

Cùng chi phí, thành phần LLM tổng hợp kém bỏ phiếu 19–26 điểm; ở 7B kém cả greedy một lượt. Nó phá đa số đúng 21/26 lần, sửa được đa số sai 2/0 lần. Kết quả **phụ thuộc task** (vote5 – llm_agg: +0,075 MATH, –0,056 GSM8K) — phát biểu đúng: *bộ tổng hợp LLM không mang giá trị ổn định; ở miền khó nó gây hại đáng kể*.

Hai đối chứng tách nốt:

- **rerun = loop** (0,453 = 0,453): giải lại *không xem* phê bình của verifier cho kết quả bằng chính xác giải lại *có* phê bình. Lợi ích đến từ **lượt sinh thêm**, không từ nội dung phản hồi. (Con số +20 đo một lần không tái lập: 5 fold còn +4,0.) Biến thể vòng lặp giải-rồi-chấm rỏ hơn pipeline đủ vai lại **thắng nó** trên MATH: loop – PSVA = +4,0; KTC [+0,5; +7,5]; $t = 3,21$ — cùng chi phí (4,2 so với 4,0 lượt).
- **Aggregator không chọn — nó chép**. 65% số câu nó chép nguyên ứng viên *cuối cùng*; đọc 600 trace: 100% lượt không sinh số mới. **Nhưng phần “gây hại” phải dính chính**: 85% số ca phá trên MATH là *không phát ra \boxed{}* — lỗi định dạng; chỉ 5% chọn nhầm thật. Thêm fallback miễn phí: A_gain từ –6,4 thành +1,0 [0; +2]. Bộ tổng hợp LLM *trung tính một khi xử lý xong định dạng* — không cộng giá trị, nhưng “phá hoại” phần lớn là hiện vật đo lường. (Một mâu thuẫn chưa giải giữa hai lần chạy 5 fold của chính đại lượng này — –6,4 và +8,0, mỗi bên nhất quán nội bộ — xem §8.)

Câu hỏi để lại: mọi can thiệp đều cho 0–5 điểm — có phải đang đo sai mẫu số?

5.3 Kiểm soát mẫu số: 57% số câu bất động

Mẫu đúng /5	n	Solver	vote5	Δ
0/5 — quá sức	48 (32%)	0,000	0,000	0,000
1/5	20	0,000	0,000	0,000
2/5	15	0,333	0,600	+0,267
3/5	12	0,583	1,000	+0,417
4/5	18	0,722	1,000	+0,278
5/5 — quá dễ	37 (25%)	1,000	1,000	0,000

Bảng 3: Phân tầng theo số mẫu đúng trong 5 lượt (MATH 1.5B, $n = 150$).

57% số câu không thể có hiệu ứng vì lý do toán học. Trên tầng khả tác động: +21,5 điểm (nhóm 1–4/5, cách nhóm của tài liệu nguồn) hay +31,1 (nhóm 2–4/5, loại tầng hiệu ứng bằng 0); trung bình toàn tập pha loãng còn +9,3. Một can thiệp +10 điểm thật sẽ hiện ra +3 — dưới sàn nhiễu, và bị kết tội oan là vô dụng. Ba kiểm soát tác động **ngược chiều**: thiếu mẫu số $\Rightarrow$ đánh giá thấp; thiếu ngân sách/mốc $\Rightarrow$ đánh giá cao.

Câu hỏi để lại: trong phần khả tác động, vai nào đóng góp?

5.4 Vai trò: chuyên biệt hoá sụp đổ; biến thật là năng lực của lượt kiểm

Chỉ số **hành vi** từ trace: ở 1.5B, planner — bị cấm tính đáp án — chứa sẵn đáp án ở 34,7% câu MATH (45,3% có \boxed); solver không sinh số mới ở 60,7–62% lượt, lời giải dài **19 ký tự** khi có plan (664 khi

không). Nó không giải — nó chép. Ở 7B, hai vai hồi phục (rò đáp án 1,0–4,0%) — nhưng ở mức đó pipeline lại thua solver đơn lẻ. Đối chứng nhân quả: **hoán vị prompt giữa các vị trí** (normal/swap/solo) cho accuracy không phân biệt được — GSM8K 0,660 = 0,660, solo 0,673; MATH swap-normal = +5,3 nhưng $t = 1,84$, KTC $[-2,7; +13,4]$ — không đạt. **Danh tính vai không phải biến.**

Biến thật là **năng lực của model ở lượt thứ hai**. Cùng 300 bài MATH (5 fold $\times$ 60):

Lượt kiểm	Hiệu ứng	KTC 95%	Sửa : Phá
Verifier 7B (solver 1.5B)	+14,0	[+7,4; +20,6]	43 : 1
Verifier 1.5B (cùng cỡ)	+3,0	chạm 0	15 : 6
Riêng phần do lớn hơn	+11,0	[+3,9; +18,1]	—

Bảng 4: Bất đối xứng năng lực ở lượt kiểm, MATH.

Cơ chế từ trace: khi can thiệp, verifier **tái sử dụng 0%** số liệu của solver — nó không dò từng bước, nó **giải lại từ đầu**. Verifier là một solver thứ hai đội lốt bộ kiểm; mua verifier 7B là mua một solver tốt hơn cho lượt thứ hai. Phù hợp: V_{gain} có ý nghĩa ở cả MATH 7B (+4,4; KTC $[+1,5; +7,3]$) — giá trị verifier xuất hiện cùng năng lực; ở MATH 1.5B thì không (+1,4; $p = 0,235$).

Câu hỏi để lại: +14,0 là so với model yếu. So đúng mức thì sao?

5.5 Kiểm soát mức so sánh và đơn giá token: cấu hình bất đối xứng bị chi phối

Cấu hình	GSM8K	MATH	Token GSM8K	Token MATH
S1.5B + V7B	0,810	0,563	105k	119k
S7B một mình	0,910	0,593	120k	152k
S7B + V7B	0,900	0,670	205k	261k

Bảng 5: Token đo thật, 5 fold. Cột token không so được trực tiếp giữa hai cỡ model — xem hiệu chỉnh bên dưới.

So với S7B đơn lẻ: bất đối xứng kém 10 điểm trên GSM8K; hoà trên MATH (chênh theo fold chứa 0). Cột token có **hai lỗi chồng nhau**: (a) trường đo gốc chỉ đếm token do 7B sinh, bỏ sót token của solver 1.5B; (b) token 7B đắt $\sim 4,7\text{--}4,9$ lần token 1.5B. Quy về trọng số FLOP (tham số $\times$ token; độ nhạy chars/token 3,0–4,0):

	Token thô 7B	Trọng số FLOP
GSM8K: asym / S7B	0,88 — “rẻ hơn 12%”	1,00–1,05 — tiết kiệm biến mất
MATH: asym / S7B	0,78 — “rẻ hơn 22%”	0,92–0,96 — còn 3–8%

Bảng 6: Hiệu chỉnh đơn giá token. Chưa tính prefill (7B còn phải đọc bài của 1.5B) nên hiệu chỉnh vẫn thiên vị cho cấu hình bất đối xứng.

Kết luận: **trên GSM8K cấu hình bất đối xứng bị chi phối hoàn toàn** (kém 10 điểm, không rẻ hơn); trên MATH là tiết kiệm *biên* với độ chính xác hoà. Solver đơn lẻ nằm trên đường Pareto ở cả hai task; pipeline đầy đủ không nằm trên đường Pareto ở MATH. Cải thiện thật duy nhất trong bảng: thêm V7B vào chính S7B trên MATH: +7,7 ($p = 0,0075$) — với giá $1,7\times$ token.

Đây là dạng tổng quát của vấn đề mốc: $V - S$ dương, $V - I$ âm — **cùng hệ, hai mốc, hai kết luận ngược nhau**, lặp lại ở mọi nhánh của khảo sát.

Câu hỏi để lại: giá trị mất đi đâu? (Từ đây dùng đẳng thức §3.2.)

5.6 Định tuyến: tiết kiệm ở nơi ít cần nhất (mức B — đo một lần, $n = 300$)

Consensus router (chạy S, V ; bắt đồng mới gọi A): GSM8K đạt 0,7200 với chi phí 2,32 lượt — giữ 94% phần lợi của pipeline (0,7233; 3 lượt) với 77% chi phí; MATH đạt 0,4133 — **đúng bằng solver đơn lẻ**, vô

dụng. Cơ chế: khi $S-V$ bất đồng, A cứu 45,4% trường hợp trên GSM8K nhưng 25,0% trên MATH. Mệnh đề M3: định tuyến chỉ trả tiền ở nơi đã sẵn đồng thuận. (Vì sao MATH tệ hơn — trả lời ở §5.8: model yếu sai nhiều hơn $\Rightarrow$ tiếp xúc nội dung sai nhiều hơn.)

5.7 Số hạng A : chênh lệch năng lực, không phải họ model — và quy luật của Δ_{ceil}

Quan sát thô trên 7 cặp gộp nhiều lần chạy: cặp *khác họ* có dư địa A cao gần gấp đôi (0,0597 so với 0,0481) — nhưng các cặp khác họ cũng có chênh lệch năng lực nhỏ hơn (0,130 so với 0,167); hai biến trộn hoàn toàn. Thiết kế tách (tiền đăng ký): **6 model, 15 cặp có hướng, cùng 499 bài MBPP, một lần chạy**, bổ sung đúng các ô còn thiếu:

$$A = \beta_0 + \beta_1 \cdot \text{chênh} + \beta_2 \cdot \text{khác_họ}$$

$$\beta_1 = -0,1922 \ (p \approx 0) \quad \beta_2 = +0,0045, \text{ KTC } 95\% [-0,0051; +0,0140], \ p = 0,31$$

R^2 chỉ với chênh lệch = 0,824. KTC của β_2 nằm **tròn dưới** ngưỡng +0,02 đã khoá trước — **null có thông tin**: “khác họ” là tương quan giả; biến thật là chênh lệch năng lực. (Kết quả đa dạng pool — 3 model cho 2,70/3 ứng viên phân biệt so với 1,91/3 khi lấy mẫu cùng model; 36,2% $\rightarrow$ 6,5% số bài chỉ một ứng viên — được ghi là “khác **model**”: đối chứng khác-model-cùng-họ chưa chạy.)

Thêm nhánh sửa cho cả 15 cặp (tiền đăng ký) cho quy luật:

$$\Delta_{\text{ceil}} = +0,0218 - 0,2392 \times \text{chênh}; \quad R^2 = 0,60; \ p = 10^{-5}; \ g^* \approx 0,09 \quad (3)$$

Đăng thức $A - B + C$ khớp 15/15. Đọc kèm bắt buộc: **0/15 cặp dương có ý nghĩa; 3/15 âm có ý nghĩa** $\Rightarrow$ chỉ phát biểu **chiều phủ định**: *chênh lệch vượt $\sim 0,09$ thì dừng dùng giao thức sửa*. Xác lập vùng dương cần $\sim 8 \times$ toàn bộ MBPP — bất khả thi trên benchmark này. Chênh giải thích 82% phương sai của A nhưng chỉ 35% của B . (Ghi chú cơ chế, mức B : ngưỡng bảo toàn mà V phải vượt tăng theo chênh với hệ số 2,18 — nhanh gấp đôi khả năng bảo toàn thực của nó, hệ số 1,10; chênh lệch hệ số $p = 0,0066$. Giao thức sửa chết vì số học ngân sách, không phải vì model mạnh “yếu bóng vía”.)

Câu hỏi để lại: B do đâu mà có?

5.8 Số hạng B : hình phạt của nội dung sai — và giao thức sửa là ống dẫn

Thiết kế sạch nhất (tiền đăng ký; MATH-500 để **đối miên** so với quan sát thăm dò gốc trên MBPP): hai nhánh dùng **cùng một lệnh giải**, khác duy nhất việc ngữ cảnh có kèm bài làm của model yếu; phân tầng theo **nội dung** bài làm đó:

	MBPP 11–510 (mức B)	MBPP 511–974 (mức B)	MATH-500 (mức A)
Artifact sai	−0,1900	−0,1927	− 0,2720 ($p \approx 0$; $n = 261$)
Artifact đúng	+0,0636	+0,0245	+ 0,0377 ($p = 0,012$; $n = 239$)

Bảng 7: Hiệu ứng của việc nhìn thấy artifact, phân tầng theo nội dung. Kết quả trung tâm.

Trên tầng artifact sai, model mạnh rơi **46,4% $\rightarrow$ 19,2%** — trên chính những bài nó vốn giải được gần một nửa; artifact đúng làm nó khá lên. Tổng hợp trọng số tái tạo *chính xác* $V - I = -0,1240$. **D không phải hình phạt của việc nhìn thấy — mà của việc nhìn thấy nội dung sai**; và vì thiết kế không có lệnh sửa, *riêng nhìn thấy đã đủ gây hại*.

Bảng $2 \times 2 \times 2$ đầy đủ (chấm lại từ trace) trả lời câu hỏi tự nhiên “*khi I sai thì sửa có giúp không?*”:

Ba đọc số: (1) **giao thức sửa là ống dẫn, không phải bộ sửa lỗi** — truyền đáp án đúng của S gần trọn vẹn (90,9%), gần như không sáng tạo lời giải mới (4,3%), phá ở quy mô lớn (63,6%); (2) tầng khai thác được nhỏ hơn tầng rủi ro **11 lần** (11 so với 121 bài); (3) “giữ nguyên S khi S đúng” chính là oracle CEIL — và tầng không oracle đó cũng chỉ thêm +0,004 trên MATH (đúng 2 bài/500), vì V vốn đã giữ được 99,6%/90,9%; kể cả vậy CEIL = 0,578 vẫn thua $I = 0,698$. **Không cấu hình nào có $V > I$** trong toàn bộ khảo sát (0/15 cặp MBPP; tốt nhất −0,030). Vấn đề không phải “quên giữ S ” — mà là V phá tầng (S sai, I đúng), và cách duy nhất bảo vệ tầng đó là *dừng cho xem*.

Tầng	n	V đúng
S đúng, I đúng	228	99,6%
S đúng , I sai	11	90,9%
S sai, I đúng (<i>vùng rủi ro</i>)	121	36,4% — tức phá 63,6%
Cả hai sai	140	4,3%

Bảng 8: Bảng $2 \times 2 \times 2$ trên MATH ($n = 500$).

Đây cũng là lời giải cho §5.6: aggregator vô dụng trên MATH vì ở đó model yếu sai nhiều hơn — tỷ lệ tiếp xúc nội dung sai cao hơn (45,4% so với 25,0% khớp hướng; mức B).

5.9 Tính chuyển miền của quy luật chênh lệch

Dùng đường khớp **trên MBPP** dự báo Δ_{ceil} **trên MATH** (tiền đăng ký; 3 cặp Qwen; mọi điều kiện hợp lệ đạt; KTC bootstrap ghép cặp 10 000 lần):

Cặp	Chênh	Đo được	KTC 95%	MBPP dự báo	
7B→14B	0,044	-0,0140	[-0,046; +0,018]	+0,0108	trong khoảng
1.5B→7B	0,244	-0,1660	[-0,208; -0,124]	-0,0361	ngoài
1.5B→14B	0,288	-0,0680	[-0,102; -0,034]	-0,0471	trong khoảng

Bảng 9: Thử điểm tính chuyển miền của quy luật chênh lệch.

2/3 dự báo trong khoảng $\Rightarrow$ quy luật **không bị bác bỏ** trên miền toán (không viết “đã xác nhận”: KTC rộng 0,064–0,084 nên phép kiểm có độ phân giải thấp). Cặp lệch lệch **hệ thống** — $B = 0,208$, gấp mười lần A — và tái lập một phép đo độc lập trên cùng cặp ($-0,1380 \rightarrow -0,1660$): quy luật mô tả xu hướng; ngoại lệ ở nơi model yếu quá yếu so với bài.

5.10 κ : đúng dẫn đạt trần oracle; học được thì “đo được $\neq$ dùng được”

Tín hiệu đúng dẫn — HumanEval, cùng model, cùng 4 lượt sinh, khác duy nhất nguồn kiểm; tái lập trên 4 cấu hình $\times 2$ hệ phần cứng:

Ô	greedy	exec3	11m3	exec3 phá	11m3 phá
HE 1.5B (Kaggle)	0,5375	0,6000	0,4812	0,0	2,8
HE 1.5B (5090)	0,5625	0,6438	0,4375	0,0	4,6
HE 7B (5090)	0,8000	0,8812	0,7812	0,0	2,6
HE 7B (Kaggle)	0,7938	0,9000	0,7438	0,0	3,2

Bảng 10: Kiểm bằng chạy test (exec3) so với LLM tự kiểm (11m3).

exec3 **phá 0 bài trong 20/20 fold** và đạt đúng oracle@4 ở hai ô có ghi số; 11m3 phá ở cả 20 fold. Mốc trung thực là greedy — bỏ phiếu **có hại trên code** ($-0,113/-0,131$; lời giải dài hiểm trùng): $\text{exec3} - \text{greedy} = +0,063 \rightarrow +0,106$. Giới hạn: khi model nền bão hoà (GSM8K 7B, solver 0,916), bộ kiểm thực thi chính xác 0,837 vẫn **lỗ ròng** (26 phá / 6 sửa).

Tín hiệu học được — bộ phân loại huấn luyện trên lỗi tiềm (đổi một chữ số trong lời giải đúng), cả hai ô hợp lệ:

Ở 7B nó học rất tốt, chuyển giao còn tốt hơn trong phân phối — nhưng AUC 0,893 chỉ mua được +2,4 điểm. **Đo được $\neq$ dùng được**. Phát biểu hợp nhất, nổi bốn thí nghiệm:

Giá trị của một bộ kiểm bằng khoảng cách $\text{oracle@}k - \text{maj@}k$, không bằng chất lượng bộ kiểm. Code: khoảng cách +21,3 điểm — bộ test lấy toàn bộ. Toán: khoảng cách nhỏ —

Model	Lỗi tiềm	Lỗi thật	AUC	Đổi thành độ chính xác
1.5B	-0,012	+0,195	0,528	-0,008 (1/5 fold)
7B	+0,573	+0,693	0,893	+0,024 (2/5 fold)

Bảng 11: Bộ phân loại học được: đo được rất tốt, gần như không dùng được.

AUC 0,893 lấy +2,4. **Nút thắt nằm ở khâu SINH, không phải khâu CHỌN** (ở 50–58% bài không đồng thuận, pool gần như không chứa ứng viên đúng).

Hai trần định tuyến tính được trên dữ liệu §5.8: cổng **theo artifact** (chỉ cho xem khi artifact đúng — oracle): 0,7160 so với I 0,6980 = **+0,018**; bộ phân loại thật cần ~89% mới hoà vốn. Router **biết-khi-I-sai** (oracle mạnh hơn): +3,2 điểm MATH — nhưng đòi tín hiệu phát hiện *lỗi của chính model mạnh*, đúng loại tín hiệu vừa chứng minh là đo được mà không dùng được. Kết luận thực tiễn: **không phải “làm công tốt hơn” — mà “mặc định đừng cho xem”**.

6 Tổng hợp: nghịch lý và lời giải

Nghịch lý. §5.4: chênh lệch năng lực lớn $\Rightarrow +14,0$ điểm. §5.7: chênh lệch năng lực lớn $\Rightarrow \Delta_{\text{ceil}}$ âm. Cùng một biến, hai dấu.

Lời giải — hai giao thức, một đẳng thức:

Tuyển chọn (verifier, 43:1): $\text{value} \approx A \times \kappa - 0 \rightarrow$ chênh tăng $\Rightarrow$ giá trị **tăng**
 Sửa chữa (V phải trả B): $\text{value} = A - B + C \rightarrow B$ tăng nhanh hơn $A \Rightarrow$ giá trị **giảm**

Chênh lệch năng lực nuôi **cả** A **lẫn** B ; giao thức quyết định gặt bên nào. Sáu mảnh bằng chứng độc lập hội tụ: (1) đại số — chỉ-chọn đặt $B \approx 0$ theo cấu trúc; (2) độ lớn — trên MATH ở chênh lớn, B gấp ~11 lần A ; (3) cơ chế — B là thiệt hại do tiếp xúc nội dung sai, tiền đăng ký, hai miền; (4) trần — cổng lọc hoàn hảo chỉ thu +0,018 trên nền -0,124; (5) ngoại chứng — tranh biện thua self-consistency và sụp ở model nhỏ trong số liệu công bố **[Đ: nguồn]**; (6) liên miền — quy luật MBPP dự báo được MATH ở 2/3 cặp.

Bức tranh cuối là một **cây quyết định**:

- **Miền có bộ kiểm đúng đắn** (code chạy test): phối hợp đạt đúng trần oracle, 0 phá — dùng, và dùng dạng chỉ-chọn.
- **Miền không có**: bỏ phiếu cơ học lấy phần lớn giá trị của việc sinh nhiều lượt; thành phần LLM tổng hợp trung tính-đến-hại; tín hiệu học được đo được nhưng không dùng được.
- **Mọi miền**: đừng cho model mạnh xem bài của model yếu với mục đích sửa — nhất là khi chênh lệch vượt ~0,09; đã có model mạnh thì gọi thẳng nó.

Một câu: dùng model nhỏ để giải, model lớn để soát;
 sinh độc lập rồi chọn — đừng đưa cho nhau sửa.

7 Phương pháp luận khảo cứu

Nhóm dùng hai chuẩn kiểm chứng bổ sung nhau: **thanh sai số theo fold** (khối vai trò/chi phí) và **tiền đăng ký + điều kiện hợp lệ + niêm phong hash** (khối luồng thông tin: bảng diễn giải khoá *trước* khi chạy, có dòng bác bỏ giả thuyết; hash artifact ghi trước khi đọc số; VOID thì không đọc). Các con số tự nói:

- **16/32 lần chạy có tệp kết quả mang trạng thái VOID (50%)** — hệ điều kiện hợp lệ đang làm đúng việc; 18 lần có niêm phong hash.
- **Số dự đoán trước công khai: 21 đúng / 43** — người đặt giả thuyết đoán sai một nửa; đó là lý do phải khoá diễn giải trước khi thấy số.

- **Tính tất định:** hai tài khoản, hai ngày, cùng phần cứng $\Rightarrow$ giống nhau 499/499 bài. Chạy lại cùng cấu hình không phải bằng chứng độc lập.
- **Rà lại thống kê giữa kỳ:** ngưỡng “5 điểm” gốc suy cho phép đo đơn lẻ; với 5 fold, chuẩn đúng là t-test (ngưỡng hiệu dụng $\sim 3,3$ điểm) kèm KTC và xác suất một phía $P(\text{hiệu ứng} > 0)$. Rà 131 đại lượng: **bốn kết quả chủ lực đều đứng vững** ($t = 3,3-6,9$; $P(> 0) = 98,5-99,9\%$); 6 kết quả được phục hồi *sau khi đối chiếu cờ hợp lệ* (thống kê không cứu được lần chạy vô hiệu); 1 kết quả mất ý nghĩa ($k = 3$ fold, $t_{\text{crit}} = 4,303$); 2 ca treo được phán dứt khoát bằng dữ liệu fold còn trên Kaggle — không cần chạy lại. 131 phép thử $\Rightarrow$ kỳ vọng $\sim 6,6$ dương tính giả [2]; các ca $p \in [0,02; 0,05]$ đọc với đề đặt tương ứng.

Phần lớn “cải thiện” ghi nhận ban đầu không sống sót qua kiểm chứng — đó là một kết quả, không phải một thất bại.

8 Hạn chế

1. Δ_{honest} **chưa có kết luận.** Đại lượng triển khai được thật đã qua năm lần chạy đều hỏng vì giới hạn 14,6 GB của GPU miễn phí; phần lớn kết luận định lượng dựa trên chặn trên Δ_{ceil} — và mọi chặn trên của dòng sửa đều âm hoặc không dương có ý nghĩa.
2. **Mâu thuẫn chưa giải:** hai lần chạy 5 fold của A_{gain} trên MATH 1.5B cho dấu ngược nhau ($-0,064$ và $+0,080$; khác cỡ fold 100/40, có thể khác xử lý `\boxed`). Con số $-6,4$ chỉ trích kèm chú thích này cho tới khi giải xong.
3. Hai khối dùng hai chuẩn kiểm chứng, chưa kiểm chéo; đề xuất hợp nhất chuẩn chưa được nhóm phê duyệt.
4. Tính chuyển miền dựa trên 3 cặp, KTC rộng, 1/3 lệch hệ thống; vùng dương của quy luật chênh **không thể** xác lập trên MBPP (thiếu lực ~ 8 lần).
5. κ chưa giải được ở miền không có bộ kiểm đúng dẫn: ba tín hiệu định tuyến đã thử đều thất bại hoặc trần quá thấp ($+0,018 / +3,2$ đều là oracle).
6. Khối luồng thông tin chỉ dùng greedy — mỗi cấu hình một điểm; khối vai trò có fold bù lại.
7. Tập model bị giới hạn bởi VRAM tăng miễn phí; phạm vi khẳng định: **model nhỏ-đến-trung (1,5B–32B) trên bài toán suy luận**; chưa nói được về model rất lớn.
8. §5.6 và các phân rã MBPP ở §5.8 là mức B (đo một lần / hậu nghiệm); token 1.5B trong hiệu chỉnh FLOP là ước lượng từ ký tự (độ nhảy đã quét).

9 Kết luận

“Đa tác tử có giúp không” không có câu trả lời đơn — nhưng có câu trả lời **có cấu trúc**. Dưới ba phép kiểm soát, giá trị của phối hợp phân rã thành ba thừa số đo được: dư địa H do chênh lệch năng lực quyết định; bộ chọn κ do tính đúng đắn của tín hiệu quyết định; thiệt hại D do tiếp xúc với nội dung sai quyết định. Cùng một chênh lệch năng lực nuôi cả cơ hội lẫn thiệt hại — giao thức tuyển chọn gặt cơ hội, giao thức sửa chữa gánh thiệt hại; và giao thức sửa, khi nhìn kỹ, là một ống dẫn đáp án chứ không phải một bộ sửa lỗi. Nơi có bộ kiểm đúng dẫn, phối hợp chạm trần oracle mà không phá một bài nào; nơi không có, cách khôn ngoan là sinh độc lập, bỏ phiếu, và dùng để các model đọc bài của nhau.

Tài liệu

- [1] J. Austin et al. *Program Synthesis with Large Language Models*. arXiv:2108.07732, 2021.
- [2] Y. Benjamini, Y. Hochberg. *Controlling the False Discovery Rate*. JRSS–B 57(1), 1995.

- [3] M. Chen et al. *Evaluating Large Language Models Trained on Code*. arXiv:2107.03374, 2021.
- [4] K. Cobbe et al. *Training Verifiers to Solve Math Word Problems*. arXiv:2110.14168, 2021.
- [5] Y. Du et al. *Improving Factuality and Reasoning in Language Models through Multiagent Debate*. ICML, 2024.
- [6] Z. Gou et al. *CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing*. ICLR, 2024.
- [7] A. Grattafiori et al. *The Llama 3 Herd of Models*. arXiv:2407.21783, 2024.
- [8] D. Guo et al. *DeepSeek-Coder: When the Large Language Model Meets Programming*. arXiv:2401.14196, 2024.
- [9] D. Hendrycks et al. *Measuring Mathematical Problem Solving with the MATH Dataset*. NeurIPS, 2021.
- [10] J. Huang et al. *Large Language Models Cannot Self-Correct Reasoning Yet*. ICLR, 2024.
- [11] J. Kaplan et al. *Scaling Laws for Neural Language Models*. arXiv:2001.08361, 2020.
- [12] H. Lightman et al. *Let’s Verify Step by Step*. ICLR, 2024.
- [13] A. Madaan et al. *Self-Refine: Iterative Refinement with Self-Feedback*. NeurIPS, 2023.
- [14] L. S. Shapley. *A Value for n -Person Games*. Contributions to the Theory of Games II, 1953.
- [15] N. Shinn et al. *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS, 2023.
- [16] C. Snell et al. *Scaling LLM Test-Time Compute Optimally Can Be More Effective than Scaling Model Parameters*. arXiv:2408.03314, 2024.
- [17] X. Wang et al. *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. ICLR, 2023.
- [18] J. Wei et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.
- [19] A. Yang et al. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024.
- [20] L. Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS, 2023.

Phụ lục (con trở nguồn)

- A. Thuật ngữ và ký hiệu — `report/THUAT_NGU.md` (chép mục 1–4 khi dựng bản in).
- B. Trích các bản tiền đăng ký (#104, #106, #107, #112) — `docs/PREREGISTRATION.md`.
- C. Bảng niêm phong hash — `docs/RESULT_SEALS.md`.
- D. 16 lần chạy VOID (trên 32) và lý do.
- E. Sổ dự đoán trước (21/43).
- F. 37 quy tắc quy trình — `docs/QUY_TRINH_VONG_LAP.md`.
- G. Bảng kết quả đầy đủ khối nhóm — `docs/RESULTS.md`.
- H. Phân tích Shapley theo vai — 29 tài liệu trong `docs/`.
- I. Rà lại thống kê giữa kỳ và các phán quyết — `CAU_HOI_THAO_LUAN.md` nhóm E, mục A6–A7.

Hình dự kiến. (1) Sơ đồ khung $H \times \kappa - D$ + ánh xạ ba nhánh — *Nguyễn*; (2) **ngịch lý hai đường ngược chiều** (quan trọng nhất) — *Nguyễn*; (3) Δ_{ceil} theo chênh lệch, 15 điểm + g^* — *Tùng Dương*; (4) phân tầng tiếp xúc 2×2 — *Tùng Dương*; (5) accuracy–chi phí (trọng số FLOP), có điểm router — *Tùng Dương*; (6) bất đối xứng verifier, có KTC — *Đức*; (7) trần định tuyến theo độ chính xác bộ phân loại — *Tùng Dương*.