

Khi nào phối hợp đa tác tử LLM tạo ra giá trị?

Một khảo sát thực nghiệm dưới ba phép kiểm soát

Nguyễn

Đức

Tùng Dương

Tháng 8, 2026

Tóm tắt nội dung

Các hệ nhiều tác tử ngôn ngữ lớn — một model lập kế hoạch, một model giải, một model kiểm tra, một model tổng hợp — thường được báo cáo là vượt trội so với một model chạy một mình. Khảo sát này đo lại nhận định đó trên bốn benchmark suy luận (GSM8K, MATH-500, MBPP, HumanEval) với các model 1,5–32 tỷ tham số, dưới ba phép kiểm soát mà phần lớn báo cáo trong lĩnh vực bỏ qua: so ở cùng chi phí tính toán; so với model mạnh chạy một mình thay vì với model yếu; và chỉ tính trên những câu mà phối hợp còn có thể tạo khác biệt.

Sau ba phép kiểm soát, phần lớn hiệu ứng dương biến mất hoặc đổi dấu. Hiệu ứng dương lớn nhất (mười bốn điểm phần trăm) chỉ tồn tại khi so với model yếu; so cùng chi phí với model mạnh chạy một mình thì hoà hoặc thua. Thí nghiệm chính — tiền đăng ký, tái lập trên hai miền — định vị được nguồn thiệt hại: khi model mạnh nhìn thấy một bài làm *sai* của model yếu, độ chính xác của nó rơi từ 46% xuống 19% trên chính những bài nó vốn giải được, trong khi bài làm đúng giúp nó tốt lên nhẹ. Hệ quả là một nghịch lý biểu kiến được giải: chênh lệch năng lực giữa hai model làm giao thức “sửa bài của nhau” ngày càng thua, nhưng lại làm phép so-với-model-yếu ngày càng đẹp — cùng một biến, hai dấu, tùy mốc so sánh.

Về phía bộ kiểm: nơi có cách kiểm chắc chắn (code chạy được test), phối hợp đạt đúng trần lý tưởng và không phá bài nào khi model chưa bão hoà; nơi không có, một bộ phân loại lỗi rất tốt (AUC 0,893) cũng chỉ đổi được hơn hai điểm — khoảng cách giữa trần lý tưởng và bộ phiếu đa số là chặn trên mà không tín hiệu học được nào trong khảo sát vượt qua. Toàn bộ quy trình dùng tiền đăng ký và điều kiện hợp lệ; một nửa số lần chạy không vượt qua và bị loại trước khi đọc số.


1 Mở đầu

Ghép nhiều model ngôn ngữ thành một hệ — model này lập kế hoạch, model kia giải, model khác kiểm tra — có tốt hơn để một model mạnh tự làm không? Trực giác nói có: nhiều mắt hơn thì soát được nhiều lỗi hơn. Phần lớn báo cáo trong lĩnh vực cũng nói có.

Hãy bắt đầu bằng một quan sát cụ thể làm lung lay trực giác đó. Lấy các bài MATH mà Qwen-7B tự giải được gần một nửa (46,4%). Giữ nguyên model, giữ nguyên lệnh giải, chỉ thêm vào ngữ cảnh một thứ: bài làm *sai* của Qwen-1.5B cho đúng bài đó. Độ chính xác rơi xuống 19,2% — model mạnh giải sai chính những bài nó vốn giải được, chỉ vì nhìn thấy một lời giải sai (Hình 1, chi tiết ở §5.8). Ngược lại, nếu bài làm kèm theo là bài *đúng*, model mạnh tốt lên nhẹ. Tức là “cho các model xem bài của nhau” không trung tính: nó là con dao hai lưỡi mà lưỡi hại sắc hơn lưỡi lợi nhiều lần.

Vì sao hiệu ứng lớn như vậy mà các báo cáo “phối hợp giúp X điểm” hiếm khi thấy nó? Vì ba vấn đề đo lường, và chúng là trục của khảo sát này.

Thứ nhất, chi phí. Một pipeline bốn vai sinh ra lượng chữ gấp 2,9 lần (GSM8K) đến 6,6 lần (MATH) so với một lượt giải — đo trên model 1,5B; các cỡ khác chúng tôi chưa đo. So một hệ đắt gấp ba với một hệ chạy một lượt rồi kết luận “phối hợp có giá trị” là so hai hệ ở hai mức ngân sách. Tinh vi hơn: khi các vai dùng model *khác* cỡ, ngay cả số token cũng không cùng đơn giá — một token do model 7B sinh tốn khoảng 4,7–4,9 lần phép tính (FLOP) so với token của model 1,5B, vì chi phí suy luận tỷ lệ với số tham số [11] (§5.4).



Hình 1: Thí nghiệm tiếp xúc (tiền đăng ký, MATH-500): hai nhánh chỉ khác nhau ở việc ngữ cảnh có kèm bài làm sai của model yếu hay không. Chênh lệch $-27,2$ điểm ($p \approx 0$) là nguồn thiệt hại chính của các giao thức cho model sửa bài của nhau (§5.8).

Thứ hai, mốc so sánh. Gần như toàn bộ dòng “sinh rồi sửa” đo cải thiện so với model *bị sửa* — tức model yếu. Nhưng người triển khai vốn đã có model mạnh trong pipeline; lựa chọn thực của họ là: chạy giao thức sửa, hay gọi thẳng model mạnh? Khảo sát này cho thấy hai mốc đó cho hai dấu ngược nhau trên cùng một hệ (§5.4, §6).

Thứ ba, mẫu số. Trên MATH với model 1,5B, 57% số câu nằm ngoài tầm với của mọi cơ chế chọn-trong-pool: 32% quá khó (không lượt giải nào đúng — không có gì để chọn), 25% quá dễ (mọi lượt đều đúng — không có gì để cải thiện). Một can thiệp thật $+10$ điểm trên phần còn lại sẽ hiện ra chỉ $+3$ điểm khi trung bình toàn tập — dưới sàn nhiều, và có nguy cơ bị kết luận nhầm là vô dụng (§5.5). Thiếu kiểm soát này thì *đánh giá thấp*; thiếu hai kiểm soát trên thì *đánh giá cao* — ba sai lệch không cùng chiều.

Đóng góp. Khảo sát hợp nhất ba nhánh nghiên cứu của nhóm — phân rõ đóng góp theo vai, phân tích chi phí–lợi ích của định tuyến, và phân tích luồng thông tin — dưới một khung đo duy nhất. Bốn đóng góp chính:

1. **Ba phép kiểm soát** (chi phí quy về FLOP, mốc so sánh là model mạnh đơn lẻ, mẫu số khả tác động) và bằng chứng rằng khi áp đủ ba, phần lớn hiệu ứng dương của phối hợp biến mất hoặc đổi dấu (§5).
2. **Thí nghiệm tiếp xúc** tiền đăng ký, tái lập hai miền (Hình 1): thiệt hại của giao thức sửa đến từ việc nhìn thấy *nội dung sai*, không phải từ việc nhìn thấy; và giao thức sửa hoạt động như *ông dẫn dắt án* hơn là bộ sửa lỗi (§5.8).
3. **Lời giải cho nghịch lý “cùng biến, hai dấu”**: chênh lệch năng lực giữa hai model làm phép so-với-model-yếu ngày càng đẹp nhưng làm giá trị thật (so với model mạnh) ngày càng âm — nghịch lý nằm ở mốc so sánh, không ở cơ chế (§6).
4. **Một chặn trên cho giá trị của bộ kiểm**: không vượt quá khoảng cách giữa trần lý tưởng và bộ phiếu đa số trên cùng pool; tín hiệu kiểm *chắc chắn* (chạy test) lấy gần trọn chặn này, tín hiệu *học được* chỉ lấy một phần nhỏ dù đo lỗi rất tốt (§5.9).

Toàn bộ số liệu đi kèm quy trình chống tự đánh lừa (tiền đăng ký, điều kiện hợp lệ, niêm phong kết quả) mô tả ở §4; 50% số lần chạy không vượt qua điều kiện và bị loại trước khi đọc số.

2 Công trình liên quan

Sinh rồi chọn. Chuỗi suy luận [18] mở đường cho self-consistency [17]: sinh nhiều lời giải độc lập rồi bỏ phiếu đa số — chính là mốc $maj@k$ của khảo sát này (định nghĩa ở §4). Dòng chọn–bảng–bộ–kiểm gồm chấm theo quá trình [12] và mở rộng compute lúc suy luận [16]. Đặc điểm chung của cả lớp: bước tổng

hợp chỉ *chọn* trong các lời giải đã sinh, không tạo lời giải mới — nên theo phân rã ở §3.2, lớp này không thể tự phá bài đúng.

Sinh rồi sửa. Self-Refine [13], Reflexion [15] và CRITIC [6] cho model đọc sản phẩm (của chính nó hoặc model khác) rồi sửa. Huang và cộng sự [10] chỉ ra LLM chưa tự sửa được suy luận khi thiếu tín hiệu ngoài — nhất quán với kết quả của chúng tôi ở §5.9. Theo rà soát sơ bộ của chúng tôi, phần lớn công trình dòng này báo cáo cải thiện so với model bị sửa hoặc lượt nháp đầu, không so với việc dùng thẳng model sửa [Đ: rà từng bài, xác nhận mốc so sánh của từng bài — đây là chỗ luận điểm §1 đứng hoặc đổ].

Đa tác tử và tranh biện. Tranh biện đa tác tử [5] và LLM-làm-giám-khảo [20] là các cơ chế phối hợp phổ biến. Tổng hợp số liệu công bố gần đây của nhóm [Đ: nguồn cụ thể] cho thấy tranh biện thua self-consistency ở đa số ô so sánh và giảm 16 điểm với Llama-3.1-8B trên GSM8K — nhất quán với mẫu hình suy giảm ở model nhỏ mà chúng tôi quan sát độc lập (§5.3). Hai hệ gần nhất về kiến trúc và phương pháp là MAS_RPSV (bốn vai nối tiếp, cùng benchmark) và SHARP (cùng dùng giá trị Shapley cho phân bổ đóng góp) [Đ: xác nhận cả hai nguồn; chưa có mục thư mục].

Vị trí của khảo sát. Chúng tôi không đề xuất kiến trúc mới; chúng tôi đề xuất *cách đo*: ba phép kiểm soát, một đẳng thức phân rã, và một khung ba thừa số — rồi dùng chúng để trả lời *khi nào* các kiến trúc trên tạo giá trị thật.

3 Phương pháp đo lường

Mục này xây dựng dần bộ công cụ đo, mỗi khái niệm được định nghĩa trước khi dùng.

3.1 Ba câu hỏi, một khung

Muốn biết một cơ chế phối hợp có tạo giá trị không, cần trả lời ba câu hỏi độc lập:

- **Dư địa** (H): pool các lời giải đã sinh có *chứa* lời giải mà model mạnh đơn lẻ không tạo ra được không? Nếu không, mọi cách chọn đều vô ích.
- **Bộ chọn** (κ): một tín hiệu *khả thi* (không cần biết đáp án) có nhặt được lời giải đó ra khỏi pool không?
- **Thiệt hại** (D): bản thân giao thức có phá hỏng những bài vốn đã đúng không?

Giá trị rỗng chỉ dương khi dư địa có thật, bộ chọn nhặt được, và thiệt hại nhỏ hơn phần nhặt được. Ba nhánh nghiên cứu của nhóm đo ba thừa số này. Khung này là ngôn ngữ tổ chức của báo cáo, không phải mô hình dự báo; công cụ định lượng kiểm được nằm ở tiểu mục sau.

3.2 Thí nghiệm tiếp xúc và đẳng thức phân rã

Xét một cặp model: model yếu và model mạnh (ví dụ Qwen-1.5B và Qwen-7B). Ký hiệu ba “nhân vật” — chúng tôi cố ý dùng chữ cái khác hẳn tên vai $P/S/V/A$ ở §4 để tránh lẫn:

- W — model yếu giải bài; bài làm của nó gọi là *artifact*.
- I — model mạnh giải bài, **độc lập**, không thấy gì của W .
- E — **cùng model mạnh đó**, cùng lệnh giải, nhưng ngữ cảnh có kèm artifact của W (bị *tiếp xúc*).

I và E là một model, khác duy nhất ở đầu vào — nên hiệu $\text{acc}(E) - \text{acc}(I)$ cô lập đúng một biến: việc nhìn thấy bài làm của model yếu. Đây là đại lượng *triển khai được* (không cần biết đáp án), ký hiệu Δ_{thuc} .

Trần lý tưởng của mọi cách phối hợp giữa W và E là: đúng nếu W đúng *hoặc* E đúng (tức có một giám khảo biết đáp án chọn hộ). Gọi nó là TRAN. So trần đó với model mạnh đơn lẻ:

$$\Delta_{\text{tran}} = \text{acc}(\text{TRAN}) - \text{acc}(I) = G - L + R, \quad (1)$$

với ba số hạng đọc bằng lời như sau:

$G = P(W \text{ đúng} \wedge I \text{ sai})$	cơ hội — tính chất của <i>cặp model</i>
$L = P(W \text{ sai} \wedge I \text{ đúng} \wedge E \text{ sai})$	thiệt hại : phá bài vốn đúng — của <i>giao thức</i>
$R = P(W \text{ sai} \wedge I \text{ sai} \wedge E \text{ đúng})$	cứu : giải được bài cả hai đều trượt

Đẳng thức (1) là đại số thuần túy, một dòng khai triển: $P(W \vee E) - P(I) = P(W \wedge \neg I) - P(\neg W \wedge I \wedge \neg E) + P(\neg W \wedge \neg I \wedge E)$. Ví dụ bằng số: trong 100 bài, nếu 15 bài W đúng mà I sai ($G=0,15$), 20 bài W sai, I đúng nhưng E hỏng ($L=0,20$), 5 bài cả hai sai mà E cứu ($R=0,05$), thì $\Delta_{\text{tran}} = 0,15 - 0,20 + 0,05 = 0$: trần lý tưởng cũng chỉ hoà model mạnh đơn lẻ. Vì là đẳng thức, việc nó “khớp” dữ liệu (4/4 cặp có lưu vết ở khối thăm dò, 15/15 cặp ở thí nghiệm chính — gộp là 19/19) chỉ chứng tỏ sổ sách không có lỗi, không phải bằng chứng cho giả thuyết nào.

Hai lưu ý về phạm vi của Δ_{tran} . *Một*, nó cần đáp án chuẩn nên không triển khai được; vai trò của nó là **sàng lọc**: $\Delta_{\text{tran}} < 0$ thì mọi cách chọn giữa W và E đều vô vọng, khởi hồi tiếp về κ . *Hai*, nó chỉ chặn lớp cơ chế chọn giữa W và E sau khi đã cho tiếp xúc; các cơ chế quyết định có cho tiếp xúc hay không nằm ngoài lớp này và có trần riêng (đo ở §5.9).

3.3 Hai lớp giao thức và biến “chênh lệch năng lực”

Chúng tôi phân hai lớp giao thức bằng một tiêu chí vận hành: đầu ra cuối có buộc phải là một phần tử của pool đã sinh hay không.

- **Tuyển chọn**: đầu ra phải nằm trong pool (bỏ phiếu đa số, chọn bằng test). Lớp này có $L = 0$ theo cấu trúc — không thể tạo lời giải sai mới.
- **Sửa chữa**: lượt sau được phép sinh chuỗi mới (verifier can thiệp, giao thức tiếp xúc). Lớp này luôn phải trả L ; nhỏ hay lớn là chuyện thực nghiệm — verifier 7B trả L rất nhỏ nhưng khác 0 (1/300 bài, §5.3), giao thức tiếp xúc trả L lớn (§5.8).

Chênh lệch năng lực (gọi tắt: *chênh*) giữa hai model là hiệu độ chính xác một lượt giải (greedy) của model mạnh trừ model yếu, trên cùng benchmark, thang 0–1. Ví dụ cặp 1.5B→7B trên MBPP có chênh 0,244. Đây là biến giải thích chính trong các thí nghiệm của chúng tôi; ký hiệu g^* dành cho mức chênh mà tại đó đường khớp của Δ_{tran} đổi dấu (§5.6).

4 Thiết lập thí nghiệm và quy trình

[TD: rà toàn bộ mục này]

Model. Qwen2.5-Instruct 1.5B/7B/14B/32B [19]; Llama-3.1-8B-Instruct [7]; DeepSeek-Coder-6.7B-Instruct [8]. Sáu model này lập thành 15 cặp có hướng của thí nghiệm §5.6; các khối còn lại dùng Qwen 1.5B/7B/14B. Lượng tử hoá đo từng model, không suy theo họ: DeepSeek-6.7B nạp nf4 hết 3,61 GB; Qwen-7B 5,21 GB; Llama-8B và Qwen-14B không lượng tử hoá được trên bản chạy (fp16 ~16/28 GB). Phần cứng: Kaggle 2×T4 (nf4/fp16) và RTX 6000 Pro (bf16). Đo được nf4 so với bf16 dịch kết quả tới 3 điểm — cùng cỡ với ngưỡng ý nghĩa hiệu dụng (~3,3 điểm, xem Thống kê) — nên so sánh chéo phần cứng chỉ đọc theo dấu, và mọi so sánh định lượng đều trong cùng (phần cứng + độ chính xác số + bộ bài).

Benchmark. GSM8K [4]; MATH-500 [9]; MBPP [1] (dải chính task_id 11–510, ~499 bài sau lọc; dải giữ lại 511–974, 464 bài); HumanEval [3]. Điểm mẫu chốt cho §5.9: MBPP/HumanEval có cách kiểm *chắc chắn* (chạy test — lời giải qua test là bằng chứng trực tiếp), còn MATH/GSM8K không có.

Vai và pipeline. Bốn vai: P (planner — lập dàn ý), S (solver — giải), V (verifier — kiểm và được phép sửa), A (aggregator — nhận nhiều ứng viên, chọn đáp án cuối); các tổ hợp viết liền, ví dụ PSVA là pipeline đủ bốn vai. Lưu ý các chữ này chỉ *vai trong pipeline*; ba nhân vật $W/I/E$ và ba số hạng $G/L/R$ ở §3.2 là bộ ký hiệu riêng của thí nghiệm tiếp xúc.

Bộ tổng hợp và các mốc. Với k lượt giải độc lập cho một bài: $\text{maj}@k$ = lấy đáp án xuất hiện nhiều nhất (bỏ phiếu đa số); $\text{oracle}@k$ = đúng nếu ít nhất một lượt đúng (trần lý tưởng của mọi cách chọn trong pool — cần đáp án chuẩn, chỉ dùng làm trần); $\text{llm_agg}@k$ = một lượt LLM đọc cả k ứng viên rồi chọn/tổng hợp. Ví dụ: 5 lượt cho đáp án $\{7, 7, 7, 12, 15\}$, đáp án chuẩn 12 — $\text{maj}@5$ chọn 7 (sai), $\text{oracle}@5$ đúng (vì có một lượt ra 12). Trên code, $\text{exec}k$ = chạy test với từng ứng viên, lấy ứng viên qua test (tín hiệu chắc chắn); $\text{llm}k$ = để LLM tự duyệt thay vì chạy test (tín hiệu học được).

Đại lượng dẫn xuất. V_{gain} = độ chính xác pipeline có V trừ pipeline cùng cấu hình bỏ V ; A_{gain} tương tự cho A . AUC (diện tích dưới đường ROC) đo khả năng một bộ phân loại tách lời giải đúng khỏi lời giải sai: 0,5 = đoán ngẫu nhiên, 1,0 = hoàn hảo.

Quy ước đơn vị. Độ chính xác viết ở thang 0–1; hiệu ứng viết bằng “điểm” = điểm phần trăm (+14,0 điểm = +0,140); “chênh” cũng là hiệu accuracy, thang 0–1 (chênh 0,09 $\approx$ 9 điểm). Chi phí có ba thang không thay thế được cho nhau: *ký tự sinh* (đo thô), *token*, và *FLOP* (tham số $\times$ token) — chỉ thang FLOP so được giữa hai cỡ model; tỷ số chi phí viết kèm dấu $\times$ (ví dụ 0,88 $\times$) để không lẫn với accuracy.

Giải mã và tính tất định. Khối luồng thông tin dùng greedy ($\text{do_sample}=\text{False}$): cùng cấu hình cho kết quả giống hệt từng bài (kiểm 499/499 giữa hai tài khoản, hai ngày). Hệ quả: chạy lại cùng cấu hình không phải bằng chứng độc lập; dao động giữa các fold đến từ *khác bài*, không phải nhiễu lấy mẫu.

Thống kê. Khối vai trò/chi phí dùng 5 fold rời nhau (mỗi fold 60–100 bài). Sàn nhiễu được hiệu chuẩn bằng cách đo cùng cấu hình trên 5 fold: V_{gain} dao động +1,0 đến +8,0 điểm, độ lệch chuẩn giữa fold 2,65 điểm — một phép đo đơn lẻ 100 bài gần như không mang thông tin. Suy diễn bằng t-test trên fold ($\text{SE} = s/\sqrt{k}$; $t_{0,975}(4) = 2,776$, tức ngưỡng hiệu dụng $\sim 3,3$ điểm), khoảng tin cậy 95% (KTC), và phép thử dấu (5/5 fold cùng dấu $\Rightarrow p = 0,031$ một phía). Khối luồng thông tin dùng McNemar chính xác ghép cặp trên cùng bộ bài và bootstrap ghép cặp (10 000 lần). Với 131 phép thử toàn dự án, kỳ vọng $\sim 6,6$ dương tính giả [2]; các $p \in [0,02; 0,05]$ đọc đề đặt tương ứng.

Nhãn tin cậy và quy trình. *Mức A* = tiền đăng ký với điều kiện hợp lệ, hoặc 5 fold kèm t-test; *mức B* = đo một lần hoặc phân rã hậu nghiệm — chỉ dùng minh họa cơ chế. Mọi thí nghiệm khối luồng thông tin khoá bằng diễn giải *trước* khi chạy (kèm dòng bác bỏ giả thuyết); kết quả niêm phong hash trước khi đọc; lần chạy không đạt điều kiện hợp lệ bị đánh dấu VOID và không đọc số. Thành tích của bộ lọc này: 16/32 lần chạy VOID (50%); số dự đoán trước công khai đoán đúng 21/43 — người đặt giả thuyết đoán sai một nửa, đó chính là lý do phải khoá diễn giải trước khi thấy số. Trong lần rà giữa kỳ trên 131 đại lượng: bốn kết quả chủ lực của khối fold (+14,0, +11,0, +5,6, +4,4 — xem §5) giữ ý nghĩa ($t = 3,3\text{--}6,9$); kết quả +7,7 của khối McNemar cũng giữ ($p = 0,0075$); 6 kết quả được phục hồi sau khi đối chiếu cờ hợp lệ; 1 mất ý nghĩa ($k=3$ fold); 2 ca treo được phán bằng dữ liệu fold còn trên Kaggle, không cần chạy lại.

5 Kết quả

*Phân kết quả chia hai hồi. **Hồi I** (§5.1–5.5) áp lần lượt ba phép kiểm soát và cho thấy bức tranh “phối hợp giúp X điểm” thay đổi thế nào sau mỗi phép. **Hồi II** (§5.6–5.9) định vị giá trị còn lại bằng ba thừa số G , L , κ . Số liệu ở mức A trừ khi ghi khác (§4).*

5.1 Điểm xuất phát: pipeline có giúp không, và nhiễu lớn cỡ nào

Bảng 1 là bức tranh trước mọi kiểm soát: trên GSM8K pipeline hơn 11,2 điểm, trên MATH nó tốn chi phí gấp 6,63 lần để kém hơn 6 điểm. Hai chú thích đọc bảng. Thứ nhất, kiểm định thống kê dùng một đại lượng gần nhưng không trùng: trên 5 fold, $\text{PSVA} - \text{PS} = +5,6$ điểm (KTC [+3,3; +7,9]; $t = 6,89$) — phần lợi trên GSM8K là thật; con số MATH là phép đo một lần, chưa có KTC theo fold. Thứ hai, phép hiệu chuẩn sàn nhiễu (§4) cho thấy một phép đo 100 bài dao động tới 7 điểm — từ đây mọi hiệu ứng đều đi kèm KTC.

Task	Solver 1 lượt	Pipeline PSVA	Chênh lệch	Ký tự sinh
GSM8K	0,632	0,744	+11,2 điểm	2,9×
MATH	0,405	0,345	−6,0 điểm	6,63×

Bảng 1: Pipeline đủ bốn vai so với một lượt giải (Qwen-1.5B; đo một lần trên toàn tập).

Bộ tổng hợp (cùng 8 lượt sinh)	MATH 1.5B	MATH 7B
<i>tham chiếu: greedy 1 lượt</i>	0,50	0,72
ma j@8 — bỏ phiếu	0,60	0,73
llm_agg@8 — LLM tổng hợp	0,41	0,47
oracle@8 — trần lý tưởng	0,73	0,85

Bảng 2: Đối bộ tổng hợp ở cùng ngân sách 8 lượt sinh (hàng đầu là mốc 1 lượt để so).

Mục tiếp theo áp phép kiểm soát thứ nhất: phần lợi này đến từ phối hợp, hay chỉ từ việc được sinh nhiều lượt hơn?

5.2 Kiểm soát chi phí: giá trị nằm ở lượt sinh, không ở vai tổng hợp

Bảng 2 giữ nguyên ngân sách và chỉ đổi *cách tổng hợp*. Ba điều đọc ra:

Một, thành phần LLM tổng hợp kém bỏ phiếu 19–26 điểm ở cùng chi phí; ở 7B nó kém cả greedy một lượt. Nó phá đa số đúng 21 lần (1.5B) và 26 lần (7B), sửa được đa số sai 2 và 0 lần. Hành vi từ 600 trace: 65% số câu nó chép nguyên ứng viên *cuối cùng* — gần một quy tắc theo vị trí hơn một bộ chọn theo nội dung; 100% lượt không sinh số mới.

Hai, lợi ích của bỏ phiếu co lại theo năng lực model nền: ở 1.5B, ma j@8 lấy +10 điểm trong dư địa 23 điểm (oracle@8 − greedy), tức 43%; ở 7B chỉ lấy +1 điểm trong dư địa 13 điểm (8%). Khoảng cách oracle@8 − ma j@8 — 13 điểm ở 1.5B, 12 điểm ở 7B — sẽ được dùng lại ở §5.9 làm chặn trên cho mọi bộ kiểm.

Ba, hai đối chứng tách phần “phối hợp” ra khỏi phần “thêm lượt”:

- rerun = loop (0,453 = 0,453): giải lại *không xem* phê bình của verifier cho kết quả bằng đúng giải lại *có xem*. Lợi ích đến từ lượt sinh thêm, không từ nội dung phản hồi. (Một phép đo đơn lẻ trước đó cho +20 điểm nhưng không tái lập: trên 5 fold còn +4,0 điểm.) Biến thể vòng lặp giải-rời-chấm rẻ hơn pipeline đủ vai còn thắng nó trên MATH: +4,0 điểm (KTC [+0,5; +7,5]; $t = 3,21$) ở cùng chi phí.
- Phần “gây hại” của aggregator chủ yếu là hiện vật đo: chỉ 73–81% lượt tổng hợp phát ra đáp án trong khung `\boxed{ }` để chấm được; thêm fallback miễn phí (thiếu khung thì lấy đáp án verifier, không gọi thêm model) đưa A_gain trên MATH 1.5B từ −6,4 điểm về +0,8 điểm (theo fold: 0; +1; 0; +2; +2 — không fold nào âm). Một lần chạy khác (bộ bài khác, không lượng tử hoá) cho +8,0 điểm; sau khi vá định dạng, hai ước lượng cùng phía không-âm, phần chênh còn lại quy cho khác bộ bài và khác độ chính xác số (mức B).

Sau kiểm soát chi phí, thứ duy nhất chắc chắn có giá trị là “thêm lượt sinh độc lập”. Mục tiếp theo hỏi: các lượt đó nên do vai gì, model cỡ nào đảm nhiệm?

5.3 Vai trò: danh tính vai không đo được tác động; năng lực lượt kiểm thì có

Chỉ số hành vi từ trace ở 1.5B cho thấy “chuyên biệt hoá vai” phần lớn là danh nghĩa: planner — bị cấm tính đáp án — vẫn chứa sẵn đáp án ở 34,7% câu MATH; solver khi có plan chỉ sao chép (lời giải dài 19 ký tự, so với 664 khi không có plan). Ở 7B hai vai hồi phục (rò đáp án 1–4%) — nhưng ở mức đó pipeline lại thua solver đơn lẻ. Đối chứng nhân quả bằng hoán vị prompt giữa các vị trí cho accuracy không phân biệt được: GSM8K 0,660 = 0,660 (solo 0,673); MATH swap − normal = +5,3 điểm nhưng $t = 1,84$,

Lượt kiểm	Hiệu ứng (điểm)	KTC 95% (điểm)	Sửa : Phá
Verifier 7B (solver 1.5B)	+14,0	[+7,4; +20,6]	43 : 1
Verifier 1.5B (cùng cỡ)	+3,0	KTC chứa 0	15 : 6
Phần riêng do cỡ model lớn hơn	+11,0	[+3,9; +18,1]	—

Bảng 3: Bất đối xứng năng lực ở lượt kiểm trên MATH. “Sửa : Phá” = số bài sai được sửa thành đúng so với số bài đúng bị phá thành sai; verifier cùng cỡ phá 6 bài so với 1 bài của verifier 7B trên cùng 300 bài.

Cấu hình	GSM8K	MATH	Token 7B, GSM8K	Token 7B, MATH
S1.5B + V7B	0,810	0,563	105k	119k
S7B một mình	0,910	0,593	120k	152k
S7B + V7B	0,900	0,670	205k	261k

Bảng 4: So đúng mốc: các cấu hình lượt kiểm so với model mạnh chạy một mình (5 fold). Cột token chỉ đếm token do model 7B sinh — không so được trực tiếp giữa cấu hình khác cỡ model; hiệu chỉnh ở Bảng 5.

KTC $[-2,7; +13,4]$ — không đạt ý nghĩa, và vì KTC rộng, phép thử này *không đủ lực loại trừ* một hiệu ứng cỡ vừa; chúng tôi chỉ ghi nhận là không tìm thấy bằng chứng.

Biến đo được tác động rõ là **năng lực của model ở lượt kiểm**. Cùng 300 bài MATH (5 fold $\times$ 60), Bảng 3:

Cơ chế từ trace: khi can thiệp, verifier tái sử dụng 0% số liệu trung gian của solver — nó không dò từng bước mà *giải lại từ đầu*. Về hành vi, lượt kiểm là một lượt giải thứ hai; điều này *nhất quán* với giả thuyết rằng +14,0 chủ yếu là lợi ích của việc thêm một lượt giải bằng model mạnh hơn (đối chứng tách hẳn hai khả năng — thêm lượt 7B *không* kèm bài của solver trên cùng 300 bài — chúng tôi chưa chạy). Nhất quán cùng hướng: V_{gain} có ý nghĩa ở MATH 7B (+4,4 điểm; KTC $[+1,5; +7,3]$) nhưng không ở MATH 1.5B (+1,4; $p = 0,235$). Lưu ý cho §3.3: verifier *sinh chuỗi mới* nên thuộc lớp sửa chữa — L của nó đo được là $1/300 \approx 0,003$, rất nhỏ nhưng không phải 0 theo cấu trúc.

Con số +14,0 đang so với model yếu. Mục tiếp theo áp phép kiểm soát thứ hai và thứ nhất cùng lúc: so đúng mốc model mạnh, ở đúng đơn giá token.

5.4 Kiểm soát mốc so sánh và đơn giá token

Bảng 4 đổi mốc từ “model yếu” sang “model mạnh một mình” và bức tranh đổi theo. Cấu hình bất đối xứng S1.5B+V7B — chính cấu hình cho +14,0 ở Bảng 3 — *kém S7B đơn lẻ 10 điểm* trên GSM8K và hoà trên MATH. Cột chi phí cần hai hiệu chỉnh: (a) cột token gốc bỏ số token của solver 1.5B; (b) token 7B đắt 4,7–4,9 lần token 1.5B theo FLOP. Bảng 5 quy về thang FLOP:

Kết luận: trên GSM8K cấu hình bất đối xứng bị chi phối (kém 10 điểm, chi phí FLOP tương đương); trên MATH là tiết kiệm biên 4–8% với độ chính xác hoà. Model mạnh đơn lẻ nằm trên đường Pareto ở cả hai task.

Điểm sáng duy nhất có ý nghĩa thống kê trong Bảng 4 lại nằm ở cấu hình *cùng cỡ*: thêm V7B vào chính S7B trên MATH được +7,7 điểm ($p = 0,0075$; McNemar), giá $1,7\times$ token. Theo ký hiệu §3.2, đây chính là một trường hợp $\text{acc}(E) > \text{acc}(I)$ — và đáng chú ý: nó xảy ra ở *chênh lệch bằng 0*. Cùng cấu hình đó trên GSM8K trả $1,7\times$ chi phí để *mất* 1 điểm — lợi ích của lượt kiểm cùng cỡ phụ thuộc task. Chúng tôi sẽ quay lại điểm dữ liệu này ở §5.6: nó là điểm duy nhất ủng hộ nửa dương của quy luật chênh.

Vì cùng một cặp model trên cùng họ bài xuất hiện với nhiều đại lượng khác nhau trong báo cáo, Bảng 6 đối chiếu để tránh đọc nhầm:

Còn một phép kiểm soát chưa áp: mẫu số. Mọi con số trên là trung bình toàn tập — kể cả những câu không cơ chế nào cứu nổi.

Tỷ số chi phí: bất đối xứng / S7B	Token thô 7B	Trọng số FLOP
GSM8K	$0,88\times$ (“rẻ hơn 12%”)	1,00–1,05 $\times$ — tiết kiệm biến mất
MATH	$0,78\times$ (“rẻ hơn 22%”)	0,92–0,96 $\times$ — còn 4–8%

Bảng 5: Hiệu chỉnh đơn giá token (độ nhạy ký tự/token quét 3,0–4,0). Chưa tính phần prefill — model 7B còn phải *đọc* bài làm của 1.5B — nên hiệu chỉnh vẫn đang thiên vị cho cấu hình bất đối xứng.

Con số	Đại lượng	Mốc so sánh	Thiết lập	Mục
+14,0 điểm	hiệu ứng lượt kiểm	<i>model yếu</i> (PS)	prompt kiểm, 300 bài	§5.3
–3,0 điểm	acc cấu hình	<i>model mạnh</i> (S7B)	như trên, 5 fold	§5.4
–12,4 điểm	$\Delta_{\text{thuc}} = \text{acc}(E) - \text{acc}(I)$	model mạnh	prompt <i>giải</i> , kèm artifact, $n=500$	§5.8
–16,6 điểm	Δ_{tran} (trần lý tưởng)	model mạnh	prompt sửa, bootstrap	§5.7

Bảng 6: Cùng cặp 1.5B→7B trên miền toán, bốn đại lượng khác nhau. Khác dấu giữa dòng đầu và ba dòng sau chính là hiện tượng trung tâm của khảo sát: đổi mốc so sánh thì đổi dấu.

5.5 Kiểm soát mẫu số: phần lớn số câu vốn bất động

Bảng 7 phân 150 bài theo “pool chứa bao nhiêu lời giải đúng”. Hai con số bất động cần phân biệt: *theo cấu trúc pool*, 57% số câu (0/5 và 5/5) không thể có hiệu ứng với bất kỳ bộ tổng hợp nào — không có gì để chọn hoặc không có gì để cải thiện; *đối với bỏ phiếu đa số* nói riêng, thêm tầng 1/5 (một phiếu không thắng nổi đa số) đưa tổng lên 70%. Trên tầng khả tác động, hiệu ứng của bỏ phiếu là +21,5 điểm (các tầng 1–4/5) hay +31,1 điểm (tầng 2–4/5); trung bình toàn tập pha loãng còn +9,3 — tỷ lệ pha loãng 2,3–3,3 lần tùy cách nhóm (tầng được xác định hậu nghiệm bằng chính kết quả sinh, nên đây là công cụ diễn giải, không phải mốc triển khai được). Một can thiệp +10 điểm thật chỉ tác động được tầng 2–4/5 (30% số bài) sẽ hiện ra +3,0 điểm toàn tập — dưới sàn nhiễu.

Ba phép kiểm soát vậy là ngược chiều nhau: thiếu mẫu số $\Rightarrow$ đánh giá *thấp*; thiếu chi phí hoặc mốc $\Rightarrow$ đánh giá *cao*. Hạn chế tự khai: các hiệu ứng chủ lực ở [§5.3–5.4](#) chưa được phân tầng lại theo cách này (thiếu dữ liệu theo-bài cho từng tầng); con số toàn tập của chúng vì vậy là ước lượng *thấp* của hiệu ứng trên tầng khả tác động.

Hết Hồi I. Bức tranh sau ba phép kiểm soát: giá trị dương chắc chắn duy nhất là lượt sinh thêm; cấu hình sửa-bài-của-nhau thua model mạnh đơn lẻ. Hồi II hỏi: giá trị mất đi đâu, và có quy luật nào đoán trước được không?

5.6 Số hạng G : cơ hội co lại khi chênh lệch tăng

Quan sát thô trên 7 cặp model gộp nhiều lần chạy: cặp *khác họ* có dư địa G cao hơn khoảng 24% (0,0597 so với 0,0481) — nhưng các cặp khác họ cũng có chênh lệch nhỏ hơn (0,130 so với 0,167); hai biến trộn hoàn toàn. Thiết kế tách (tiền đăng ký): 6 model, 15 cặp có hướng, cùng 499 bài MBPP, hồi quy

$$\begin{aligned}
 G &= \beta_0 + \beta_1 \cdot \text{chênh} + \beta_2 \cdot \text{khác_họ} \\
 \beta_1 &= -0,1922 \ (p \approx 0) \\
 \beta_2 &= +0,0045 \ (\text{KTC } [-0,0051; +0,0140]; \ p = 0,31).
 \end{aligned}$$

R^2 chỉ với chênh là 0,824. KTC của β_2 nằm trọn dưới ngưỡng tương đương +0,02 đã khoá trước — một kết quả null *có thông tin*: “khác họ” là tương quan giả; biến giải thích là chênh lệch năng lực. Và dấu của β_1 đáng chú ý: chênh lệch càng lớn, cơ hội G càng *nhỏ* — model yếu càng đuối thì càng hiếm bài nó cứu được model mạnh. (Kết quả đa dạng pool — 3 model cho 2,70/3 ứng viên phân biệt so với 1,91/3 khi cùng model — chỉ được ghi là “khác model”: đối chứng khác-model-cùng-họ chưa chạy.)

Thêm nhánh sửa cho cả 15 cặp (tiền đăng ký) cho quy luật của trần:

$$\Delta_{\text{tran}} = +0,0218 - 0,2392 \times \text{chênh}; \quad R^2 = 0,60; \ p = 10^{-5}; \ g^* \approx 0,09, \quad (2)$$

Số lượt đúng /5	n	Solver	ma j@5	Δ (điểm)
0/5 — quá khó	48 (32%)	0,000	0,000	0
1/5	20 (13%)	0,000	0,000	0
2/5	15	0,333	0,600	+26,7
3/5	12	0,583	1,000	+41,7
4/5	18	0,722	1,000	+27,8
5/5 — quá dễ	37 (25%)	1,000	1,000	0

Bảng 7: Phân tầng theo số lượt đúng trong 5 lượt sinh (MATH 1.5B, $n = 150$).

Cặp	Chênh	Δ_{tran} đo được	KTC 95%	MBPP dự báo	Phán quyết
7B→14B	0,044	−0,0140	[−0,046; +0,018]	+0,0108	trong khoảng
1.5B→7B	0,244	−0,1660	[−0,208; −0,124]	−0,0361	ngoài
1.5B→14B	0,288	−0,0680	[−0,102; −0,034]	−0,0471	trong khoảng

Bảng 8: Thử điểm tính chuyển miền của quy luật chênh (thang 0–1).

trong đó $g^* = \beta_0/|\beta_1|$ là mức chênh nơi đường khớp cắt 0 (tức ≈ 9 điểm accuracy; chúng tôi chưa ước lượng KTC cho g^* nên nó là mô tả xu hướng, chưa phải quy tắc vận hành). Đăng thức (1) khớp 15/15 cặp. Đọc kèm bắt buộc: 0/15 cặp dương có ý nghĩa, 3/15 âm có ý nghĩa — trên MBPP quy luật chỉ phát biểu được chiều phủ định (chênh vượt $\sim 0,09$ thì giao thức sửa cho hiệu ứng âm); xác lập vùng dương cần cỡ 8 lần dữ liệu MBPP. Hai điểm dữ liệu ngoài MBPP soi vào nửa dương: cặp 7B→14B trên MATH (chênh $0,044 < g^*$) đo được $-1,4$ điểm, KTC chứa cả hai phía — không ủng hộ; cấu hình cùng cỡ (chênh = 0) trên MATH đo được $+7,7$ điểm có ý nghĩa (§5.4) — ủng hộ. Nửa dương vì vậy dừng ở mức “một điểm thuận, một điểm không kết luận”. Chênh giải thích 82% phương sai của G nhưng chỉ 35% của L — phần lớn biến thiên của thiệt hại đến từ thứ khác, chưa định danh (đưa vào Hạn chế). (Ghi chú cơ chế^(mức B): ngưỡng bảo toàn mà lượt sửa phải vượt tăng theo chênh nhanh gấp đôi khả năng bảo toàn thực của nó — hệ số 2,18 so với 1,10; $p = 0,0066$ — gọi ý hiệu ứng âm phát sinh từ cấu trúc ngân sách $G-L$, không từ suy giảm năng lực nội tại của model mạnh.)

Quy luật rút trên code. Trước khi hỏi “ L do đâu”, thử xem nó có chuyển miền không.

5.7 Quy luật có chuyển miền không?

Dùng đường khớp (2) trên MBPP dự báo Δ_{tran} trên MATH (tiền đăng ký; 3 cặp Qwen; KTC bootstrap ghép cặp 10 000 lần) — Bảng 8:

2/3 dự báo trong khoảng: quy luật *không bị bác bỏ* — nhưng KTC rộng 0,064–0,084 nên phép kiểm có độ phân giải thấp, và thứ tự ba điểm không đơn điệu (chênh 0,244 âm sâu hơn chênh 0,288), nên tính đơn điệu của quy luật chưa kiểm được trên miền toán. Cặp lệch nằm ngoài một cách hệ thống — $L = 0,208$, gấp ~ 11 lần G — và tái lập ở một phép đo độc lập trên cùng cặp ($-0,1380 \rightarrow -0,1660$): quy luật mô tả xu hướng; ngoại lệ ở nơi model yếu quá yếu so với bài.

Cặp ngoại lệ ấy có L áp đảo. Mục tiếp theo mổ xẻ L : thiệt hại đến từ đâu?

5.8 Số hạng L : hình phạt của nội dung sai — và giao thức sửa là ống dẫn

Đây là thí nghiệm chính của khảo sát (tiền đăng ký; chọn MATH-500 để *đổi miền* so với quan sát thăm dò gốc trên MBPP), chính là thiết kế đã giới thiệu ở Hình 1: hai nhánh I và E dùng cùng một lệnh giải, khác duy nhất việc ngữ cảnh có kèm artifact của W ; kết quả phân tầng theo *nội dung* artifact — Bảng 9:

Trên tầng artifact sai, model mạnh rơi từ 46,4% xuống 19,2% — trên chính những bài nó vốn giải được gần một nửa; artifact đúng cải thiện nó. Tổng hợp trọng số hai tầng tái tạo đúng $\Delta_{\text{thuc}} = -12,4$ điểm. Kết luận cơ chế: D không phải hình phạt của việc nhìn thấy artifact nói chung, mà của việc nhìn thấy *nội dung sai*; và vì thiết kế không có lệnh sửa, chỉ riêng sự hiện diện của nội dung sai trong ngữ cảnh đã đủ tạo hiệu ứng âm. (Đối chứng loại trừ ảnh hưởng thuần độ dài ngữ cảnh — chèn một artifact đúng-nhưng-không-

Tầng	MBPP 11–510 ^(mức B)	MBPP 511–974 ^(mức B)	MATH-500 (mức A)
artifact sai	−19,0	−19,3	− 27,2 ($p \approx 0$; $n = 261$)
artifact đúng	+6,4	+2,5	+ 3,8 ($p = 0,012$; $n = 239$)

Bảng 9: Hiệu ứng tiếp xúc $\text{acc}(E) - \text{acc}(I)$ (đơn vị: điểm), phân tầng theo nội dung artifact. Hai cột MBPP là phân rã hậu nghiệm (mức B); cột MATH là thí nghiệm tiền đăng ký (mức A).

Tầng	n	E đúng (%)
W đúng, I đúng	228	99,6
W đúng, I sai	11	90,9
W sai, I đúng (vùng rủi ro)	121	36,4 — tức phá 63,6%
Cả hai sai	140	4,3

Bảng 10: Phân tầng 2×2 theo (W, I) trên MATH ($n = 500$), với tỷ lệ E đúng mỗi tầng.

liên-quan cùng độ dài — chưa chạy; ghi ở Hạn chế.) Quan sát này tương thích với “verifier tái sử dụng 0%” ở §5.3: model mạnh không *sao chép* bề mặt nội dung sai, nhưng vẫn bị nó *neo* hướng giải — ảnh hưởng đi qua định hướng, không qua trích dẫn.

Bảng 10 chấm lại toàn bộ 500 bài theo $(W \text{ đúng/sai}) \times (I \text{ đúng/sai})$, và ghi tỷ lệ E đúng trong từng ô — trả lời câu hỏi tự nhiên “khi model mạnh sai thì sửa có giúp không?”:

Ba đọc số từ Bảng 10. *Một*, giao thức sửa là **ông dẫn, không phải bộ sửa lỗi**: gần như không sáng tạo lời giải mới khi cả hai model đều trượt (4,3% = 6/140), phá ở quy mô lớn trên vùng rủi ro (63,6% = 77/121), và truyền lại đáp án đúng của W khi có (10/11 bài — tầng quá nhỏ để ước lượng chặt). *Hai*, ở cặp này tầng khai thác được nhỏ hơn vùng rủi ro 11 lần (11 so với 121 bài); tỷ lệ này co giãn theo chênh, chưa đo ở mức chênh khác. *Ba*, chiến lược “ W đúng thì giữ W ” chính là oracle TRAN — và ngay cả cho không oracle đó, mức tăng cũng chỉ +0,4 điểm (đúng thêm 2/500 bài), vì E vốn đã giữ được 99,6%/90,9%; kể cả vậy TRAN = 0,578 vẫn thua $I = 0,698$. Trong lớp giao thức sửa *bất đối xứng* đã đo, không cấu hình nào có $\text{acc}(E) > \text{acc}(I)$ (0/15 cặp MBPP, tốt nhất −3,0 điểm; các cặp MATH ở Bảng 8); trường hợp $E > I$ duy nhất là cấu hình cùng cỡ ở §5.4. Vấn đề không phải “quên giữ W ” — mà là E phá vùng rủi ro, và trong các phương án đã thử (hai cổng oracle ở §5.9), chỉ việc không đưa artifact vào ngữ cảnh bảo vệ được vùng đó.

G co lại, *L* phình ra theo chênh. *Mảnh cuối của khung*: bộ chọn κ — có tín hiệu khả thi nào nhạt được phần giá trị còn lại không?

5.9 κ và định tuyến: tín hiệu chắc chắn ăn trọn chặn trên; tín hiệu học được thì không

Tín hiệu chắc chắn. HumanEval, cùng model, cùng 4 lượt sinh, khác duy nhất nguồn kiểm — Bảng 11: `exec3` phá 0 bài trong cả 20/20 fold và đạt đúng `oracle@4` ở hai ô có ghi số (0,6438 và 0,8812); `llm3` phá ở cả 20 fold. Mốc trung thực trên code là greedy — bỏ phiếu *có hại* trên code (−11,3 và −13,1 điểm; lời giải dài hiếm khi trùng nhau nguyên văn): `exec3` − greedy dao động +6,3 đến +10,6 điểm qua bốn ô. Điều kiện áp dụng quan trọng: khi model nền *bão hoà* (GSM8K 7B, solver 0,916), một bộ kiểm thực thi độ chính xác 0,837 vẫn cho hiệu ứng rỗng âm (26 phá / 6 sửa) — “có bộ kiểm chắc chắn” chỉ đáng giá khi còn dư địa.

Tín hiệu học được. Bộ phân loại huấn luyện trên *lỗi tiêm* — lấy lời giải đúng rồi đổi một chữ số trong đáp án — rồi đem phát hiện lỗi thật; đây cũng chính là phép thử “thay một số trong đáp án, verifier có thấy không” — Bảng 12:

Ở 7B tín hiệu *đo* rất tốt (AUC 0,893; trên lỗi thật còn tách tốt hơn lỗi tiêm — cần loại trừ khả năng bộ phân loại bắt đặc trưng bề mặt như độ dài; đối chứng chưa chạy) — nhưng *dùng* thì chỉ đổi được +2,4 điểm, và 2/5 fold dương nghĩa là theo phép thử đầu của chính chúng tôi, mức tăng này chưa phân biệt được với 0. Tín hiệu *đo* được không tự động là tín hiệu *dùng* được — và điều đó *củng cố* phát biểu chặn trên

Ô	greedy	exec3	11m3	exec3 phá (bài/fold)	11m3 phá (bài/fold)
HE 1.5B (Kaggle)	0,5375	0,6000	0,4812	0,0	2,8
HE 1.5B (5090)	0,5625	0,6438	0,4375	0,0	4,6
HE 7B (5090)	0,8000	0,8812	0,7812	0,0	2,6
HE 7B (Kaggle)	0,7938	0,9000	0,7438	0,0	3,2

Bảng 11: Chọn bằng chạy test (exec3) so với LLM tự duyệt (11m3). Bốn ô là bốn điều kiện khác nhau (hai model $\times$ hai hệ phần cứng; độ trôi phần cứng $\sim 0,03$ nhỏ hơn hiệu ứng quan tâm nên kết luận về dấu vẫn đứng). **[TD: xác nhận đơn vị cột “phá”]**

Model	Tách biệt trên lỗi tiềm	Tách biệt trên lỗi thật	AUC	Δ độ chính xác khi dùng để chọn
1.5B	-0,012	+0,195	0,528	-0,8 điểm (1/5 fold dương)
7B	+0,573	+0,693	0,893	+2,4 điểm (2/5 fold dương)

Bảng 12: Bộ phân loại lỗi học được. Hai cột đầu: mức tách biệt điểm phân loại giữa lời giải đúng và sai, đo trên lỗi tiềm và lỗi thật **[TD: xác nhận định nghĩa chính xác của đại lượng hai cột này]**. Ở 1.5B, AUC 0,528 $\approx$ đoán ngẫu nhiên: thay một chữ số trong đáp án, verifier 1.5B không phát hiện được.

dưới đây.

Phát biểu hợp nhất. Đặt cạnh nhau: trên code, khoảng cách $\text{oracle}@k - \text{maj}@k$ là +21,3 điểm và exec3 lấy gần tròn (đạt đúng $\text{oracle}@4$, phá 0); trên toán, khoảng cách là 12–13 điểm (Bảng 2) nhưng tín hiệu học được tốt nhất chỉ lấy +2,4 điểm.


Khoảng cách $\text{oracle}@k - \text{maj}@k$ là **chặn trên** cho giá trị của mọi bộ kiểm trên cùng pool. Tín hiệu *chắc chắn* (chạy test) lấy gần tròn chặn đó; tín hiệu *học được* trong khảo sát của chúng tôi chỉ lấy được một phần nhỏ, dù chất lượng đo lỗi rất cao. Nút thắt của miền toán vì vậy kép: vừa thiếu tín hiệu chắc chắn, vừa nghèo pool — trong số bài mà $\text{maj}@5$ sai, 71% (48/68, tính từ Bảng 7) là bài pool không chứa nổi một ứng viên đúng, tức không bộ chọn nào cứu nổi.

Định tuyến (mức B). Hai kết quả về “chọn lúc nào cần gọi thêm”, đều mức B (do một lần, $n = 300$). *Consensus router* (chạy S, V ; bắt đồng mới gọi A): GSM8K giữ gần tròn phần lợi của pipeline với 77% chi phí (0,720 so với 0,723 ở 2,32 so với 3 lượt); MATH đạt 0,413 — bằng solver đơn lẻ, không mang lại gì. Cơ chế phía sau nhất quán với §5.8: tỷ lệ bài model yếu sai — tức tỷ lệ artifact sai trong ngữ cảnh — khoảng 33% trên GSM8K so với 59% trên MATH, và khi hai vai bất đồng, A cứu được 45,4% trường hợp trên GSM8K nhưng chỉ 25,0% trên MATH. Quan sát “định tuyến tiết kiệm ở đúng nơi ít cần tiết kiệm nhất” vì vậy dừng ở mức B. *Hai trăn cho cổng tiếp xúc* (tính trên dữ liệu §5.8): cổng-theo-artifact hoàn hảo (chỉ cho xem artifact đúng — oracle) được +1,8 điểm so với I ; bộ phân loại thật cần chính xác ~ 88 –89% mới hoà vốn (hoà vốn $\approx 27,2/(27,2 + 3,8)$ theo hai hiệu ứng ở Bảng 9). Cổng biết-khi- I -sai (oracle mạnh hơn) được +3,2 điểm — nhưng đòi phát hiện *lỗi của chính model mạnh*, đúng loại tín hiệu vừa cho thấy đo được mà không dùng được. Hàm ý: cải thiện bộ cổng có trần thấp; cấu hình mặc định không đưa artifact vào ngữ cảnh có kỳ vọng cao hơn.

6 Tổng hợp: nghịch lý nằm ở mốc so sánh

Hai kết quả tưởng chừng đối nghịch: §5.3 nói chênh lệch năng lực lớn cho +14,0 điểm; §5.6 nói chênh lệch lớn đẩy Δ_{tran} âm. Cùng một biến, hai dấu.

Lời giải: hai con số dùng hai mốc so sánh, và chênh lệch năng lực tác động ngược chiều lên hai mốc.



Hình 2: Nghịch lý móc so sánh. Cùng trục hoành là chênh lệch năng lực: hiệu ứng đo so với *model yếu* (đường liền; hai điểm đo MATH) tăng; giá trị so với *model mạnh* (đường đứt: khớp trên 15 cặp MBPP; chấm đỏ: ba điểm đo MATH của Bảng 8; ô vuông: điểm +7,7 tại chênh 0) giảm và âm sau g^* . Hình vẽ đúng số liệu nhưng nổi hai thiết lập khác nhau — xem Bảng 6 trước khi so hai đường theo trục tung.

- *So với model yếu* (cách đo phổ biến của dòng sinh-rồi-sửa): lượt kiểm là một lượt giải bằng model mạnh hơn (§5.3), nên hiệu ứng xấp xỉ chênh lệch năng lực cộng phần lượt-sinh-thêm — *tăng theo chênh gần như theo định nghĩa*: +3,0 điểm ở chênh 0 lên +14,0 điểm ở chênh 0,244.
- *So với model mạnh* (móc đúng của người triển khai): giá trị là $G - L + R$, trong đó G *giảm* theo chênh ($\beta_1 = -0,19$, §5.6) và L *tăng* — ở chênh 0,244 trên MATH, L gấp ~ 11 lần G — nên giá trị giảm, và điểm dương duy nhất đo được nằm ở chênh = 0 (+7,7 điểm, §5.4).

Nghịch lý vì vậy không nằm ở cơ chế mà ở phép đo: *chênh lệch năng lực chính là cái làm móc-so-với-model-yếu phồng lên và làm giá trị thật xẹp xuống*. Cơ chế nội dung sai (§5.8) giải thích vì sao phía móc-mạnh âm sâu đến vậy: càng chênh, artifact càng hay sai, model mạnh càng bị neo vào lời giải sai trên chính vùng nó vốn làm được.

Năm mảnh bằng chứng nội bộ hội tụ về bức tranh này: (1) cấu trúc — lớp chỉ-chọn đặt $L = 0$ theo định nghĩa; (2) độ lớn — $L \approx 11G$ ở chênh lớn trên MATH; (3) cơ chế — thiệt hại do tiếp xúc nội dung sai, tiền đăng ký, hai miền; (4) trần — cổng lọc hoàn hảo chỉ thu +1,8 điểm trên nền -12,4 điểm; (5) liên miền — quy luật MBPP không bị bác bỏ trên MATH ở 2/3 cặp (độ phân giải thấp). Một quan sát ngoài — tranh biện kém self-consistency ở model nhỏ trong số liệu công bố [Đ: nguồn] — nhất quán về hướng nhưng chờ xác nhận.

Cây quyết định thực dụng (trong phạm vi model 1,5B–32B, bốn benchmark suy luận):

- **Miền có cách kiểm chắc chắn** (code chạy test) và *model chưa bão hoà*: sinh độc lập rồi chọn bằng test — đạt trần, phá 0 bài. Khi model đã bão hoà, thêm bộ kiểm vẫn lỗ (26 phá / 6 sửa ở GSM8K 7B).
- **Miền không có**: bỏ phiếu đa số lấy được phần đáng kể của dư địa ở model nhỏ (43% ở MATH 1.5B) nhưng gần cạn ở model mạnh (8% ở 7B) và có hại trên code; thành phần LLM tổng hợp trung tính-đến-hại; tín hiệu học được đo tốt nhưng chưa đổi được thành độ chính xác.
- **Trong các miền đã khảo sát**: cấu hình cho model mạnh xem bài model yếu để sửa cho hiệu ứng âm hoặc không dương, rõ nhất khi chênh vượt $\sim 0,09$ (trên MBPP); móc phải so luôn là gọi thẳng model mạnh.

7 Kết luận và hạn chế

“Đa tác tử có giúp không” không có câu trả lời duy nhất; câu trả lời phụ thuộc ba thừa số đo được. Dư địa G do chênh lệch năng lực quyết định — và co lại khi chênh tăng; bộ chọn κ do tính chắc chắn của tín hiệu kiểm quyết định — không phải chất lượng đo; thiệt hại L do tiếp xúc với nội dung sai quyết định — và giao thức sửa, theo số liệu §5.8, hoạt động như ống dẫn đáp án hơn là bộ sửa lỗi. Cùng một chênh lệch năng lực làm phép so-với-model-yếu đẹp lên và giá trị thật xấu đi; nơi có bộ kiểm chắc chắn và còn dư địa, phối hợp chạm trần mà không phá bài nào; nơi không có, cấu hình tốt nhất đã đo là sinh độc lập và bỏ phiếu, không đưa bài làm của model này vào ngữ cảnh model khác. Phần lớn “cải thiện” ghi nhận ban đầu của chính chúng tôi không sống qua bộ ba kiểm soát cộng điều kiện hợp lệ — 16/32 lần chạy VOID, người đặt giả thuyết đoán đúng 21/43 — và chúng tôi coi việc quy trình bắt được điều đó là một kết quả phương pháp ngang hàng các kết quả nội dung.

Hạn chế.

1. Δ_{thuc} **mới phủ một phần không gian cấu hình**. Đại lượng triển khai được đã đo ở: 15 cặp MBPP (0/15 dương), 1 cặp MATH bất đối xứng (−12,4 điểm), và 1 cấu hình cùng cỡ (+7,7 điểm). Ba cặp xác nhận chéo mới (thiết kế H100) chạy dở vì giới hạn VRAM 14,6 GB: 8/9 nhánh sinh đã xong, còn một nhánh — kết quả chưa đọc theo đúng quy trình niêm phong.
2. **Mâu thuẫn A_{gain} đã thu hẹp nhưng chưa khép**: sau khi vá định dạng `\boxed`, hai lần chạy cho +0,8 và +8,0 điểm — cùng phía không-âm, còn khác độ lớn (khác bộ bài, khác lượng tử hoá); kết luận “aggregator trung tính sau xử lý định dạng” vì vậy ở mức giả thuyết.
3. Chênh giải thích 82% phương sai của G nhưng chỉ 35% của L : phần lớn biến thiên của thiệt hại chưa được định danh.
4. Phép thử danh tính vai trên MATH thiếu lực (KTC tới +13,4 điểm); đối chứng thêm-lượt-7B-không-kèm-artifact, đối chứng artifact trung tính cùng độ dài, và đối chứng khác-model-cùng-họ đều chưa chạy.
5. Tính chuyển miền dựa trên 3 cặp, KTC rộng, thứ tự không đơn điệu; vùng dương của quy luật chênh chỉ có một điểm thuận (+7,7 tại chênh 0) và không thể xác lập trên MBPP (thiếu lực ~ 8 lần); g^* chưa có KTC.
6. Định tuyến và các phân rã MBPP là mức B; khối luồng thông tin chỉ dùng greedy (mỗi cấu hình một điểm); các hiệu ứng chủ lực chưa phân tầng lại theo mẫu số khả tác động.
7. Phạm vi khẳng định: model 1,5B–32B trên bài toán suy luận; chưa nói được về model rất lớn. Hai chuẩn kiểm chứng của hai khối (fold so với tiền đăng ký) chưa kiểm chéo.

8 Đóng góp thành viên

[Đ: Nhóm xác nhận/điền ở Bước 0 — bản nháp:] Nguyên: thiết kế và chạy các thí nghiệm khối luồng thông tin và chi phí (§5.4–5.9), quy trình tiền đăng ký, chấp bút báo cáo. **Đức:** rà và xác nhận trích dẫn §2, đối chiếu mốc so sánh của các công trình sinh-rồi-sửa, hình bất đối xứng verifier. **Tùng Dương:** rà thiết lập thí nghiệm §4, kiểm định nghĩa các cột bảng 11–12, các hình còn lại.

Tài liệu

- [1] J. Austin et al. *Program Synthesis with Large Language Models*. arXiv:2108.07732, 2021.
- [2] Y. Benjamini, Y. Hochberg. *Controlling the False Discovery Rate*. JRSS–B 57(1), 1995.
- [3] M. Chen et al. *Evaluating Large Language Models Trained on Code*. arXiv:2107.03374, 2021.

- [4] K. Cobbe et al. *Training Verifiers to Solve Math Word Problems*. arXiv:2110.14168, 2021.
- [5] Y. Du et al. *Improving Factuality and Reasoning in Language Models through Multiagent Debate*. ICML, 2024.
- [6] Z. Gou et al. *CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing*. ICLR, 2024.
- [7] A. Grattafiori et al. *The Llama 3 Herd of Models*. arXiv:2407.21783, 2024.
- [8] D. Guo et al. *DeepSeek-Coder: When the Large Language Model Meets Programming*. arXiv:2401.14196, 2024.
- [9] D. Hendrycks et al. *Measuring Mathematical Problem Solving with the MATH Dataset*. NeurIPS, 2021.
- [10] J. Huang et al. *Large Language Models Cannot Self-Correct Reasoning Yet*. ICLR, 2024.
- [11] J. Kaplan et al. *Scaling Laws for Neural Language Models*. arXiv:2001.08361, 2020.
- [12] H. Lightman et al. *Let’s Verify Step by Step*. ICLR, 2024.
- [13] A. Madaan et al. *Self-Refine: Iterative Refinement with Self-Feedback*. NeurIPS, 2023.
- [14] L. S. Shapley. *A Value for n -Person Games*. Contributions to the Theory of Games II, 1953.
- [15] N. Shinn et al. *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS, 2023.
- [16] C. Snell et al. *Scaling LLM Test-Time Compute Optimally Can Be More Effective than Scaling Model Parameters*. arXiv:2408.03314, 2024.
- [17] X. Wang et al. *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. ICLR, 2023.
- [18] J. Wei et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.
- [19] A. Yang et al. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024.
- [20] L. Zheng et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS, 2023.

A Thuật ngữ và ký hiệu

greedy: giải mã tất định, luôn chọn token xác suất cao nhất; cùng cấu hình cho kết quả giống hệt.

maj@k / oracle@k / llm_agg@k: xem §4 (kèm ví dụ $\{7, 7, 7, 12, 15\}$).

artifact: bài làm của model yếu W , thứ được đưa (hoặc không) vào ngữ cảnh model mạnh.

$W / I / E$: model yếu; model mạnh độc lập; cùng model mạnh nhưng tiếp xúc artifact (§3.2).

$G / L / R$: cơ hội / thiệt hại / cứu — ba số hạng của $\Delta_{\text{tran}} = G - L + R$.

Δ_{tran} : trần lý tưởng trừ model mạnh (cần đáp án chuẩn — chỉ để sàng lọc); Δ_{thuc} : $\text{acc}(E) - \text{acc}(I)$, triển khai được.

chênh (lệch năng lực): hiệu accuracy một lượt giữa model mạnh và model yếu, thang 0–1; g^* : mức chênh nơi đường khớp Δ_{tran} đổi dấu.

V_gain / A_gain: hiệu accuracy khi thêm/bỏ vai V/A khỏi pipeline cùng cấu hình.

mức A / mức B: tiền đăng ký hoặc 5 fold kèm t-test / đo một lần hoặc hậu nghiệm (chỉ minh hoạ cơ chế).

VOID: lần chạy không đạt điều kiện hợp lệ khoá trước — không đọc số.

sàn nhiễu: biên độ dao động của cùng cấu hình giữa các fold (hiệu chuẩn: +1,0 đến +8,0 điểm).

B Con trở tư liệu gốc

- B.** Trích các bản tiền đăng ký (#104, #106, #107, #112) — `docs/PREREGISTRATION.md`.
- C.** Bảng niêm phong hash — `docs/RESULT_SEALS.md`; 16 lần chạy **VOID** (trên 32) và lý do.
- D.** Sổ dự đoán trước (21/43); 37 quy tắc quy trình — `docs/QUY_TRINH_VONG_LAP.md`.
- E.** Bảng kết quả đầy đủ khối nhóm — `docs/RESULTS.md`; phân tích Shapley theo vai — `docs/`.
- F.** Rà thống kê giữa kỳ và các phán quyết — `report/CAU_HOI_THAO_LUAN.md` (nhóm E, A6–A7, F).